

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Brouillon

1. Problématique

- Sur la compréhension du cinéma par l'IA :

Ce qui est encore en cours de développement pour les outils actuellement = compréhension du langage cinématographique (montage, narration), analyse des ambiances et émotions, détection d'œuvres musicales.

Incapacité des machines à comprendre le langage ciné pour l'instant et à l'analyser correctement : pourquoi ?

Il n'existe pas de solution tout en un

L'image animée regroupe bcp de choses.

- Interface et l'expérience utilisateur :

Comment combiner performance technique et expérience utilisateur au sein de l'application avec l'implémentation de l'IA ?

Implémentation de deux outils de recherche assistée dans l'application : comment guider l'utilisateur vers l'outil qu'il cherche ?

Faire une interface utilisateur qui augmente la productivité et l'interactivité mais en même temps qui reste adaptée aux institutions culturelles qui n'ont pas forcément d'objectifs de rendement et de productivité comme des entreprises privées. Trouver la limite. Ne pas en faire une appli de marketing.

Tensions entre besoins utilisateurs musée / et une logique de productivité d'entreprise privée vers laquelle se tourne de plus en plus l'application : tableau de bord, intelligence artificielle.

Améliorer l'interface et l'expérience utilisateur est ce qui fait prospérer skinsoft et ce qui la démarque de ses concurrents.

- Migration de données :

Décalage entre ce que le client veut pour ses données, et ce que skin soft est capable de faire. Un changement de logiciel induit forcément une modification de la saisie des données, même si l'application est entièrement paramétrable. Décalage entre ce que l'institution attend et ce que skinsoft peut faire conformément aux standards documentaires, au temps qu'ils peuvent y consacrer et aux limites de l'application et de l'interface.

Difficulté de paramétrer l'application en fonction de la manière de saisir les données propres à chaque institution, des thésaurus utilisés...

L'application et les paramétrages évoluent presque à chaque nouveau client et devient plus malléable.

- Sur l'indexation :

La génération de résumé sur une archive audiovisuelle prévue par skin soft se fait de quelle façon, à partir de quelles données ?

Résumé à partir de notices déjà constituées sur l'archives en question

Extraction des éléments dans l'image : autorités

Extraction d'éléments dans le son

Comment le NLP transforme les pratiques d'indexation ? Lien entre les deux ?

Pour l'instant, il existe des modèles qui permettent de détecter la séparation entre les plans grâce au changement de position des personnages, changement de lumières... Mais la détection du changement de séquences se situe à un niveau supplémentaire de compréhension du langage cinématographique. Cela suppose de comprendre ce qu'est une séquence (combinaison d'un changement temporel et spatial). Comment améliorer les modèles qui détecte les changements de plans pour leur faire comprendre les changements de séquences ? Surtout sur des archives audiovisuelles où il se passe peu de choses dans l'image. La plupart des cas d'usages vus et lus sont entraînés sur des séquences de télévision par exemple, un langage "classique et normé qui est toujours le même. Pour les archives très anciennes comme celles d'Albert Kahn, il n'y a pas de coupures ou très peu, les plans sont fixes, les sujets sont généralement loins de la caméra. est ce que c'est plus facile à entraîner ? comment entraîner un modèle qui puisse analyser des vidéos à la fois très similaires et très différentes en termes de langage cinématographique ?

les archives audiovisuelles nécessitent une indexation de contenu : extraction d'information à partir de ce qui se trouve dans l'image

pour les archives papier, l'indexation automatique des archives nées numériques et les archives numérisées est différentes. Pour les archives nées numériques, il existe déjà un produit numérique : pdf par exemple ou document texte. Pour une archive numérisée, il faut produire ce dérivé pour y appliquer de la reconnaissance d'entités, de caractères... Est-ce la même chose pour les archives audiovisuelles ? Ou ça ne change rien ?

permettre l'annotation vidéo : pour qui ? quand ? comment ?

L'un des problèmes sur la mise en place de l'IA dans les institutions patrimoniales est un manque de moyens financiers et de savoir faire technique. Les institutions sont souvent limitées à choisir des outils déjà entraînés et constitués à partir de données souvent différentes et éloignées des archives historiques complexes et hétérogènes (whisper, MMS...). Cela donne une indexation imprécise, risquée et pas forcément performante. Skinsoft est une entreprise innovante au service de ces institutions, cela peut être son rôle de proposer aux musées des outils entraînés à partir de données historiques et donc plus performants pour des collections patrimoniales. ou alors récupérer des modèles et les réentraîner.

Définition de l'indexation documentaire

- **Indexation documentaire (Sumominen, Husson, Reignier)**

définition de l'indexation : "Le fait de dresser un répertoire ou une liste, généralement alphabétique, des sujets traités, des noms cités dans un ouvrage, suivis des références aux pages, aux paragraphes" (Rolland-Coul. 1969).¹

autre définition : Selon l'AFNOR, l'indexation est la "représentation par les éléments d'un langage documentaire ou naturel, des notions résultant de l'analyse du contenu d'un document en vue d'en faciliter la recherche"²

définition de l'indexation : "L'indexation est cette technique consistant à caractériser le contenu d'un document et l'information qu'il détient de manière à le retrouver quand on effectue des recherches sur l'un des sujets dont il traite. La difficulté est donc de savoir caractériser et représenter l'information documentaire pour qu'il soit aisé de la mettre en rapport avec des sujets d'investigation. Mise en rapport d'une requête et d'un contenu représenté et synthétisé, l'indexation permet de s'orienter dans la masse des

¹INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).

²Pierre Husson, « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RETIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).

documents et d'organiser ses connaissances. L'indexation appartient donc à ce qu'on appelle depuis quelques années les techniques intellectuelles Indexation et archivage de contenus multimédias”³

Contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ». ⁴ (aussi placé dans IAcinema)

- **Archives audiovisuelles (Bassaïsteguy (INA), Rattinger, Le Ber, Attard)**
- **IA et vision par ordinateur (Arnab (ViViT), Gong (AST), Trojahn, Yuan)**

2. Indexation automatique

- Pourquoi automatiser l'indexation ?

Pour justifier l'indexation automatique : « Les bibliothèques gèrent un grand nombre de métadonnées, pour différents types de documents. Le plus souvent, ces documents sont indexés à l'aide de mots sujets sélectionnés au sein d'un vocabulaire contrôlé, afin d'être recherchés plus tard. L'indexation manuelle de documents est un travail intellectuel très consommateur de temps. »⁵

« Incomplete descriptive metadata often hinder their access by the public. ⁶ Légitime la mise en place d'une indexation automatique car elle servirait à compléter des métadonnées manquantes et donc à rendre accès les collections plus facilement au public. Le manque de métadonnées et d'informations, d'indexation est souvent un frein lors de la publication en ligne, de l'accès au public (car pas de contexte : risque de contradictions historiques).

« Les systèmes d'indexation automatique suivent généralement un processus dans lequel les documents textuels sont, dans un premier temps, ”préparés” [...] les documents sont convertis dans une représentation vectorielle de leur fréquence d'apparition, ce

³Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

⁴*Ibid.*

⁵Osma Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605, p. 21.

⁶Peter Sullivan et Muhammad Abdul-Mageed, *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].

qui, à l'aide d'un algorithme, permet d'établir des comparaisons entre les mots-sujets utilisés. »⁷ Pour les images : comparaison des objets. La différence de médium modifie les outils utilisés et la manière de les utiliser pour en tirer des infos.

« Les algorithmes d'indexation automatique se répartissent selon deux types d'approche : lexicale et associative. »⁸

Pour les archives audiovisuelles, des processus techniques s'ajoutent : extraction d'entités depuis l'image, extraction d'entités depuis le son. La forme du médium cinématographique crée une opacité et une complexité pour l'instauration de pipeline algorithmiques.

- **Pipeline**

Mise en place d'une pipeline IA : Ce sont plusieurs outils combinés qui créent l'indexation : analyse audio avec l'ASR et la segmentation, analyse de l'image avec la computer vision et shot detection, le NLP avec le NER et term extraction. Cette pipeline permet d'extraire des métadonnées en lien avec des vocabulaires contrôlés et ainsi d'indexer les images. « Each tool specializes in a single task, and is brought together with other tools in pipelines. Technologies can be layered upon one another in order to more meaningfully annotate content. »⁹

Implémentation d'une combinaison d'outils différents pour l'indexation : "La combinaison de différents outils et leur intégration dans des environnements logiciels existants est un sujet important, pour lequel il existe désormais un large éventail de solutions, souvent open source"¹⁰

- **Outils**

Trint : automatic speech recognition FasterR CNN et Farec CNN : face detection models YOLO : outil opensource de détection d'objets et d'identification

- **Cas d'indexation**

The vanderbilt university television news archive : ils utilisent Trint pour transcrire les discours et engagent des étudiants pour corriger les transcriptions sur l'interface de l'outil Trint :

⁷O. Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande »..., p. 21.

⁸*Ibid.*

⁹*AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).

¹⁰Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

”students also note the start and stop time of segments, and write relevant on-screen information such as names into the transcript. Each 30-minute program takes one hour of student worker time to correct. When the transcript is complete, it is exported to Amazon’s Named Entity Recognition service on the cloud, where information such as person, location, or topic is pulled out. That information is then brought back into the workflow with scripts written in Python that turn the information into individual titles for each news segment. Additional information such as reporter or location are added to database fields, and duplicate records are kept in PBCore for future use when more of the information from the Named Entity Recognition system might be stored in the database.”¹¹

- Points d’attention la qualité des images est absolument primordiale et déterminante dans la mise en place d’un pipeline d’indexation automatique : ”La question de la qualité des images est cruciale dans le cadre d’un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d’impacter les performances de l’algorithme utilisé, et d’affecter négativement les interprétations du modèle”.¹²

3. indexation iconographique

- Définition « L’indexation iconographique consiste à décrire le contenu des images à l’aide de descripteurs afin de faciliter l’accès aux œuvres, sans cependant dispenser sa consultation. »¹³

- Outils

”When it comes to processing image-based records in archives, supervised learning models can be helpful for identification and classification, while unsupervised learning models are best suited for processing large amounts of data for creating generic descriptions, and highlighting possible connections between records.”¹⁴

- cas d’usage

Computer-Aided Metadata generation for Photo Archives Initiative (CAMPI)¹⁵ production de tags sur des images et recommandation d’images similaires

¹¹*Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).

¹²Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l’exemple des manuscrits d’astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l’Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

¹³P. Husson, « Indexation iconographique et intelligence artificielle... », p. 3.

¹⁴Kaila Fewster et Richard Arias, « Teachable AI for the Archival Professions – Module 4 : » ().

¹⁵*Ibid.*

détection d'objets

YOLO (you only look once) Algorithme qui utilise CNNs pour entourer des objets dans des images et les classer dans des catégories il s'agit d'un single shot object detector : il se base sur une seule analyse de l'image dans sa globalité facial recognition, scene analysis, object tracking¹⁶

two shot objects detector : multiple image reviews Exemple : Mask Region-based CNN (R-CNN) algorithm. "uses deep neural networks to identify regions of interest in the photograph and build boxes around objects found throughout the image"¹⁷ Cette manière de faire est appelée "semantic segmentation" : "identifies semantic objects without specifying how many instances of that object are present in the image"¹⁸ Par exemple, s'il y a 5 personnes dans une image, la segmentation sémantique les identifie comme un même objet sémantique dans l'image.

Instance segmentation : "identifies all the semantic objects in an image and segments them into specific instances to accurately distinguish between each object of a similar semantic category" (c'est ce que fait Mask RCNN)¹⁹

4. indexation audio

- Indexation audio

automatic speech recognition and speech translation

Selon une expérimentation de Sullivan et Abdul-Mageed en 2025 sur des archives de l'unesco, Whisper V3 est le modèle le plus convaincant pour identifier la langue dans une piste audio (LID), avec 91,13 pourcent de précision. En revanche, MMS (massively multilingual speech) de Meta obtient une précision de seulement 11 pourcent. Cela s'explique car MMS a été entraîné sur des données trop homogènes (enregistrements de la bible).²⁰

les embedding de locuteurs (représentations vectorielle sde voix) se dégradent dans deux cas : si un locuteur parle plusieurs langues différentes, ce sont plusieurs locuteurs qui sont reconnus. Si un long moment sépare deux enregistrements d'un même locuteur, il est également interprété comme deux personnes différentes. « Speaker embeddings

¹⁶ *Ibid.*

¹⁷ *Ibid.*

¹⁸ *Ibid.*

¹⁹ *Ibid.*

²⁰ P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

remain a fragile component of speech processing pipelines that is prone to biases related to the channel, age, and language. »²¹

5. notions IA

- Définition

”Par IA, on entend, dans une acception large et ouverte, la tentative de construire des machines et des systèmes capables de penser et d’agir rationnellement”²² donc à terme, de pouvoir effectuer exactement les mêmes actions spécialisées que l’homme, telles que l’indexation, qui est une tâche certes répétitive, mais complexe, qui varie selon le type de corpus.

6. machine learning

- Machine learning ”Le ML est un domaine de l’IA qui regroupe les méthodes, les processus et les techniques nécessaires pour rendre une machine ou un système informatique plus « intelligent ».”²³ c’est à cette étape que la machine apprend et est entraînée sur les techniques d’indexation à partir d’exemples humains : annotation de données.

”L’idée à la base du ML est qu’une machine peut résoudre des problèmes de la même manière que l’homme, en apprenant à partir d’« expériences » et d’exemples, sans être explicitement programmée pour la résolution spécifique du problème. Ainsi, au lieu d’implémenter un algorithme concret de résolution de problèmes dans une machine, les données sont transmises à un algorithme générique qui, par un « processus d’apprentissage », devient lui-même capable de résoudre les problèmes.”²⁴

Il existe différentes méthodes de machine learning : Apprentissage supervisé Apprentissage non supervisé Apprentissage profond et réseaux neuronaux artificiels (deep learning)

”La raison pour laquelle telle ou telle fonction s’impose pendant le processus d’apprentissage ne peut être reconstituée que rétrospectivement et favorise souvent des décisions curieuses de l’algorithme. L’un des principaux problèmes réside dans le fait que les systèmes ne font pas la distinction entre les corrélations et les causalités dans les ensembles de données. L’exemple d’une « recherche de vaches sur des images » illustre bien cette

²¹ *Ibid.*

²² J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives »...

²³ *Ibid.*

²⁴ *Ibid.*

situation : les vaches se trouvent souvent dans des prairies ; le modèle commence alors à ajouter « prairie » (couleur, formes, modèles d’images) au concept « vache ». L’algorithme n’a donc appris qu’une corrélation sur la base d’une probabilité statistique (vache et pré), mais n’a pas compris les relations.”²⁵

Exemple de transcription basée sur le machine learning : Transkribus : peut aussi s’appliquer aux archives audiovisuelles.

- Deep learning

méthode dérivée du machine learning basée sur les réseaux de neurones.

”L’apprentissage profond permet d’envisager une redéfinition des méthodes des historiens et historiens de l’art, en intégrant une part d’automatisation dans le traitement des sources iconographiques, permettant ainsi d’envisager l’exploration de corpus bien plus vastes ”²⁶

”La recherche de similarité compte parmi les applications les plus directes du deep learning”, ” elle permet de classifier les images en vue de leur étude en constituant des séries iconographiques aux caractéristiques visuelles similaires, selon un score de similarité calculé par l’algorithme”²⁷

Transformers

Récemment, une transition architecturale des modèles a produit un basculement vers des modèles basés sur les transformers en vision par ordinateur, remplaçant progressivement les CNN. Cela explique pourquoi les outils actuellement disponibles comme CLIP, ViViT, AT, sont tous basés sur cette architecture.

”les vision transformers (ViT) s’avèrent souvent plus efficaces que les réseaux de neurones convolutifs (CNN) dans des domaines tels que la segmentation d’image, la détection d’objets et les tâches connexes. L’architecture de type transformer alimente également de nombreux modèles de diffusion utilisés pour la génération d’images, le Text to Speech multimodal et les modèles vision-langage (VLM).”²⁸ ”En raison de leur capacité à comprendre la manière complexe dont chaque partie d’une séquence de données influence les autres et s’y rapporte, les modèles transformers permettent également un usage multimodal.”²⁹ ”La fonctionnalité centrale des modèles transformers est leur

²⁵ *Ibid.*

²⁶ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

²⁷ *Ibid.*

²⁸ Cole Stryker Bergmann Dave, *Qu’est-ce qu’un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

²⁹ *Ibid.*

mécanisme d'auto-attention, dont ils tirent leur incroyable capacité à détecter les relations (ou dépendances) entre les différentes parties d'une entrée. Contrairement aux architectures RNN et CNN qui l'ont précédée, l'architecture de type transformer utilise uniquement des couches d'attention et des couches de propagation standard.³⁰ Les RNN et CNN analysent les données de façon "sérielle"³¹, dans un ordre donné, les empêchant ainsi de saisir les "dépendances à longue portée".³² Les transformers : "Les mécanismes d'attention, quant à eux, examinent simultanément les séquences dans leur intégralité et décident de la manière et du moment où il convient de se concentrer sur certaines étapes de chaque séquence.", "En plus d'améliorer considérablement la capacité à comprendre les dépendances à longue portée, cette qualité des transformeurs permet également la parallélisation, qui consiste à réaliser plusieurs étapes de calcul simultanément, au lieu de les sérialiser."³³

les transformers pour l'analyse d'image : "Les transformeurs offrent également certains avantages par rapport aux réseaux de neurones, en particulier pour les données visuelles. Intrinsèquement locaux, les CNN utilisent des convolutions pour traiter successivement les sous-ensembles de données d'entrée. Par conséquent, les CNN peinent à discerner les dépendances à longue portée, telles que les corrélations entre les mots (dans un texte) ou les pixels (dans une image) qui ne sont pas voisins. Les mécanismes d'attention n'ont pas cette limitation."³⁴

CNN : réseau de neurones convolutif Outils de classification : "modèles de programmation puissants permettant notamment la reconnaissance d'images en attribuant automatiquement à chaque image fournie en entrée, une étiquette correspondant à sa classe d'appartenance."³⁵ l'un des principaux cas d'usages des CNN est la "reconnaissance d'images". "Dans une moindre mesure, on les utilise aussi pour l'analyse vidéo."³⁶

7. computer vision

Branche de l'IA qui permet principalement d'extraire de l'information d'images ou de vidéos. Permet aux machines de "voir", comme les humains et ainsi d'extraire des données d'éléments visuels. Aujourd'hui, la computer vision se fait par machine learning.

³⁰ *Ibid.*

³¹ *Ibid.*

³² *Ibid.*

³³ *Ibid.*

³⁴ *Ibid.*

³⁵ Jérémie Robert, *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).

³⁶ *Ibid.*

- Définition

”La vision par ordinateur est un domaine d’intelligence artificielle (IA) qui permet aux ordinateurs et aux systèmes d’extraire des informations pertinentes à partir d’images, de vidéos et d’autres entrées visuelles numériques, pour prendre des mesures selon ces entrées. Cette capacité à fournir des recommandations la distingue des tâches de reconnaissance d’images.”³⁷

les composants de la vision par ordinateur ont été mis en place en partie pour l’analyse d’images et la détection d’objets dans l’image.³⁸

”La détection de contours (ou edge detection) est une étape fondamentale pour le traitement des images en vision artificielle : combinée à des méthodes de détection des lignes il devient envisageable d’automatiser la transformation d’images au format .tiff ou .jpeg en objets plus aisément manipulables”³⁹

Etapas d’entraînement d’un modèle : ”prévoir un jeu de données initial, et d’évaluer les performances du modèle après ce premier entraînement. À partir de ces résultats, il devient possible d’adapter les jeux de données suivants, pour pallier aux faiblesses constatées.”⁴⁰

”Pour des tâches classiques de vision artificielle, telles que la détection d’objet, des modèles pré-entraînés performants existent en libre accès, qui ne nécessitent donc pas autant de travail d’entraînement qu’un modèle créé dans son entièreté pour un projet. Des jeux de données en accès libre sont également disponibles pour l’entraînement de modèles pour la détection automatique, tels que ImageNet 16, qui bien qu’ils ne soient pas adaptés à des sources historiques, permettent d’effectuer un premier entraînement d’un modèle sans mobiliser les moyens nécessaires à la création d’un jeu de données.”⁴¹
limites : est ce qu’il en existe tout autant pour les corpus vidéos ? à chercher

- cas d’application

Object detection :⁴² single shot detector : YOLO, using CNN two stages detectors : Deux analyses de l’image. Demande plus de puissance de calcul mais est plus efficace. pour prédire, analyser et comparer la performance des différents modèles de détection

³⁷ *Qu’est-ce qu’un réseau de neurones convolutifs ?* / IBM, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).

³⁸ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

³⁹ *Ibid.*

⁴⁰ *Ibid.*

⁴¹ *Ibid.*

⁴² *YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).

d'objet, on a besoin de "standard quantitative metrics". Les plus communs "evaluation metrics" sont : INtersection over union (LOu) et average precision (AP)

YOLO : réseau de neurones qui fait des prédictions sur la détection d'objets et qui les classifie "all at once". (à placer aussi dans les cas d'usages sur les archives audiovisuelles)

Content-Based Image Retrieval : une des applications de la computer vision. Exemple de cas d'usage : Galt archives avec Archippanion⁴³

Visual language models (VLMs) : combinaison d'algorithmes de computer vision et de LLMs pour : "create visual outputs based on input text, or textual outputs based on images or video" / "VLMs are able to do a variety of vision language tasks like captioning and summarization, image generation, search and retrieval, and object detection and segmentation" "However, there are still challenges with these emerging models like biases, hallucinations, and overgeneralizations as well as concerns of cost and environmental impact considering that VLMs combine two already complex AI architectures into one even more complicated tool"⁴⁴ exemple de VLM : CLIP : génère de la description en langage naturel à partir d'éléments visuels

8. IA appliquée à la vidéo

- audiovisual processing Audiovisuel Processing (AVP) : ensemble de technologies appliquées à l'analyse de contenus vidéos et audio (comprend computer vision et ASR automatic speech recognition)⁴⁵

constat : malgré de grandes avancées dans le processing audiovisuel, ces outils restent largement inaccessibles et ne sont pas donc pas adoptés dans le milieu des archives : « Despite the massive progress made in the performance levels and overall availability of Audiovisual Processing (AVP) technologies, such as Computer Vision (CV) and Automatic Speech Recognition (ASR), the availability of these tools for heritage institutions is still lagging behind. »

autre constat : "« Digital tools for paper resources have tended not to consider the strong presence of visual elements in them. Due to the lack of practically available AVP tools to digital humanities, scholarly research has 'grossly neglected visual content, causing a lopsided representation of all sorts of digitized archives'. » Sous représentation des éléments visuels dans l'indexation, même pour une collection audiovisuelle. Les

⁴³K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

⁴⁴*Ibid.*

⁴⁵Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

métadonnées textuelles liées aux films sont nsuffisantes pour enrichir leurs métadonnées : titre, synopsis...⁴⁶

- Cas d'usage

Reconnaissance et extraction d'objets

Exemple de projet d'extraction d'entités depuis des images en mouvement :⁴⁷ Méthode du distant viewing : reconnaissance des visages, classification des plans. Le montage et le cadrage servent à construire la place des personnages dans le récit. « One of the first tasks in understanding a video file is to break up the sequence of frames into distinct units known as shots ». « We first split an input video file into individual shots, then locate faces within every frame, identify the faces in a frame, and finally put all of the information together to cluster shots based on camera angles and distances ».⁴⁸

Shot boundary detection

Shot boundary detection : détection automatique des coupures entre les plans dans une vidéo Shot semantics : description de ce qui est présent dans l'image et à quel endroit de l'image et ainsi relier l'image à des catégories de plan (shot type).

exemple de pipeline pour détecter les coupures entre les plans : "the vast majority of cuts in most film and television episodes consist of abrupt transitions between alternative camera shots. These are both easy to define and relatively easy to detect. The algorithm we use in our analysis uses a combination of histogram differences and down sampled pixel intensities. Our method functions by measuring the extent to which two successive shots are different from one another in terms of the general color palette and the distribution of brightness over the frame. If these differences fall above a specified threshold, we indicate the presence of a cut.²² We also added special logic to avoid erroneous cuts during fade-in and fade-out events."⁴⁹

face detection models : Faster R-CNN and FAREC-CNN⁵⁰

Shot classification : il est possible de classifier le type de plan à l'image en utilisant le placement des visages : "In this final step we no longer work directly with the visual materials and build a meta-algorithm that takes detected shot breaks and faces as input and outputs categorical predictions for each shot".⁵¹ Il s'agit de définir tous les types de

⁴⁶ *Ibid.*

⁴⁷ Taylor Arnold, Lauren Tilton et Annie Berke, « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4-2 (juill. 2019), DOI : 10.22148/16.043.

⁴⁸ *Ibid.*

⁴⁹ *Ibid.*

⁵⁰ *Ibid.*

⁵¹ *Ibid.*

plans et à partir de ces définitions, construire un jeu de données qui sera testé : close-up, over the shoulder...

Outils AVP

ImageJ : open source visual analysis software suite⁵² Detectron2 : détection de points corporels dans l'image⁵³

- Limites et discussion

les AVP ne sont pas accessibles en libre accès aux chercheurs en humanité numériques. Les algorithmes ont besoin d'un accès direct aux données, or, pour des raisons de sécurité des données et des droits de propriétés intellectuelles auxquels sont soumis les archives, les données des archives ne peuvent pas quitter leur environnement numérique. donc : "A side effect of this is that for the analysis of AV material commercially available tools cannot be used, as these are primarily cloud based. To tackle this challenge it is necessary that any AVP infrastructure can be integrated with a local archival infrastructure, i.e., we need to bring the algorithms to the data, rather than the data to the algorithms"⁵⁴

au lieu de transférer les fichiers vers un service externe, l'algorithme doit être déployé localement au sein même de l'infrastructure de l'archive.

exemple de l'architecture DANE au sein du projet CLARIAH : l'architecture est divisée en plusieurs "workers" et une file d'attente. si l'un des workers s'arrête de fonctionner, les autres continuent leur tâche. Cette architecture produit deux types de données : des métadonnées structurées directement exploitables, et des vecteurs de caractéristiques (= représentations abstraites des données utilisables pour des requêtes de similarité : ouvre des possibilités de recherche par ressemblance son et vidéo.)⁵⁵

"there is a near-linear relationship between quality of transcriptions and search performance." : importance de la qualité de la transcription audiovisuelle pour améliorer la recherche.⁵⁶

"the application of AVP tools to large image datasets significantly scales up the level of analysis from 'close' to 'distant' viewing, allowing scholars to observe patterns in the data that are invisible in the traditional, interpretative analyses of small sample sets."

⁵²N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

⁵³*Ibid.*

⁵⁴*Ibid.*

⁵⁵*Ibid.*

⁵⁶*Ibid.*

le distant viewing permet de passer d'une lecture individuelle d'items à une analyse d'éléments à l'échelle d'un corpus.⁵⁷

9. segmentation

- pourquoi segmenter ?

La segmentation comme logique documentaire : la segmentation d'une vidéo crée de nouveaux éléments indexables Cordell : "your object of study is no longer an entire film but shots or scenes"⁵⁸

Qu'est-ce que ça signifie pour l'institution de passer d'un objet-film à une collection de plans ? Quelles sont les implications pour le droit, pour l'accès public, pour la description archivistique ?

La segmentation découle d'une logique et d'un objectif d'indexation : problématique principale pour indexer : il faut déjà séparer la vidéo en tous les plans qui la composent pour en extraire les éléments : "One of the first tasks in understanding a video file is to break up the sequence of frames into distinct units known as shots—or uninterrupted footage between cuts—in a process known as shot boundary detection."⁵⁹

Une vidéo doit être segmentée avant de pouvoir être indexée : « One of the most common initial steps for video content organisation is segmenting the video into different meaningful parts. Proper segmentation facilitates content organisation, improves accessibility, and enhances the ability to perform analytics on large video datasets. »⁶⁰

pour justifier la mise en place d'une segmentation : « Automated segmentation accelerates the processing of large volumes of video content and ensures consistency and accuracy in the segmentation process. »⁶¹ la mise en place d'une automatisation de la segmentation permettrait d'homogénéiser l'indexation documentaire : un algorithme segmente les vidéos de la même façon, pas les humains. Mais les vidéos sont toutes différentes : est ce qu'on peut garder la même pratique de segmentation sur des corpus vidéo différents ?

⁵⁷ *Ibid.*

⁵⁸ Ryan Cordell, « Machine Learning + Libraries » ().

⁵⁹ T. Arnold, L. Tilton et A. Berke, « Visual Style in Two Network Era Sitcoms »...

⁶⁰ Jonathan Attard et Dylan Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].

⁶¹ *Ibid.*

– Pipelines de segmentation

Pyscenedetect Une idée de pipeline de segmentation : est la détection de scènes avec pyscenedetect (découpage d’une vidéo en segments en détectant les coupes visuelle), puis classification des segments. D’un côté la segmentation syntaxique et de l’autre la classification sémantique.⁶²

ResNet (pas de la segmentation : créer un fichier sur la classification ?) Le meilleur classifieur d’images avec le plus haut résultat de précision selon attard 2025 est ResNet⁶³

Recommandations : Les modèles multimodaux qui combinent audio et vidéo (vivit-ast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d’usage et qui séparent les pipelines.⁶⁴

ViViT Expérimentation avec ViViT : le modèle ViViT, modèle basé sur des transformers, capture les caractéristiques spatio temporelles de la vidéo, contrairement à Resnet qui analyse chaque image d’un vidéo indépendamment. ViViT extrait ”extracts spatio-temporal tokens from the input video, which are then encoded by a series of transformer layers.”⁶⁵. C’est un modèle qui tente d’analyser l’espace et le temps dans une vidéo donnée. Vivit adopte donc une approche ”video-native”. Le modèle à choisir dépend de la nature du corpus audiovisuel que l’on souhaite indexer. Si les archives sont des plans fixes qui ne changent que très peu, resnet suffit.

Conclusion sur ViViT : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset to train. »⁶⁶. : les transformers n’ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu’il soit dans l’image. Ils ont donc besoin d’être entraînés sur beaucoup plus de données : c’est une grande limite. Une approche par calssifieurs d’images plus légers comme ResNet peut donc être préférable. ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d’archives historique sauf pré entraînement massif.

⁶² *Ibid.*

⁶³ *Ibid.*

⁶⁴ *Ibid.*

⁶⁵ Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić et Cordelia Schmid, *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].

⁶⁶ *Ibid.*

2SDS

l'étude de xin2023⁶⁷ présente 2SDS, un algorithme de segmentation temporelle vidéo. Plutôt que d'utiliser un réseau de neurones pour détecter les changements de scènes, 2SDS compare des empreintes (hash) d'images successives. Si deux frames sont suffisamment différentes (distance de Hamming supérieure à un seuil), elles appartiennent à des scènes distinctes. « 2D CNNs only recognise a video as discrete images, rather than a continuous stream of images. This poses some issues. For example, a CNN model could not resolve the motion of a person because the person is stationary in every frame, and this will cause the loss of significant information in video analysis. »⁶⁸ : un CNN 2D comme resnet analyse chaque plan de manière indépendante et ignore la logique temporelle de la vidéo. 2SDS résout ce problème en regroupant les plans similaires avant de les classifier. (à relier avec la notion de shot boundary detection). « We need to devise an implementation that complements the CNN model to solve the continuity issue. This implementation should group the discrete frames (adjacent on the temporal axis) that look similar to each other into scenes, this procedure is what we call temporal segmentation. »⁶⁹ : la segmentation temporelle : regrouper les plans qui se suivent et visuellement similaires : c'est ce que fait pyscene detect avec le content detector. l'article explique aussi la mise en place d'un pipeline de détection de changement de plan : 4 étapes :

down sampling : miniaturisation du plan pour détecter les changements globaux, pas locaux

conversion de l'image RGB en niveaux de gris

calcul d'une valeur de "hachage" de l'image : Chaque ligne de 9 pixels est convertie en 8 bits binaires comparant les pixels adjacents. Produit une « empreinte » numérique de la frame.

distance de hamming : comparaison des empreinte de deux frames consécutives. Si la distance est supérieure à 5, les deux plans appartiennent à des scènes différentes. le seuil est paramétrable. pyscenedetect est l'implémentation concrète de ce processus.

les auteurs conseillent de ne pas utiliser des réseaux de neurones pour la segmentation vidéo : « The usage of RNN or even neural networks is not practical in time

⁶⁷Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

⁶⁸*Ibid.*

⁶⁹*Ibid.*

sensitive tasks like real-time object recognition and live video stream analysis, which requires fast responding algorithms, and RNNs usually cannot meet those requirements. »⁷⁰

détecter les coupures entre es scènes est une analyse syntaxique et non sémantique : il suffit de détecter la différence visuelle. les meilleurs résultats de détection de coupures se font sur des plans fixes, avec des sujets distants, des mouvements lents, donc plutôt bien adaptées aux archives audiovisuelles.

l'article de XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV] ne cherche pas à comprendre les scènes mais seulement à analyser leur syntaxe pour en détecter les coupures. 2SDS règle le problème de délimitation en séquence, mais ne décrit pas la vidéo comme d'autres outils peuvent le faire : CLIP, YOLO, BLIP. De plus, le corpus de tests est réduit (6 vidéos issues de youtube), et en couleur.

10. Limites et critiques

- Limites contextuelles

« How to give context to the machines? To give common sense? It's a problem of artificial intelligence from the beginning. »⁷¹

- limites de l'automatisation :

”l'intégration de la vision artificielle aux méthodes des historiens n'existe que conjointement à des interventions humaines, qui assurent la pertinence des traitements effectués et apportent une analyse nécessaire.”⁷²

- sur l'indexation automatique audio : « Audio archives present a complex terrain for contemporary speech processing technologies, owing to the varied domains these recordings encapsulate. »⁷³ : deux problèmes sur un corpus d'archives anciennes : variabilité linguistiques (multilingues, accents différents), variabilité temporelle (vieillesse des voix). les archives audiovisuelles sont un matériau hétérogène : opacité du médium.
- sur l'indexation automatique des archives audiovisuelles

⁷⁰ *Ibid.*

⁷¹ *AI in Audiovisual Archives / Sound & Vision...*

⁷² J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁷³ P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

IL est important pour les archivistes de savoir comment ont été entraînés les modèles qu'ils utilisent, sur quelles données.

la vidéo : souvent de moins bonne qualité que l'image fixe, donc les résultats d'indexation automatique peuvent être moins bons

contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ».⁷⁴

Lacunes

l'article de attard souligne que « The study underscores the lack of specialised annotation tools and the high resource demands of sophisticated models, which could present significant obstacles for future research with limited computational resources. »⁷⁵ c'est une limite surtout pour les institutions. Rejoint l'argument et les limites exposées par⁷⁶

Les modèles multimodaux qui combinent audio et vidéo (vivit-ast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d'usage et qui séparent les pipelines.⁷⁷

Absence d'outils d'annotation spécialisés dans la segmentation vidéo. Attard adapte label studio, un outil généraliste.⁷⁸

Limites des transformers : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset to train. »⁷⁹. : les transformers n'ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu'il soit dans l'image. Ils ont donc besoin d'être entraînés sur beaucoup plus de données : c'est une grande limite. Une approche par classifieurs d'images plus légers comme ResNet peut donc être préférable. ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d'archives historique sauf pré entraînement massif.

⁷⁴B. Bachimont, *Indexation et archivage de contenus multimédias...*

⁷⁵J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

⁷⁶P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

⁷⁷J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

⁷⁸*Ibid.*

⁷⁹A. Arnab, M. Dehghani, G. Heigold, *et al.*, *ViViT...*

- éthique de l'IA

Sur l'éthique de l'expérience utilisateur : Principles for Accountable Algorithms : responsibility, explainability, accuracy, auditability, fairness⁸⁰

Limites du machine learning : "Une répartition arbitraire des systèmes est toutefois limitée dans la mesure où, d'une part, les systèmes entraînés ont souvent un domaine d'application spécifique et, d'autre part, leurs capacités sont fortement liées aux jeux de données utilisés. Les algorithmes entraînés avec différents jeux de données produisent des résultats différents."⁸¹

- Biais de la computer vision appliquée aux images :

"For instance, racial bias has been an ongoing challenge with computer vision tools, particularly with facial recognition software. A study published by MIT Media Lab in 2018 found that facial recognition software had an average error rate of 0.8 percent for light-skinned men, versus a 34.7 percent error rate for darker-skinned women"⁸² "societal biases are often engrained in AI model training datasets, which lead to the models reproducing those biases in their outputs"⁸³ "In addition to this, the training data of computer vision models has relied mostly on visual content available to be harvested from the Internet, which in its majority corresponds to content developed during the last three decades. These models would underperform on images that are of a more historical character, commonly found in visual archives, since they are underrepresented in the training data"⁸⁴

Limite liée à la qualité des images : la qualité des images est absolument primordiale et déterminante dans la mise en place d'un pipeline d'indexation automatique : "La question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle".⁸⁵ Important dans le cadre d'une indexation d'archives audiovisuelles, qui sont souvent de moins bonne qualité que les images car les fichiers sont plus lourds.

⁸⁰ *Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).

⁸¹ J. Arnold, M. Lüpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

⁸² K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

⁸³ *Ibid.*

⁸⁴ *Ibid.*

⁸⁵ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

11. Archives audiovisuelles

- Spécificités

”When you start looking at moving images and doing ML on them, your object of study is no longer an entire film but shots or scenes or still images. And that suddenly brings in important questions for archives and libraries. When the record itself changes...that raises huge questions that folks are not grappling with. Not just enriching a particular object but changing the object”.⁸⁶

Difficultés de ce type de contenu : ”moving image data, which is a particularly difficult data type to atomize.”⁸⁷

- Indexer les archives audiovisuelles

La spécificité du langage cinématographique comme obstacle à l’indexation
archives muettes et anciennes

Contrairement aux documents textuels qui comportent souvent des éléments d’indexation dans leur forme (couverture de livre,) les archives audiovisuelles n’en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d’indexation. Il s’agit alors de mettre en place une « indexation par le contenu ». ⁸⁸ (aussi placé dans IAcinema)

Premier outil d’indexation des images : Perzeptron de Franz Rozenblatt en 1957 : machine de reconnaissance d’images.

Pour l’indexation des archives audiovisuelles : apprentissage supervisé, non supervisé ou en profondeur : sont appliqués ou combinés.

”Dans le cas des archives audiovisuelles, on voit en outre très clairement comment les besoins des utilisateur · rice · s sont pris en compte lors de la conception de l’indexation automatique en profondeur et comment les données et les traces des utilisateur · rice · s sont utilisées pour optimiser l’accès aux archives audiovisuelles (mot-clé : système de recommandation).”⁸⁹

”L’indexation, la recherche et le filtrage basés sur le texte de contenus audiovisuels pertinents se heurtent par nature à des limites : Les contenus audiovisuels doivent

⁸⁶R. Cordell, « Machine Learning + Libraries »...

⁸⁷*Ibid.*

⁸⁸B. Bachimont, *Indexation et archivage de contenus multimédias...*

⁸⁹J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives »...

également pouvoir être recherchés à l’aide de méthodes audiovisuelles (par exemple la navigation par images, Query by Example).⁹⁰

”L’identification de contenus simples d’images ou de sons basée sur des descripteurs techniques ou des attributs dérivés a tendance à être de plus en plus laissée à la machine apprenante (par exemple « photo de groupe », « personne avec un casque sur la tête », termes parlés), tandis que l’identification plus poussée de personnes, de corps, de lieux, d’événements ou de sujets concrets est encore très sujette à erreurs.”⁹¹

Définition du NLP

Le NLP et la recherche sémantique (Tannier, Wang, ressources ISO/Oracle)

« NLP is the area of AI and linguistics concerned with training machines to decipher meaning in human language. » « NLP tools such as Entity Extraction are especially valuable in archival settings because they can help link descriptive data to controlled vocabularies. »⁹²

limites

« Technologies were primarily trained on white men with regional speaking styles dominant on TV, and didn’t work well on speech and accents of people of other cultures or regions. »⁹³

12. Experience utilisateur

- Côté expérience utilisateur

Il faut partir de l’expérience utilisateur : quelles sont les attentes, quelles sont les difficultés métier ? est ce qu’une automatisation des tâches est attendue ? cf démo avec Yves Klein qui ont demandé de ne pas avoir les nouvelles fonctionnalités IA dans leur espace de travail. Crainte de fuite de données aussi. ”the real problems are professional problems – the idea is that the IT people have to be aware of the real problems, the real things to do ; if they don’t introduce themselves in the archives they won’t be aware of what to do.”⁹⁴

Indexation automatique et expérience utilisateur : une question de transparence : ”Alors que l’utilisation du ML va déjà de soi dans certains domaines, il y a des domaines dans

⁹⁰ *Ibid.*

⁹¹ *Ibid.*

⁹² *AI in Audiovisual Archives / Sound & Vision...*

⁹³ *Ibid.*

⁹⁴ *Bringing AI into the Audiovisual Archive / Sound & Vision...*

lesquels nous devons rendre son utilisation transparente pour les utilisateur · rice · s et leur donner la possibilité d'option de retrait, par exemple lorsqu'il s'agit de données personnelles. La transparence est également requise lorsqu'il s'agit d'adapter l'offre concrète aux besoins des utilisateur · rice · s sur la base de profils d'utilisateur · rice · s (obtenus par le biais de demandes, d'autodéclaration ou de « traces d'utilisation », comme le classement d'une liste de résultats ou des propositions par des systèmes de recommandation).⁹⁵

- besoin utilisateur comment répondre à un réel besoin utilisateur et pas seulement à une logique produit ?

13. Limites et critiques

- Limites contextuelles

« How to give context to the machines? To give common sense? It's a problem of artificial intelligence from the beginning. »⁹⁶

- limites de l'automatisation :

”l'intégration de la vision artificielle aux méthodes des historiens n'existe que conjointement à des interventions humaines, qui assurent la pertinence des traitements effectués et apportent une analyse nécessaire.”⁹⁷

- sur l'indexation automatique audio : « Audio archives present a complex terrain for contemporary speech processing technologies, owing to the varied domains these recordings encapsulate. »⁹⁸ : deux problèmes sur un corpus d'archives anciennes : variabilité linguistiques (multilingues, accents différents), variabilité temporelle (vieillesse des voix). les archives audiovisuelles sont un matériau hétérogène : opacité du médium.
- sur l'indexation automatique des archives audiovisuelles

IL est important pour les archivistes de savoir comment ont été entraînés les modèles qu'ils utilisent, sur quelles données.

la vidéo : souvent de moins bonne qualité que l'image fixe, donc les résultats d'indexation automatique peuvent être moins bons

⁹⁵Id., « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

⁹⁶*AI in Audiovisual Archives / Sound & Vision...*

⁹⁷J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁹⁸P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ».⁹⁹

Lacunes

l'article de attard souligne que « The study underscores the lack of specialised annotation tools and the high resource demands of sophisticated models, which could present significant obstacles for future research with limited computational resources. »¹⁰⁰ c'est une limite surtout pour les institutions. Rejoint l'argument et les limites exposées par¹⁰¹

Les modèles multimodaux qui combinent audio et vidéo (vivit-ast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d'usage et qui séparent les pipelines.¹⁰²

Absence d'outils d'annotation spécialisés dans la segmentation vidéo. Attard adapte label studio, un outil généraliste.¹⁰³

Limites des transformers : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset to train. »¹⁰⁴ : les transformers n'ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu'il soit dans l'image. Ils ont donc besoin d'être entraînés sur beaucoup plus de données : c'est une grande limite. Une approche par classifieurs d'images plus légers comme ResNet peut donc être préférable. ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d'archives historique sauf pré entraînement massif.

- éthique de l'IA

Sur l'éthique de l'expérience utilisateur : Principles for Accountable Algorithms : responsibility, explainability, accuracy, auditability, fairness¹⁰⁵

⁹⁹B. Bachimont, *Indexation et archivage de contenus multimédias...*

¹⁰⁰J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁰¹P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

¹⁰²J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁰³*Ibid.*

¹⁰⁴A. Arnab, M. Dehghani, G. Heigold, *et al.*, *ViViT...*

¹⁰⁵*Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML...*

Limites du machine learning : "Une répartition arbitraire des systèmes est toutefois limitée dans la mesure où, d'une part, les systèmes entraînés ont souvent un domaine d'application spécifique et, d'autre part, leurs capacités sont fortement liées aux jeux de données utilisés. Les algorithmes entraînés avec différents jeux de données produisent des résultats différents."¹⁰⁶

- Biais de la computer vision appliquée aux images :

"For instance, racial bias has been an ongoing challenge with computer vision tools, particularly with facial recognition software. A study published by MIT Media Lab in 2018 found that facial recognition software had an average error rate of 0.8 percent for light-skinned men, versus a 34.7 percent error rate for darker-skinned women"¹⁰⁷ "societal biases are often engrained in AI model training datasets, which lead to the models reproducing those biases in their outputs"¹⁰⁸ "In addition to this, the training data of computer vision models has relied mostly on visual content available to be harvested from the Internet, which in its majority corresponds to content developed during the last three decades. These models would underperform on images that are of a more historical character, commonly found in visual archives, since they are underrepresented in the training data"¹⁰⁹

Limite liée à la qualité des images : la qualité des images est absolument primordiale et déterminante dans la mise en place d'un pipeline d'indexation automatique : "La question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle".¹¹⁰ Important dans le cadre d'une indexation d'archives audiovisuelles, qui sont souvent de moins bonne qualité que les images car les fichiers sont plus lourds.

¹⁰⁶J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁰⁷K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

¹⁰⁸*Ibid.*

¹⁰⁹*Ibid.*

¹¹⁰J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visité le 12/05/2026).
- ARNAB (Anurag), DEGHANI (Mostafa), HEIGOLD (Georg), SUN (Chen), LUČIĆ (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4–2 (juill. 2019), DOI : 10.22148/16.043.
- ASPERTI (Andrea), DESSÌ (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BASSAÏSTEGUY (Sidonie), *Le Médium, c'est La Mémoire : Archivages Du Document à l'Institut National de l'audiovisuel*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visité le 13/05/2026).

- BERGMANN (Cole Stryker Dave), *Qu'est-ce qu'un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BERMÈS (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l'IA 2025 », dans *Conférence Nationale Sur Les Applications de l'Intelligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- CARON (Mathilde), BOJANOWSKI (Piotr), JOULIN (Armand) et DOUZE (Matthijs), « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What's the Difference ?* / IBM, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).
- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAT/IFTA Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (), oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- INDEXATION : Définition de INDEXATION*, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).

- LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).
- Les secrets du traitement du langage naturel décryptés*, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).
- LIN (Xinyu), ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].
- LIU (Haotian), LI (Chunyu), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].
- LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Manan), HAMDY (Mohammed), *et al.*, *Bridging the Data Provenance Gap Across Text, Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].
- MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].
- MOIRAGHI (Eleonora), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs.CV].
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, p. 152, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 08/06/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).

- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).
- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).
- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).
- Qu'est-ce qu'un réseau de neurones convolutifs ?* / IBM, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).
- Qu'est-ce que la conception de chatbot ?* / IBM, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).
- ROBERT (Jérémy), *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).
- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- SULLIVAN (Peter) et ABDUL-MAGEED (Muhammad), *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605.

- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).
- Traitement du langage naturel : découvrez comment les machines lisent et écrivent*, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).
- VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*-hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].
- YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- YOON (Sangwoong), KANG (Woo Young), JEON (Sungwook), LEE (SeongEun), HAN (Changjin), PARK (Jonghun) et KIM (Eun-Sol), *Image-to-Image Retrieval by Learning Similarity between Scene Graphs*, déc. 2020, DOI : 10.48550/arXiv.2012.14700, arXiv : 2012.14700 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

Mon introduction

Première partie

Une partie

Chapitre 1

Mon premier chapitre

Deuxième partie

Une autre partie

Conclusion

Annexe A

Le titre très long de la première
annexe

Table des matières

Résumé	i
Brouillon	iii
1. Problématique	iii
2. Indexation automatique	vi
3. indexation iconographique	viii
4. indexation audio	ix
5. notions IA	x
6. machine learning	x
7. computer vision	xiii
8. IA appliquée à la vidéo	xiv
9. segmentation	xvii
10. Limites et critiques	xx
11. Archives audiovisuelles	xxiii
12. Experience utilisateur	xxiv
13. Limites et critiques	xxv
Remerciements	xxix
Introduction	xxxix
I Une partie	1
1 Mon premier chapitre	3
II Une autre partie	5
Conclusion	7

A Titre court	9
----------------------	----------