

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Brouillon

1. Contexte skinsoft

- L'entreprise

Skinsoft propose des solutions logicielles full web principalement à destination d'institutions patrimoniales.

L'application générale est divisée en espaces de travail, spécifiques au contexte institutionnel dans lequel elle est implémentée. Par exemple, un musée aura un module S-museum, un musée d'histoire naturelle aura un module Skin Specimen, une cinémathèque aura un module S-movies. Ces espaces de travail sont eux même configurables et adaptables en fonction des pratiques métiers de l'institution. Skinsoft peut ainsi paramétrer l'utilisation de certains champs, de certains types de notices sur demande de l'utilisateur. En amont de la livraison de l'application chez un client, un mapping est effectué entre les champs d'indexation et de catalogage utilisés par le client dans une ancienne base de données, et les champs que propose skinsoft dans son application. Même si les champs sont configurables, une adaptation et une mise à niveau doit s'effectuer. C'est d'ailleurs le point le plus complexe à gérer en termes de relations clients. Le client doit en effet accepter d'abandonner certaines pratiques pour pouvoir adopter un nouveau logiciel. Ce processus est fastidieux et demande de nombreuses formations pour accompagner les équipes métiers.

En un mot, l'idée de l'application proposée par skinsoft est celle de la configurabilité et de l'adaptabilité. C'est ce mot d'ordre qui pousse l'entreprise à repenser son logiciel à chaque nouveau contrat, pour être le plus proche possible des pratiques métiers de chaque institution et des différentes attentes.

- mise en place de l'IA

Avec l'arrivée de l'IA dans le monde du travail et sa remise en question de la place humaine dans certaines pratiques professionnelles qui seraient automatisables, une entreprise dédiée à l'amélioration des pratiques métier en contexte patrimonial et culturel

comme skinsoft souhaite l'implémenter.

Cette volonté d'implémenter l'IA 'inscrit dans l'appel à projets "France 2030" qui couvre notamment la maîtrise des technologies numériques et le "déploiement de l'innovation".¹. Cette initiative finance des initiatives à l'intersection de la culture, du numérique et de l'IA.

À quels besoins concrets chez les clients skinsoft l'IA répond-elle ? aussi, on parle d'IA mais qu'est ce que ça implique comme notions et outils concrètement ? (voir IAgenerale.tex)

- améliorer l'expérience client dans l'application - améliorer l'efficacité de l'application
- augmenter l'efficacité des pratiques métier - donner accès plus rapidement et à un plus grand nombre d'archives - promouvoir une meilleur organisation interne

En effet, la question du besoin est centrale, pour une utilisation de l'IA éthique, comme le mentionne le ministère de la culture : " il ne s'agit pas d'utiliser l'IA par défaut, mais d'abord d'examiner le besoin à couvrir et de vérifier la capacité des systèmes d'IA à satisfaire ce besoin dans des conditions optimales ; le cas échéant, de favoriser des alternatives moins consommatrices que l'IA si elles sont suffisantes à répondre au besoin".²

L'objectif est double pour une entreprise comme skinsoft : La mise ne place de l'IA dans l'application permettrait d'autonomiser les institutions sur leur usage du logiciel et d'être plus productifs dans l'indexation de leurs collections. Ainsi, les équipes skinsoft seraient moins sollicitées pour des problèmes liés à l'usage de l'application qui pourraient être réglés par un modèle de langage. La mise en place d'une barre de recherche fondée sur le langage naturel découle de ces objectifs, ainsi que la mise en place d'un chatbot, deux idées déjà amorcées et au coeur des discussions chez Skinsoft.

Mais d'autres besoins métier sont susceptibles d'être assistés par IA, au delà de la recherche et de questionnements d'usage. En effet, skinsoft souhaiterait mettre en place une automatisation de l'indexation, permettant ainsi d'une part d'alléger la charge de travail des équipes au sein d'une institution patrimoniale, et d'autre part, de donner accès à davantage de documents pour le grand public.

¹France 2030 : un plan d'investissement pour la France / *economie.gouv.fr*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).

²La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).

Faire le lien avec l'indexation des archives audiovisuelles : pas les mêmes défis d'indexation pour une collection audiovisuelles : lié à la spécificité de ces documents "boîtes noires"

- la tension privé public Si skinsoft est une entreprise privée, elle adopte en revanche une posture publique culturelle, celle de ses clients, afin de répondre à leurs besoins. La mise en place de l'IA est pensée pour améliorer les logiques patrimoniales quotidiennes telles que l'indexation, le catalogage, le classement, la gestion de projet... Ces pratiques ne sont pas liées à des objectifs de rentabilité et de productivité concurrentiels comme c'est le cas d'entreprises privées. Ainsi, skinsoft fait face à une tension : l'entreprise s'affiche comme une entreprise innovante en matière de technologies numériques, alors même que ses clients sont cantonnés à des pratiques presque ancestrales, celle de la gestion de collections.

Au sein de la mise en place et de l'arrivée de l'IA dans un logiciel de gestion des collections, il faut ainsi se questionner sur sa pertinence. Ces nouvelles fonctionnalités sont-elles attendues ? Les institutions sont-elles prêtes à utiliser l'IA au quotidien pour gérer leur collection ? pour les décrire ? pour les rendre accessible au public ?

En 2025, le ministère de la culture identifie "l'enrichissement de la connaissances et des savoirs" comme un usage potentiel de l'IA en secteur culturel avec par exemple "de l'aide au catalogage, à l'indexation automatique des collections, au tri et au classement des documents et données destinés à être archivés, à la transcription des textes manuscrits, à la reconnaissance de formes, à la diffusion et à la valorisation des contenus culturels et patrimoniaux quel que soit leur format (image, son...)".³

Les limites de l'IA identifiées, à savoir l'hallucination, la marge d'erreur, les biais culturels, sont ici restreintes puisque les outils d'IA seraient mis à disposition par skinsoft à des professionnels, et non au grand public directement. Certes, ces outils IA permettront à terme, comme l'indexation automatique, de rendre les collections accessibles au public, mais seulement après vérification d'un professionnel attitré.

Les professionnels pourraient mettre à profit l'IA pour un double objectif : la préservation et l'accessibilité des collections.⁴. C'est exactement le cas pour l'indexation automatique.

- S-movies

³ *Ibid.*

⁴ *L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et*, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).

les collections de film : un défi documentaire WEMI opacité de la hiérarchisation des niveaux refonte de la manière d’indexer dans l’application pour les collections de films : un des enjeux actuels : améliorer l’expérience utilisateur.

2. S-Movies

Skinsoft propose la gestion de collections cinématographiques, avec un espace de travail dédié, S-Movies. C’est au sein de cet espace que skinsoft souhaite mettre en place l’indexation automatique des items.

Cet espace de travail repose sur la description des collections en différents niveaux du FRBR recommandés par la Fédération Internationale des Archives du Film. En effet la FIAF recommande quatre niveaux de description hiérarchique pour le catalogage des films : l’oeuvre/expression, qui correspond à l’idée de l’oeuvre originale, la variante, qui est une version différente de l’oeuvre originale, la manifestation, qui correspond à la diffusion de l’oeuvre, sa sortie, l’item, qui correspond à l’exemplaire physique ou numérique de l’oeuvre. Une oeuvre peut avoir plusieurs diffusion, et ainsi être liée à plusieurs manifestations. De plus, la collection peut compter plusieurs exemplaires physiques ou numériques d’une seule oeuvre.

3. Problématique

- Sur la compréhension du cinéma par l’IA :

Ce qui est encore en cours de développement pour les outils actuellement = compréhension du langage cinématographique (montage, narration), analyse des ambiances et émotions, détection d’œuvres musicales.

Incapacité des machines à comprendre le langage ciné pour l’instant et à l’analyser correctement : pourquoi ?

Il n’existe pas de solution tout en un

L’image animée regroupe bcp de choses.

- Interface et l’expérience utilisateur :

Comment combiner performance technique et expérience utilisateur au sein de l’application avec l’implémentation de l’IA ?

Implémentation de deux outils de recherche assistée dans l’application : comment guider l’utilisateur vers l’outil qu’il cherche ?

Faire une interface utilisateur qui augmente la productivité et l'interactivité mais en même temps qui reste adaptée aux institutions culturelles qui n'ont pas forcément d'objectifs de rendement et de productivité comme des entreprises privées. Trouver la limite. Ne pas en faire une appli de marketing.

Tensions entre besoins utilisateurs musée / et une logique de productivité d'entreprise privée vers laquelle se tourne de plus en plus l'application : tableau de bord, intelligence artificielle.

Améliorer l'interface et l'expérience utilisateur est ce qui fait prospérer skinsoft et ce qui la démarque de ses concurrents.

- Migration de données :

Décalage entre ce que le client veut pour ses données, et ce que skin soft est capable de faire. Un changement de logiciel induit forcément une modification de la saisie des données, même si l'application est entièrement paramétrable. Décalage entre ce que l'institution attend et ce que skinsoft peut faire conformément aux standards documentaires, au temps qu'ils peuvent y consacrer et aux limites de l'application et de l'interface.

Difficulté de paramétrer l'application en fonction de la manière de saisir les données propres à chaque institution, des thésaurus utilisés...

L'application et les paramétrages évoluent presque à chaque nouveau client et devient plus malléable.

- Sur l'indexation :

La génération de résumé sur une archive audiovisuelle prévue par skin soft se fait de quelle façon, à partir de quelles données ?

Résumé à partir de notices déjà constituées sur l'archives en question

Extraction des éléments dans l'image : autorités

Extraction d'éléments dans le son

Comment le NLP transforme les pratiques d'indexation ? Lien entre les deux ?

Pour l'instant, il existe des modèles qui permettent de détecter la séparation entre les plans grâce au changement de position des personnages, changement de lumières... Mais la détection du changement de séquences se situe à un niveau supplémentaire de compréhension du langage cinématographique. Cela suppose de comprendre ce qu'est une séquence (combinaison d'un changement temporel et spatial). Comment améliorer les

modèles qui détecte les changements de plans pour leur faire comprendre les changements de séquences ? Surtout sur des archives audiovisuelles où il se passe peu de choses dans l'image. La plupart des cas d'usages vus et lus sont entraînés sur des séquences de télévision par exemple, un langage "classique et normé qui est toujours le même. Pour les archives très anciennes comme celles d'Albert Kahn, il n'y a pas de coupures ou très peu, les plans sont fixes, les sujets sont généralement loins de la caméra. est ce que c'est plus facile à entraîner ? comment entraîner un modèle qui puisse analyser des vidéos à la fois très similaires et très différentes en termes de langage cinématographique ?

les archives audiovisuelles nécessitent une indexation de contenu : extraction d'information à partir de ce qui se trouve dans l'image

pour les archives papier, l'indexation automatique des archives nées numériques et les archives numérisées est différente. Pour les archives nées numériques, il existe déjà un produit numérique : pdf par exemple ou document texte. Pour une archive numérisée, il faut produire ce dérivé pour y appliquer de la reconnaissance d'entités, de caractères... Est-ce la même chose pour les archives audiovisuelles ? Ou ça ne change rien ?

permettre l'annotation vidéo : pour qui ? quand ? comment ?

L'un des problèmes sur la mise en place de l'IA dans les institutions patrimoniales est un manque de moyens financiers et de savoir faire technique. Les institutions sont souvent limitées à choisir des outils déjà entraînés et constitués à partir de données souvent différentes et éloignées des archives historiques complexes et hétérogènes (whisper, MMS...). Cela donne une indexation imprécise, risquée et pas forcément performante. Skinsoft est une entreprise innovante au service de ces institutions, cela peut être son rôle de proposer aux musées des outils entraînés à partir de données historiques et donc plus performants pour des collections patrimoniales. ou alors récupérer des modèles et les réentraîner.

Définition de l'indexation documentaire

- **Indexation documentaire (Sumonin, Husson, Reignier)**

définition de l'indexation : "Le fait de dresser un répertoire ou une liste, généralement alphabétique, des sujets traités, des noms cités dans un ouvrage, suivis des références aux pages, aux paragraphes" (Rolland-Coul. 1969).⁵

autre définition : Selon l'AFNOR, l'indexation est la "représentation par les éléments

⁵INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).

d'un langage documentaire ou naturel, des notions résultant de l'analyse du contenu d'un document en vue d'en faciliter la recherche"⁶

définition de l'indexation : "L'indexation est cette technique consistant à caractériser le contenu d'un document et l'information qu'il détient de manière à le retrouver quand on effectue des recherches sur l'un des sujets dont il traite. La difficulté est donc de savoir caractériser et représenter l'information documentaire pour qu'il soit aisé de la mettre en rapport avec des sujets d'investigation. Mise en rapport d'une requête et d'un contenu représenté et synthétisé, l'indexation permet de s'orienter dans la masse des documents et d'organiser ses connaissances. L'indexation appartient donc à ce qu'on appelle depuis quelques années les techniques intellectuelles Indexation et archivage de contenus multimédias"⁷

Contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ».⁸ (aussi placé dans IAcinema)

- Archives audiovisuelles (Bassaïsteguy (INA), Rattinger, Le Ber, Attard)
- IA et vision par ordinateur (Arnab (ViViT), Gong (AST), Trojahn, Yuan)

4. analyse automatique de l'image

Objet de cette sous partie : Avant de pouvoir indexer, il faut pouvoir produire une analyse automatique de l'image animée.

5. Indexation automatique

- Pourquoi automatiser l'indexation ?

Pour justifier l'indexation automatique : « Les bibliothèques gèrent un grand nombre de métadonnées, pour différents types de documents. Le plus souvent, ces documents sont

⁶Pierre Husson, « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RETIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).

⁷Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

⁸*Ibid.*

indexés à l'aide de mots sujets sélectionnés au sein d'un vocabulaire contrôlé, afin d'être recherchés plus tard. L'indexation manuelle de documents est un travail intellectuel très consommateur de temps. »⁹

« Incomplete descriptive metadata often hinder their access by the public.¹⁰ Légitime la mise en place d'une indexation automatique car elle servirait à compléter des métadonnées manquantes et donc à rendre accès les collections plus facilement au public. Le manque de métadonnées et d'informations, d'indexation est souvent un frein lors de la publication en ligne, de l'accès au public (car pas de contexte : risque de contradictions historiques).

« Les systèmes d'indexation automatique suivent généralement un processus dans lequel les documents textuels sont, dans un premier temps, "préparés" [...] les documents sont convertis dans une représentation vectorielle de leur fréquence d'apparition, ce qui, à l'aide d'un algorithme, permet d'établir des comparaisons entre les mots-sujets utilisés. »¹¹ Pour les images : comparaison des objets. La différence de médium modifie les outils utilisés et la manière de les utiliser pour en tirer des infos.

« Les algorithmes d'indexation automatique se répartissent selon deux types d'approche : lexicale et associative. »¹²

Pour les archives audiovisuelles, des processus techniques s'ajoutent : extraction d'entités depuis l'image, extraction d'entités depuis le son. La forme du médium cinématographique crée une opacité et une complexité pour l'instauration de pipeline algorithmiques.

• Pipeline

Mise en place d'une pipeline IA : Ce sont plusieurs outils combinés qui créent l'indexation : analyse audio avec l'ASR et la segmentation, analyse de l'image avec la computer vision et shot detection, le NLP avec le NER et term extraction. Cette pipeline permet d'extraire des métadonnées en lien avec des vocabulaires contrôlés et ainsi d'indexer les images. « Each tool specializes in a single task, and is brought together with other tools in pipelines. Technologies can be layered upon one another in order to more meaningfully annotate content. »¹³

⁹Osmo Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605, p. 21.

¹⁰Peter Sullivan et Muhammad Abdul-Mageed, *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].

¹¹O. Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », ..., p. 21.

¹²*Ibid.*

¹³*AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).

Implémentation d'une combinaison d'outils différents pour l'indexation : "La combinaison de différents outils et leur intégration dans des environnements logiciels existants est un sujet important, pour lequel il existe désormais un large éventail de solutions, souvent open source"¹⁴

- Outils

Trint : automatic speech recognition
FasterR CNN et Farec CNN : face detection models
YOLO : outil opensource de détection d'objets et d'identification

- Cas d'indexation

The vanderbilt university television news archive : ils utilisent Trint pour transcrire les discours et engagent des étudiants pour corriger les transcriptions sur l'interface de l'outil Trint :

"students also note the start and stop time of segments, and write relevant on-screen information such as names into the transcript. Each 30-minute program takes one hour of student worker time to correct. When the transcript is complete, it is exported to Amazon's Named Entity Recognition service on the cloud, where information such as person, location, or topic is pulled out. That information is then brought back into the workflow with scripts written in Python that turn the information into individual titles for each news segment. Additional information such as reporter or location are added to database fields, and duplicate records are kept in PBCore for future use when more of the information from the Named Entity Recognition system might be stored in the database."¹⁵

- Points d'attention la qualité des images est absolument primordiale et déterminante dans la mise en place d'un pipeline d'indexation automatique : "La question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle".¹⁶

¹⁴Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

¹⁵*Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).

¹⁶Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

6. indexation iconographique

- Définition « L'indexation iconographique consiste à décrire le contenu des images à l'aide de descripteurs afin de faciliter l'accès aux œuvres, sans cependant dispenser sa consultation. »¹⁷

- Outils

"When it comes to processing image-based records in archives, supervised learning models can be helpful for identification and classification, while unsupervised learning models are best suited for processing large amounts of data for creating generic descriptions, and highlighting possible connections between records."¹⁸

- cas d'usage

Computer-Aided Metadata generation for Photo Archives Initiative (CAMPI)¹⁹ production de tags sur des images et recommandation d'images similaires

détection d'objets

YOLO (you only look once) Algorithme qui utilise CNNs pour entourer des objets dans des images et les classer dans des catégories il s'agit d'un single shot object detector : il se base sur une seule analyse de l'image dans sa globalité facial recognition, scene analysis, object tracking²⁰

two shot objects detector : multiple image reviews Exemple : Mask Region-based CNN (R-CNN) algorithm. "uses deep neural networks to identify regions of interest in the photograph and build boxes around objects found throughout the image"²¹ Cette manière de faire est appelée "semantic segmentation" : "identifies semantic objects without specifying how many instances of that object are present in the image"²² Par exemple, s'il y a 5 personnes dans une image, la segmentation sémantique les identifie comme un même objet sémantique dans l'image.

Instance segmentation : "identifies all the semantic objects in an image and segments them into specific instances to accurately distinguish between each object of a similar semantic category" (c'est ce que fait Mask RCNN)²³

Line segment detection and description

¹⁷P. Husson, « Indexation iconographique et intelligence artificielle... », p. 3.

¹⁸Kaila Fewster et Richard Arias, « Teachable AI for the Archival Professions – Module 4 : » ().

¹⁹*Ibid.*

²⁰*Ibid.*

²¹*Ibid.*

²²*Ibid.*

²³*Ibid.*

”« As a typical two-dimensional (2D) low-level image feature, line segments contain more structural and geometric features about the scene than points, as shown in Fig. 1. In addition, they have the advantage of compact data expression and strong orientation constraints, and can completely support multiview geometry theory in both 2D and three-dimensional (3D) spaces, compared with edges. »²⁴ L’analyse par lignes surpasse l’analyse par pixel/points, car elle permet une analyse géométrique de l’image et une meilleur classification de lieux par exemple : décor, perspective, architectures. L’analyse par segment permet aussi de réduire la taille de calcul par rapport à une analyse de contours de l’image par exemple : un segment est relié par deux points donc prend moins de place.

« Gradient grouping-based methods [...] lack adequate semantic and global feature constraints, the region candidates are easily interrupted by noise and small occlusion. [...] Learning-based approaches tend to detect semantically meaningful line segments, such as those in indoor scenarios. In addition, similar to point features, they struggle to detect highly accurate line segments. One reason lies in that images are often downsized during training. »²⁵

Gallica.pix

26

- Indexation par le contenu sémantique ”L’indexation par le contenu sémantique, ne vise pas à rechercher des notions visuelles (aussi définies comme « bas niveau ») mais à détecter automatiquement des concepts (aussi définis comme « haut niveau ») pour la création d’un index sémantique. Cela permet l’étiquetage soit d’une image entière, soit d’une portion de l’image et ces étiquettes peuvent être ensuite incluses dans une ontologie qui permet de faire des inférences ou de désambiguïser.”²⁷ exemple le plus parlant aujourd’hui : ImageNet

Autres outils d’indexation sémantique des images : IBM Watson, réseau ResNet SSD pour la reconnaissance des visages. classification des genres d’images : CNN, modèle inception v3 (tensorflow) extraction de thèmes : Topic modeling (latent dirichlet allocation)

²⁴Xinyu Lin, Yingjie Zhou, Yipeng Liu et Ce Zhu, *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].

²⁵*Ibid.*

²⁶Eleonora Moiraghi, *Explorer des corpus d’images. L’IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.

²⁷*Ibid.*

7. indexation audio

- Indexation audio

automatic speech recognition and speech translation

Selon une expérimentation de Sullivan et Abdul-Mageed en 2025 sur des archives de l'unesco, Whisper V3 est le modèle le plus convaincant pour identifier la langue dans une piste audio (LID), avec 91,13 pourcent de précision. En revanche, MMS (massively multilingual speech) de Meta obtient une précision de seulement 11 pourcent. Cela s'explique car MMS a été entraîné sur des données trop homogènes (enregistrements de la bible).²⁸

les embedding de locuteurs (représentations vectorielles de voix) se dégradent dans deux cas : si un locuteur parle plusieurs langues différentes, ce sont plusieurs locuteurs qui sont reconnus. Si un long moment sépare deux enregistrements d'un même locuteur, il est également interprété comme deux personnes différentes. « Speaker embeddings remain a fragile component of speech processing pipelines that is prone to biases related to the channel, age, and language. »²⁹

8. notions IA

- Définition

”Par IA, on entend, dans une acception large et ouverte, la tentative de construire des machines et des systèmes capables de penser et d’agir rationnellement”³⁰ donc à terme, de pouvoir effectuer exactement les mêmes actions spécialisées que l’homme, telles que l’indexation, qui est une tâche certes répétitive, mais complexe, qui varie selon le type de corpus.

9. machine learning

- Machine learning ”Le ML est un domaine de l’IA qui regroupe les méthodes, les processus et les techniques nécessaires pour rendre une machine ou un système informatique plus « intelligent ».”³¹ c’est à cette étape que la machine apprend et est entraînée sur les techniques d’indexation à partir d’exemples humains : annotation de données.

²⁸P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

²⁹*Ibid.*

³⁰J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives »...

³¹*Ibid.*

”L’idée à la base du ML est qu’une machine peut résoudre des problèmes de la même manière que l’homme, en apprenant à partir d’« expériences » et d’exemples, sans être explicitement programmée pour la résolution spécifique du problème. Ainsi, au lieu d’implémenter un algorithme concret de résolution de problèmes dans une machine, les données sont transmises à un algorithme générique qui, par un « processus d’apprentissage », devient lui-même capable de résoudre les problèmes.”³²

Il existe différentes méthodes de machine learning : Apprentissage supervisé Apprentissage non supervisé Apprentissage profond et réseaux neuronaux artificiels (deep learning)

”La raison pour laquelle telle ou telle fonction s’impose pendant le processus d’apprentissage ne peut être reconstituée que rétrospectivement et favorise souvent des décisions curieuses de l’algorithme. L’un des principaux problèmes réside dans le fait que les systèmes ne font pas la distinction entre les corrélations et les causalités dans les ensembles de données. L’exemple d’une « recherche de vaches sur des images » illustre bien cette situation : les vaches se trouvent souvent dans des prairies ; le modèle commence alors à ajouter « prairie » (couleur, formes, modèles d’images) au concept « vache ». L’algorithme n’a donc appris qu’une corrélation sur la base d’une probabilité statistique (vache et pré), mais n’a pas compris les relations.”³³

Exemple de transcription basée sur le machine learning : Transkribus : peut aussi s’appliquer aux archives audiovisuelles.

- Deep learning

méthode dérivée du machine learning basée sur les réseaux de neurones.

”L’apprentissage profond permet d’envisager une redéfinition des méthodes des historiens et historiens de l’art, en intégrant une part d’automatisation dans le traitement des sources iconographiques, permettant ainsi d’envisager l’exploration de corpus bien plus vastes ”³⁴

”La recherche de similarité compte parmi les applications les plus directes du deep learning”, ” elle permet de classer les images en vue de leur étude en constituant des séries iconographiques aux caractéristiques visuelles similaires, selon un score de similarité calculé par l’algorithme”³⁵

Transformers

³² *Ibid.*

³³ *Ibid.*

³⁴ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

³⁵ *Ibid.*

Récemment, une transition architecturale des modèles a produit un basculement vers des modèles basés sur les transformers en vision par ordinateur, remplaçant progressivement les CNN. Cela explique pourquoi les outils actuellement disponibles comme CLIP, ViViT, AT, sont tous basés sur cette architecture.

”les vision transformers (ViT) s’avèrent souvent plus efficaces que les réseaux de neurones convolutifs (CNN) dans des domaines tels que la segmentation d’image, la détection d’objets et les tâches connexes. L’architecture de type transformer alimente également de nombreux modèles de diffusion utilisés pour la génération d’images, le Text to Speech multimodal et les modèles vision-langage (VLM).”³⁶ ”En raison de leur capacité à comprendre la manière complexe dont chaque partie d’une séquence de données influence les autres et s’y rapporte, les modèles transformers permettent également un usage multimodal.”³⁷ ”La fonctionnalité centrale des modèles transformers est leur mécanisme d’auto-attention, dont ils tirent leur incroyable capacité à détecter les relations (ou dépendances) entre les différentes parties d’une entrée. Contrairement aux architectures RNN et CNN qui l’ont précédée, l’architecture de type transformer utilise uniquement des couches d’attention et des couches de propagation standard.”³⁸ Les RNN et CNN analysent les données de façon ”sérielle”³⁹, dans un ordre donné, les empêchant ainsi de saisir les ”dépendances à longue portée”.⁴⁰ les transformers : ”Les mécanismes d’attention, quant à eux, examinent simultanément les séquences dans leur intégralité et décident de la manière et du moment où il convient de se concentrer sur certaines étapes de chaque séquence.”, ”En plus d’améliorer considérablement la capacité à comprendre les dépendances à longue portée, cette qualité des transformateurs permet également la parallélisation, qui consiste à réaliser plusieurs étapes de calcul simultanément, au lieu de les sérialiser.”⁴¹

les transformers pour l’analyse d’image : ”Les transformateurs offrent également certains avantages par rapport aux réseaux de neurones, en particulier pour les données visuelles. Intrinsèquement locaux, les CNN utilisent des convolutions pour traiter successivement les sous-ensembles de données d’entrée. Par conséquent, les CNN peinent à discerner les dépendances à longue portée, telles que les corrélations entre les mots (dans un texte) ou les pixels (dans une image) qui ne sont pas voisins. Les mécanismes d’attention n’ont

³⁶Cole Stryker Bergmann Dave, *Qu’est-ce qu’un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

³⁷*Ibid.*

³⁸*Ibid.*

³⁹*Ibid.*

⁴⁰*Ibid.*

⁴¹*Ibid.*

pas cette limitation.”⁴²

CNN : réseau de neurones convolutif Outils de classification : ”modèles de programmation puissants permettant notamment la reconnaissance d’images en attribuant automatiquement à chaque image fournie en entrée, une étiquette correspondant à sa classe d’appartenance.”⁴³ l’un des principaux cas d’usages des CNN est la ”reconnaissance d’images”. ”Dans une moindre mesure, on les utilise aussi pour l’analyse vidéo.”⁴⁴

Description du fonctionnement d’un CNN appliqué à un corpus d’images : « CNNs learn a hierarchy of filters, which are applied to an input image in order to extract meaningful information from the input. [...] CNNs tend to learn features that resemble Gabor-like edge detectors and color-opponent filters at lower layers [...]. On higher layers of the CNNs, features capture more abstract image content by integrating the lower-layer features. »⁴⁵. A relier avec ResNet : même fonctionnement.

- Supervised learning

Définition : ”Supervised learning is a machine learning approach that’s defined by its use of labeled data sets. These data sets are designed to train or “supervise” algorithms into classifying data or predicting outcomes accurately. Using labeled inputs and outputs, the model can measure its accuracy and learn over time.”⁴⁶ Ils peuvent être séparés entre deux types de problèmes : classification and regression

Nécessite l’intervention humaine : ”In supervised learning, the algorithm “learns” from the training data set by iteratively making predictions on the data and adjusting for the correct answer. While supervised learning models tend to be more accurate than unsupervised learning models, they require upfront human intervention to label the data appropriately.”⁴⁷

appliqué aux images, l’apprentissage supervisé suppose que chaque image fournie à une machine soit annotée par un humain⁴⁸

⁴² *Ibid.*

⁴³ Jérémy Robert, *Convolutional Neural Network : Tout ce qu’il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).

⁴⁴ *Ibid.*

⁴⁵ Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

⁴⁶ Julianna Delua, *Supervised vs. Unsupervised Learning : What’s the Difference ? / IBM*, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

⁴⁷ *Ibid.*

⁴⁸ Mathilde Caron, Piotr Bojanowski, Armand Joulin et Matthijs Douze, « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.

Cela suppose des heures de travail et des milliers d’annotations pour entraîner le modèle, ce que les institutions ne peuvent pas faire

- Unsupervised learning

définition : ”Unsupervised learning uses machine learning algorithms to analyze and cluster unlabeled data sets. These algorithms discover hidden patterns in data without the need for human intervention (hence, they are “unsupervised”). Unsupervised learning models are used for three main tasks : clustering, association and dimensionality reduction”.⁴⁹

”Unsupervised learning models, in contrast, work on their own to discover the inherent structure of unlabeled data. Note that they still require some human intervention for validating output variables.”⁵⁰

Un exemple de tentative de unsupervised learning est Deepcluster, une tentative d’entraîner un CNN sans annotations humaines, en générant des étiquettes automatiquement via un algorithme de clustering (k-means).⁵¹

Un modèle peut regrouper des images similaires et utiliser ces groupes comme étiquettes⁵²

Deepcluster regroupe ainsi les similarités visuelles produites par le CNN en clusters avec k-means, et entraîne le CNN à prédire ces clusters.

Deepcluster est performant même sur des images structurées différemment : « Even when trained on uncured Flickr images, DeepCluster outperforms the current state of the art by a significant margin on most tasks. This experiment validates that DeepCluster is robust to a change of image distribution. »⁵³. C’est intéressant dans l’idée d’adapter un de ces outils à des archives patrimoniales spécifiques.

Mais la limite est la suivante : « Replacing labels by raw metadata leads to biases in the visual representations with unpredictable consequences. ».⁵⁴. On donne des métadonnées brutes ou incomplètes à un CNN, donc il est possible que ce qu’il interprète soit biaisé. Un tel biais n’est pas acceptable dans un contexte archivistique.

autre limite, Deepcluster a été validé sur imageNet, qui compte 1.28 millions d’images,

⁴⁹J. Delua, *Supervised vs. Unsupervised Learning...*

⁵⁰*Ibid.*

⁵¹M. Caron, P. Bojanowski, A. Joulin, *et al.*, « Deep Clustering for Unsupervised Learning of Visual Features »...

⁵²*Ibid.*

⁵³*Ibid.*

⁵⁴*Ibid.*

et YFCC100M, 1 million d'images. Il est donc probable qu'il ne soit pas adapté à une collection réduite comme celles des institutions patrimoniales.

10. computer vision

- Définition Branche de l'IA qui permet principalement d'extraire de l'information d'images ou de vidéos. Permet aux machines de "voir", comme les humains et ainsi d'extraire des données d'éléments visuels.

Aujourd'hui, la computer vision se fait par machine learning.

"La vision par ordinateur est un domaine d'intelligence artificielle (IA) qui permet aux ordinateurs et aux systèmes d'extraire des informations pertinentes à partir d'images, de vidéos et d'autres entrées visuelles numériques, pour prendre des mesures selon ces entrées. Cette capacité à fournir des recommandations la distingue des tâches de reconnaissance d'images."⁵⁵

les composants de la vision par ordinateur ont été mis en place en partie pour l'analyse d'images et la détection d'objets dans l'image.⁵⁶

"La détection de contours (ou edge detection) est une étape fondamentale pour le traitement des images en vision artificielle : combinée à des méthodes de détection des lignes il devient envisageable d'automatiser la transformation d'images au format .tiff ou .jpeg en objets plus aisément manipulables"⁵⁷

Etapas d'entraînement d'un modèle : "prévoir un jeu de données initial, et d'évaluer les performances du modèle après ce premier entraînement. À partir de ces résultats, il devient possible d'adapter les jeux de données suivants, pour pallier aux faiblesses constatées."⁵⁸

"Pour des tâches classiques de vision artificielle, telles que la détection d'objet, des modèles pré-entraînés performants existent en libre accès, qui ne nécessitent donc pas autant de travail d'entraînement qu'un modèle créé dans son entièreté pour un projet. Des jeux de données en accès libre sont également disponibles pour l'entraînement de modèles pour la détection automatique, tels que ImageNet 16, qui bien qu'ils ne soient pas adaptés à des sources historiques, permettent d'effectuer un premier entraînement

⁵⁵ *Qu'est-ce qu'un réseau de neurones convolutifs ?* / IBM, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).

⁵⁶ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁵⁷ *Ibid.*

⁵⁸ *Ibid.*

d'un modèle sans mobiliser les moyens nécessaires à la création d'un jeu de données."⁵⁹
limites : est ce qu'il en existe tout autant pour les corpus vidéos ? à chercher

- cas d'application

Object detection :⁶⁰ single shot detector : YOLO, using CNN two stages detectors : Deux analyses de l'image. Demande plus de puissance de calcul mais est plus efficace. pour prédire, analyser et comparer la performance des différents modèles de détection d'objet, on a besoin de "standard quantitative metrics". Les plus communs "evaluation metrics" sont : INtersection over union (LOu) et average precision (AP)

YOLO : réseau de neurones qui fait des prédictions sur la détection d'objets et qui les classifie "all at once". (à placer aussi dans les cas d'usages sur les archives audiovisuelles)

Content-Based Image Retrieval : une des applications de la computer vision. Exemple de cas d'usage : Galt archives avec Archipanion⁶¹

Visual language models (VLMs) : combinaison d'algorithmes de computer vision et de LLMs pour : "create visual outputs based on input text, or textual outputs based on images or video" / "VLMs are able to do a variety of vision language tasks like captioning and summarization, image generation, search and retrieval, and object detection and segmentation" "However, there are still challenges with these emerging models like biases, hallucinations, and overgeneralizations as well as concerns of cost and environmental impact considering that VLMs combine two already complex AI architectures into one even more complicated tool "⁶² exemple de VLM : CLIP : génère de la description en langage naturel à partir d'éléments visuels

- Esthétique computationnelle

Sous discipline de la vision par ordinateur : évaluation de l'art par une machine. terme développé par Brachmann dans son article.⁶³

"computational aesthetics is concerned with [...] "the creation and evaluation of art using computers." [...] A computational analysis can pick up very subtle relationships that may escape the attention by human observers; moreover, computational methods are objective in nature and are potentially non-exhaustive in the amount of detail analyzed. »⁶⁴

⁵⁹ *Ibid.*

⁶⁰ *YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).

⁶¹ K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

⁶² *Ibid.*

⁶³ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

⁶⁴ *Ibid.*

prédiction automatique des scores esthétiques : Rating prediction : algorithmes capables de prédire la qualité esthétique d'une image.

les modèles les plus utilisés pour faire ces prédictions sont les CNN « Deep neural networks learn features that are important for aesthetic evaluations automatically, provided that a dataset is big enough. [...] They can even take into account abstract features, such as image content, without the explicit design of such features by humans. »⁶⁵

limite des CNN pour l'analyse de l'esthétisme des images : « While hand-crafted features allow to quantify which feature contributes the most to an aesthetic rating, this interpretability is lost with generic features. [...] Deep neural networks and generic features basically represent a black-box approach that lacks this kind of interpretability. »⁶⁶

11. IA appliquée à la vidéo

- Intro "Visual object analysis researchers are increasingly experimenting with video, because it is expected that motion cues should help with detection, recognition, and other analysis tasks."⁶⁷
- audiovisual processing Audiovisuel Processing (AVP) : ensemble de technologies appliquées à l'analyse de contenus vidéos et audio (comprend computer vision et ASR automatic speech recognition)⁶⁸

constat : malgré de grandes avancées dans le processing audiovisuel, ces outils restent largement inaccessibles et ne sont pas donc pas adoptés dans le milieu des archives : « Despite the massive progress made in the performance levels and overall availability of Audiovisual Processing (AVP) technologies, such as Computer Vision (CV) and Automatic Speech Recognition (ASR), the availability of these tools for heritage institutions is still lagging behind. »

autre constat : "« Digital tools for paper resources have tended not to consider the strong presence of visual elements in them. Due to the lack of practically available AVP tools to digital humanities, scholarly research has 'grossly neglected visual content, causing a lopsided representation of all sorts of digitized archives'. » Sous représentation des éléments visuels dans l'indexation, même pour une collection audiovisuelle. Les

⁶⁵ *Ibid.*

⁶⁶ *Ibid.*

⁶⁷ Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

⁶⁸ Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

métadonnées textuelles liées aux films sont nsuffisantes pour enrichir leurs métadonnées : titre, synopsis...⁶⁹

- Cas d'usage

Reconnaissance et extraction d'objets

Exemple de projet d'extraction d'entités depuis des images en mouvement :⁷⁰ Méthode du distant viewing : reconnaissance des visages, classification des plans. Le montage et le cadrage servent à construire la place des personnages dans le récit. « One of the first tasks in understanding a video file is to break up the sequence of frames into distinct units known as shots ». « We first split an input video file into individual shots, then locate faces within every frame, identify the faces in a frame, and finally put all of the information together to cluster shots based on camera angles and distances ».⁷¹

Shot boundary detection

Shot boundary detection : détection automatique des coupures entre les plans dans une vidéo Shot semantics : description de ce qui est présent dans l'image et à quel endroit de l'image et ainsi relier l'image à des catégories de plan (shot type).

exemple de pipeline pour détecter les coupures entre les plans : "the vast majority of cuts in most film and television episodes consist of abrupt transitions between alternative camera shots. These are both easy to define and relatively easy to detect. The algorithm we use in our analysis uses a combination of histogram differences and down sampled pixel intensities. Our method functions by measuring the extent to which two successive shots are different from one another in terms of the general color palette and the distribution of brightness over the frame. If these differences fall above a specified threshold, we indicate the presence of a cut.²² We also added special logic to avoid erroneous cuts during fade-in and fade-out events."⁷²

face detection models : Faster R-CNN and FAREC-CNN⁷³

Shot classification : il est possible de classifier le type de plan à l'image en utilisant le placement des visages : "In this final step we no longer work directly with the visual materials and build a meta-algorithm that takes detected shot breaks and faces as input and outputs categorical predictions for each shot".⁷⁴ Il s'agit de définir tous les types de

⁶⁹ *Ibid.*

⁷⁰ Taylor Arnold, Lauren Tilton et Annie Berke, « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4-2 (juill. 2019), DOI : 10.22148/16.043.

⁷¹ *Ibid.*

⁷² *Ibid.*

⁷³ *Ibid.*

⁷⁴ *Ibid.*

plans et à partir de ces définitions, construire un jeu de données qui sera testé : close-up, over the shoulder...

Outils AVP

ImageJ : open source visual analysis software suite⁷⁵ Detectron2 : détection de points corporels dans l'image⁷⁶

- Limites et discussion

les AVP ne sont pas accessibles en libre accès aux chercheurs en humanité numériques. Les algorithmes ont besoin d'un accès direct aux données, or, pour des raisons de sécurité des données et des droits de propriétés intellectuelles auxquels sont soumis les archives, les données des archives ne peuvent pas quitter leur environnement numérique. donc : "A side effect of this is that for the analysis of AV material commercially available tools cannot be used, as these are primarily cloud based. To tackle this challenge it is necessary that any AVP infrastructure can be integrated with a local archival infrastructure, i.e., we need to bring the algorithms to the data, rather than the data to the algorithms"⁷⁷

au lieu de transférer les fichiers vers un service externe, l'algorithme doit être déployé localement au sein même de l'infrastructure de l'archive.

exemple de l'architecture DANE au sein du projet CLARIAH : l'architecture est divisée en plusieurs "workers" et une file d'attente. si l'un des workers s'arrête de fonctionner, les autres continuent leur tâche. Cette architecture produit deux types de données : des métadonnées structurées directement exploitables, et des vecteurs de caractéristiques (= représentations abstraites des données utilisables pour des requêtes de similarité : ouvre des possibilités de recherche par ressemblance son et vidéo.)⁷⁸

"there is a near-linear relationship between quality of transcriptions and search performance." : importance de la qualité de la transcription audiovisuelle pour améliorer la recherche.⁷⁹

"the application of AVP tools to large image datasets significantly scales up the level of analysis from 'close' to 'distant' viewing, allowing scholars to observe patterns in the data that are invisible in the traditional, interpretative analyses of small sample sets."

⁷⁵N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

⁷⁶*Ibid.*

⁷⁷*Ibid.*

⁷⁸*Ibid.*

⁷⁹*Ibid.*

le distant viewing permet de passer d'une lecture individuelle d'items à une analyse d'éléments à l'échelle d'un corpus.⁸⁰

- Diginpix : système d'identification d'entités visuelles dans les images fixes et animées
Développé par l'INA et open source pour les images animées : "L'image animée implique une problématique ultérieure par rapport à l'image fixe en raison de sa dimension temporelle. Un visualiseur spécifique a été aussi développé, dans une logique open source, pour permettre le repérage rapide des entités visuelles dans la temporalité de la vidéo."⁸¹

impact de l'indexation automatique sur les données : "Comme le repérage d'entités visuelles demande énormément d'informations locales, les bases de données d'indexation constituées à partir de la reconnaissance des entités sont conséquentes (elles peuvent avoir une taille supérieure à celle des vidéos elles-mêmes) et font l'objet de recherches au sein de l'établissement pour en optimiser les temps de calcul.

Dans ce contexte, la qualité et la modélisation des données jouent un rôle fondamental car c'est sur les bases de données que les algorithmes sont entraînés."⁸²

Diginpix repose sur : "The identification process mainly relies on an efficient CBIR system, searching in an indexed image database composed of 600,000 weak-labelled images crawled from Google Images. DigInPix proposes a responsive-design html5 interface1 for testing purposes."⁸³

fonctionnement détaillé : "The core engine makes use of local descriptors hashing techniques and a scalable indexing and search structure based on hash tables. This allows matching all local descriptors one by one in the full index and favors a more precise matching of small objects in highly cluttered pictures. Using geometry in addition to this raw scheme further improves the search performances"⁸⁴

Diginpix produit une sorte de segmentation : "When dealing with videos, keyframes are first extracted whenever the content changes significantly, i.e. new shot, moving camera, new objects appearing, etc., thanks to a keyframe detector using grid-based histograms of LBP features. The time between two keyframes typically varies from 100ms to 30s. All the detected keyframes are then processed one by one in the same

⁸⁰ *Ibid.*

⁸¹ E. Moiraghi, *Explorer des corpus d'images. L'IA au service du patrimoine...*

⁸² *Ibid.*

⁸³ Pierre Letessier, Nicolas Hervé, Alexis Joly, Hakim Nabi, Mathieu Derval et Olivier Buisson, « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.

⁸⁴ *Ibid.*

way than single images.”⁸⁵

- Amalia.js⁸⁶

12. segmentation

- Segmentation d’images

La segmentation appliquée à l’image en général, y compris l’image fixe, consiste à diviser l’image en groupes de pixels selon certains critères.

- Segmentation vidéo

Appliquée à l’image animée, la segmentation peut vouloir dire plusieurs choses différentes. En effet, l’image audiovisuelle comporte une valeur ajoutée à l’image fixe : celle de la dimension temporelle d’une succession d’images fixes créant une animation de l’image. Elle peut aussi comporter une piste audio, dans la plupart des cas, puisque le son est intégré au cinéma dès 1932. Il faut tout de même noter que toutes les images animées ne comportent pas de son (films de famille, films expérimentaux, films muets). Dans notre analyse, le son sera tout de même pris en compte dans la mise en place d’un pipeline de segmentation pour prévoir le cas fréquent d’une bande sonore.

Une fois ceci expliqué, la segmentation peut être appliquée à l’image audiovisuelle de manières différentes. Généralement, elle peut être définie comme une division d’une vidéo en plusieurs segments ou objets.⁸⁷ Plus spécifiquement, elle peut désigner la segmentation d’une séquence en différents plans, ou d’un film en différentes séquences, on parlera alors de segmentation temporelle. Elle peut aussi désigner la segmentation des objets ”dominants”⁸⁸ dans l’image selon des critères visuels.⁸⁹ Ce type de segmentation cherche seulement à analyser la place des objets dans l’image, et non leur signification.⁹⁰ On parle de segmentation sémantique lorsque survient une extraction des objets qui appartiennent à des catégories sémantiques prédéfinies.⁹¹ Ainsi la segmentation sémantique prépare l’indexation en assignant des étiquettes à chaque pixel extrait

⁸⁵ *Ibid.*

⁸⁶ N. Hervé, P. Letessier, M. Derval et H. Nabi, « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.

⁸⁷ Tianfei Zhou, Fatih Porikli, David Crandall, Luc Van Gool et Wenguan Wang, *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

⁸⁸ **zhou2022** .

⁸⁹ Jean Carrive, « Chapitre 4. Analyse automatique de l’image et du son pour l’enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.

⁹⁰ T. Zhou, F. Porikli, D. Crandall, *et al.*, *A Survey on Deep Learning Technique for Video Segmentation...*

⁹¹ *Ibid.*

de l'image. Elle est aussi applicable à l'image fixe, puisqu'elle ne prend pas en compte la dimension temporelle de l'image anme, contrairement à la segmentation temporelle. Enfin, peut être appliquée à une vidéo une segmentation de la bande sonore, qu'on désignera sous le nom de segmentation audio, par exemple entre des paroles et de la musique.⁹²

- la segmentation sémantique Concentrons nous ici sur la segmentation sémantique. Deux modèles de segmentation sémantique se distinguent. Les méthodes orientées précision, qui agrègent l'information temporelle entre les images our améliorer la prédiction. (Elles utilisent le flux optique ou des modles basés sur l'attention. Ex de méthodes : TDNET)⁹³ Les méthodes orientées vitesse, qui réutilisent les caractéristiquesdes images adjacentes pour ne pas les recalculer à chaque image. (ex : approche des keyframes : calculer les features clés sur certaines images et les appliquer aux autres. Manque de précision.⁹⁴) La segmentation sémantique reste toutefois lacunaire sur des vidéos longue durée, ou sur des vidéos dont les catégories sémantiques sont inconnues, ce qu'on appelle la segmentation "open world".⁹⁵ (les modèles actuels connaissent les catégories sémantiques à l'avance et ne peuvent pas gérer ou reconnaître des catégorie inconnues). Zhou et al coseillent également d'adapter le calcul en fonciton du contenu de l'image, pour adapter des parties du réseau au contexte de l'image pour éviter un gaspillage de calcul.⁹⁶

Adapté au contexte skinsoft, il faudrait donc produire un mapping des champs utilisés pour décrire un film, une archive audiovisuelle, ou annoter des archives avec les champs dédiés. Les corpus sur lesquels sont entraînés les modèles sont bien loin de la complexité des archives audiovisuelles.

Ex de résultats : Sur Cityscapes (VSS), la méthode EFC obtient les meilleures performances avec 83,5 pourcents d'IoUclass.⁹⁷

Segmentation guidée par le langage (LVOS)

problématiques liées à la nature de la vidéo : "C'est donc un problème de segmentation, qui est posé parce que les divisions "calculables"d'une vidéo (les plans et les segments de parole ou de musique), n'ont pas de valeur documentaire. En revanche, les divisions

⁹²J. Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels »...

⁹³T. Zhou, F. Porikli, D. Crandall, *et al.*, *A Survey on Deep Learning Technique for Video Segmentation...*

⁹⁴*Ibid.*

⁹⁵*Ibid.*

⁹⁶*Ibid.*

⁹⁷*Ibid.*

documentaires "naturelles" (sujets d'un journal, numéros d'un spectacle de variétés, scènes d'un film) ne sont pas directement calculables"⁹⁸

La segmentation d'objets vidéo se décline en trois mode : automatique, semi automatique, interactif.⁹⁹

(en quoi est ce différent d'une image fixe ? ça ne peut pas être appliqué aux images fixes ?). C'est plutôt utilisé pour le montage : retirer des objets dans l'image par ex. Ça ne concerne pas la signification des images dans l'image, seulement leur place.

- pourquoi segmenter ?

La segmentation découle d'une volonté d'indexer le contenu de l'image. En effet, selon Carrive, "La première étape du processus d'analyse des documents audiovisuels est bien souvent une étape de segmentation temporelle qui consiste à identifier dans le document des séquences possédant des caractéristiques communes ou des ruptures entre ces séquences."¹⁰⁰. Segmenter ainsi l'image permet d'indexer non plus la vidéo au complet mais des fragments, rendant son analyse plus précise. C'est également la manière dont sont analysés les films, plans par plans, ou séquences par séquence, pour en déceler le sens, à la fois une segmentation des éléments qui se trouve dans l'image, leur relations entre eux, et l'enchaînement des plans, les mouvements de caméra. L'entraînement de modèles pour l'indexation est donc calquée sur le regard humain qui permet d'analyser et d'indexer des films. Une fois la segmentation effectuée, l'objet d'analyse n'est plus le film entier mais des plans ou des séquences.¹⁰¹ La segmentation crée ainsi de nouveaux objets indexables. La segmentation est ainsi la première étape de la compréhension d'un fichier vidéo : "One of the first tasks in understanding a video file is to break up the sequence of frames into distinct units"¹⁰² Une fois le fichier vidéo segmenté, il est alors possible d'organiser le contenu, d'améliorer l'accès, et de produire des analyses sur des larges données vidéo.¹⁰³ La segmentation permettrait d'analyser de larges quantités de données, tout en homogénéisant les pratiques documentaires, en augmentant la précision et la cohérence.¹⁰⁴.

⁹⁸Ronfard, Rémi, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).

⁹⁹T. Zhou, F. Porikli, D. Crandall, *et al.*, *A Survey on Deep Learning Technique for Video Segmentation...*

¹⁰⁰J. Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels »...

¹⁰¹Ryan Cordell, « Machine Learning + Libraries » ().

¹⁰²T. Arnold, L. Tilton et A. Berke, « Visual Style in Two Network Era Sitcoms »...

¹⁰³Jonathan Attard et Dylan Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].

¹⁰⁴*Ibid.*

Qu'est-ce que ça signifie pour l'institution de passer d'un objet-film à une collection de plans ? Quelles sont les implications pour le droit, pour l'accès public, pour la description archivistique ?

la mise en place d'une automatisation de la segmentation permettrait d'homogénéiser l'indexation documentaire : un algorithme segmente les vidéos de la même façon, pas les humains. Mais les vidéos sont toutes différentes : est ce qu'on peut garder la même pratique de segmentation sur des corpus vidéo différents ?

- Segmentation sémantique ou segmentation d'images

La segmentation sémantique est une tâche de la vision par ordinateur.

"Semantic segmentation is a fundamental task in computer vision. It aims to divide the image into multiple regions according to the class of the pixel, which is important for practical applications such as autonomous driving, automatic delivery sorting, and intelligent surveillance systems"¹⁰⁵

Importance de la segmentation sémantique pour les vidéos : "videos contain not only spatial features but also temporal features. This naturally results in lower accuracy of image-based segmentation models compared with video-based segmentation models for Video Semantic Segmentation (VSS)."¹⁰⁶

- Pipelines de segmentation

Pyscenedetect Une idée de pipeline de segmentation : est la détection de scènes avec pyscenedetect (découpage d'une vidéo en segments en détectant les coupes visuelle), puis classification des segments. D'un côté la segmentation syntaxique et de l'autre la classification sémantique.¹⁰⁷

ResNet (pas de la segmentation : créer un fichier sur la classification ?) Le meilleur classifieur d'images avec le plus haut résultat de précision selon attard 2025 est ResNet¹⁰⁸

Recommandations : Les modèles multimodaux qui combinent audio et vidéo (vivitast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d'usage et qui séparent les pipelines.¹⁰⁹

¹⁰⁵Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

¹⁰⁶*Ibid.*

¹⁰⁷J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁰⁸*Ibid.*

¹⁰⁹*Ibid.*

ViViT Expérimentation avec ViViT : le modèle ViViT, modèle basé sur des transformers, capture les caractéristiques spatio temporelles de la vidéo, contrairement à Resnet qui analyse chaque image d'un vidéo indépendamment. ViViT extrait "extracts spatio-temporal tokens from the input video, which are then encoded by a series of transformer layers." ¹¹⁰. C'est un modèle qui tente d'analyser l'espace et le temps dans une vidéo donnée. ViViT adopte donc une approche "video-native". Le modèle à choisir dépend de la nature du corpus audiovisuel que l'on souhaite indexer. Si les archives sont des plans fixes qui ne changent que très peu, resnet suffit.

Conclusion sur ViViT : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset to train. » ¹¹¹. : les transformers n'ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu'il soit dans l'image. Ils ont donc besoin d'être entraînés sur beaucoup plus de données : c'est une grande limite. Une approche par classifieurs d'images plus légers comme ResNet peut donc être préférable. ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d'archives historique sauf pré entraînement massif.

2SDS

L'étude de xin2023 ¹¹² présente 2SDS, un algorithme de segmentation temporelle vidéo. Plutôt que d'utiliser un réseau de neurones pour détecter les changements de scènes, 2SDS compare des empreintes (hash) d'images successives. Si deux frames sont suffisamment différentes (distance de Hamming supérieure à un seuil), elles appartiennent à des scènes distinctes. « 2D CNNs only recognise a video as discrete images, rather than a continuous stream of images. This poses some issues. For example, a CNN model could not resolve the motion of a person because the person is stationary in every frame, and this will cause the loss of significant information in video analysis. » ¹¹³ : un CNN 2D comme resnet analyse chaque plan de manière indépendante et ignore la logique temporelle de la vidéo. 2SDS résout ce problème en regroupant les plans similaires avant de les classer. (à relier avec la notion de shot boundary detection).

¹¹⁰Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić et Cordelia Schmid, *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].

¹¹¹*Ibid.*

¹¹²Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

¹¹³*Ibid.*

« We need to devise an implementation that complements the CNN model to solve the continuity issue. This implementation should group the discrete frames (adjacent on the temporal axis) that look similar to each other into scenes, this procedure is what we call temporal segmentation. »¹¹⁴ : la segmentation temporelle : regrouper les plans qui se suivent et visuellement similaires : c'est ce que fait pyscene detect avec le content detector. l'article explique aussi la mise en place d'un pipeline de détection de changement de plan : 4 étapes :

down sampling : miniaturisation du plan pour détecter les changements globaux, pas locaux

conversion de l'image RGB en niveaux de gris

calcul d'une valeur de "hachage" de l'image : Chaque ligne de 9 pixels est convertie en 8 bits binaires comparant les pixels adjacents. Produit une « empreinte » numérique de la frame.

distance de hamming : comparaison des empreinte de deux frames consécutives. Si la distance est supérieure à 5, les deux plans appartiennent à des scènes différentes. le seuil est paramétrable. pyscenedetect est l'implémentation concrète de ce processus.

les auteurs conseillent de ne pas utiliser des réseaux de neurones pour la segmentation vidéo : « The usage of RNN or even neural networks is not practical in time sensitive tasks like real-time object recognition and live video stream analysis, which requires fast responding algorithms, and RNNs usually cannot meet those requirements. »¹¹⁵

détecter les coupures entre es scènes est une analyse syntaxique et non sémantique : il suffit de détecter la différence visuelle. les meilleurs résultats de détection de coupures se font sur des plans fixes, avec des suets distants, des mouvements lents, donc plutôt bien adaptées aux archives audiovisuelles.

l'article de XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV] ne cherche pas à comprendre les scènes mais seulement à analyser leur syntaxe pour en détecter les coupures. 2SDS règle le problème de délimitation en séquence, mais ne décrit pas la vidéo comme d'autres outils peuvent le faire : CLIP, YOLO, BLIP. De plus, le corpus de tests est réduit (6 vidéos issues de youtube), et en couleur.

video semantic segmentation (VSS) : TDNSNet

¹¹⁴ *Ibid.*

¹¹⁵ *Ibid.*

”fundamental machine vision task with various practical applications, such as autonomous driving and automated surveillance. Current studies mainly utilize temporal features based on optical flow and the self-attention mechanism to improve VSS accuracy.”¹¹⁶ Limites : ”reduced accuracy and computational overhead due to inaccurate optical flow and the computational cost of the self-attention mechanism.”¹¹⁷ L’outil temporal difference segmentation net se propose comme uen solution à ces limites selon l’article de yuan¹¹⁸

Limites identifiées par Yuan2025 des modèles de VSS existants : les modèles basés sur le flux optique (optical flow) sont dépendants de la prédiction du fluxet génèrent des erreurs, dégrandant ainsi la qualité de la segmentation (erro accumulation). Les modèles fondés sur les mécanismes d’auto attention capturent mieux les relations entre images mais leur complexité les rend difficilement applicables à des vidéos complexes elles mêmes.¹¹⁹

TDSNet : ”TDSNet employs temporal-difference-based temporal feature through the Temporal Feature Refine Module (TFRM). To further improve the accuracy of VSS, TDSNet adaptively fuses temporal features of varied motion magnitude with the Motion Magnitude Refine Module (MMRM). This module weighs and fuses temporal features of different magnitudes between frames.”¹²⁰

TDSNet est donc un modèle qui se base sur la différence temporelle : ”the temporal-difference-based features are obtained by the subtraction of the features from two consecutive frames. As a result, the model activates the dynamic regions of the feature while deactivating the static regions, allowing it to capture temporal features effectively.”¹²¹ Le modèle soustrait les features de deux images consécutives pour en faire ressortir les régions dynamiques (en mouvement) et désactive les régions statiques. Ainsi il capture uniquement l’information temporelle, pour un faible cout computationnel.

TDSNet repose sur deux modules : TFRM : temporal feature refine model : il extrait les features temporelles par différence entre l’image cible (target frame) et l’image de référence (reference frame). Il utilise ensuite l’information de mouvement retenue pour aligner et fusionner les features de la référence dans l’image cible.¹²²

MMRM : Motion magnitude refine module les features extraites par le TFRM contiennent

¹¹⁶H. Yuan, J. Peng et Z. Cai, « TDSNet... ».

¹¹⁷*Ibid.*

¹¹⁸*Ibid.*

¹¹⁹*Ibid.*

¹²⁰*Ibid.*

¹²¹*Ibid.*

¹²²*Ibid.*

des magnitudes de mouvements variés : ”we observe that motion magnitudes in the far frames are not necessarily larger than that of near frames. For example, with repetitive motion of the video, farther frames may exhibit smaller motion magnitudes.”. Le MMRM calcule donc le poids adaptatif de chaque feature temporelle selon la magnitude de mouvement réellement observée dans la vidéo en entrée, puis les fusionne.¹²³

Le modèle est entraîné sur deux jeux de données : VSPW (13 images par secondes et un écart de mean Intersection over Union de 0.7 pourcent)

CamVid

Cambridge driving : base de données vidéo étiquetée par des classes sémantiques d’objets.¹²⁴ : 2009 donc trop vieux ce qui est intéressant, c’est que en 2009, il y a moins d’algorithmes puissants et précis qui existent, donc c’est la vé

- Automatic temporal vidéo scene segmentation (ou video story segmentation)

”The automatic temporal video scene segmentation (also known as video story segmentation) is still an open problem without definite solutions in most cases.”¹²⁵ les meilleurs solutions et qui donnent les meilleurs résultats qui existent sont les techniques multimodales utilisant les caractéristiques de plusieurs outils : ”Among the available techniques, the ones which shows better results are multimodal using features extracted from multiple modalities.”¹²⁶ La fusion multimodale peut se faire de deux façon, fusion en une seule représentation, fusion par segmentation de chaque modalité : ”Multimodal fusion may be performed to fuse each modality as a single representation (early fusion) or by each modality segmentation (late fusion), the latter been widely due to multimodal fusion simplicity.”¹²⁷. C’est la seconde approche qui est privilégiée.

limites des CNN : ”CNNs cannot adequately learn cues which are temporally distributed along the video due to difficulties to model temporal features data dependencies.”¹²⁸

RNNs : ”Successfully employed on text processing, RNNs are fitted to analyze sequences of data of variable length and may better grasp the temporal relationship among low-level features of video segments, hopefully obtaining more accurate scene boundary detection.”¹²⁹. Les RNN permettent de mieux capturer les relations temporelles.

¹²³ *Ibid.*

¹²⁴ G. J. Brostow, J. Fauqueur et R. Cipolla, « Semantic Object Classes in Video... ».

¹²⁵ Tiago Henrique Trojahn et Rudinei Goularte, « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.

¹²⁶ *Ibid.*

¹²⁷ *Ibid.*

¹²⁸ *Ibid.*

¹²⁹ *Ibid.*

Une des solutions serait de combiner CNN et RNN : complémentaires.

DIVAN - INA mise en place d'un système expérimental d'indexation semi automatique des archives audiovisuelles, conçu en trois étapes : segmenter, classifier, composer.¹³⁰ les événements détectés dans l'image sont annotés et validés par les archivistes.

- segmentation audio la segmentation audio peut être divisée en différentes sous tâches : la transcription de la parole ("Les performances de ces systèmes peuvent être très bonnes lorsque de bonnes conditions sont réunies : bonnes conditions d'enregistrement, élocution claire, syntaxe correcte, noms propres connus du système en particulier."¹³¹), l'alignement audio/texte, indexation ("identification des termes les plus importants (mots clés), identification des sujets traités ou segmentation thématique"¹³²)

Une autre tâche de la segmentation audio et de l'analyse audio est l'identification des locuteurs. "Pour cela, il est nécessaire de posséder une référence pour chacun des locuteurs à reconnaître. Une référence peut consister en un ensemble d'échantillons de la voix de la personne à reconnaître"¹³³

- analyse des visages l'analyse des visages dans une vidéo se divise en plusieurs sous tâches : détection, suivi, caractérisation, reconnaissance.¹³⁴
- autres tâches de la segmentation Recherche d'instance (instance search) : "À partir d'un plan vidéo cible et d'un ensemble de thèmes qui délimitent la requête, il s'agit de retrouver dans une collection les plans les plus pertinents correspondant à la requête."¹³⁵

Indexation sémantique : "Il s'agit de caractériser des plans vidéo en leur assignant des étiquettes (tags) représentant des caractéristiques abstraites (appelées « concepts »)."¹³⁶

- Découverte d'objets visuels "La découverte d'objets visuels consiste à rechercher automatiquement les objets apparaissant le plus fréquemment dans une collection d'images ou de vidéos"¹³⁷
- data mining

¹³⁰Ronfard, Rémi, (*PDF*) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions...*

¹³¹J. Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels »...

¹³²*Ibid.*

¹³³*Ibid.*

¹³⁴*Ibid.*

¹³⁵*Ibid.*

¹³⁶*Ibid.*

¹³⁷*Ibid.*

”La fouille de données, ou data mining, recouvre un « ensemble de techniques ayant pour objet l’extraction d’un savoir à partir de grandes quantités de données, par des méthodes automatiques ou semi-automatiques » [14]. Les outils informatiques cherchent à découvrir, à faire émerger, à dégager, dévoiler des informations qu’il n’aurait pas été possible d’obtenir manuellement, parce que la quantité de documents à analyser est trop importante ou parce que les informations cherchées ne sont pas explicites et n’apparaissent en quelque sorte que statistiquement.”¹³⁸

Les archives audiovisuelles s’appliquent mal à ce concept puisque ce sont des archives : on veut pouvoir les décrire à la pièce, comme le ferait l’archiviste. On n’a pas extrait de statistiques mais des descriptions précises.

- fossé sémantique désigne le fossé entre ce que les algorithmes savent détecter et ce que les utilisateurs recherchent.

13. Limites et critiques

- Limites générales de l’IA

les modèles d’IA sont entraînés en anglais, pose des questions d’adaptabilité : ”Les IA conversationnelles reposent sur des grands modèles de langue (LLM) entraînés principalement sur des données en anglais, ce qui crée des biais linguistiques et culturels dans les résultats qu’ils produisent. [...] Il est donc indispensable que ces modèles soient entraînés avec une diversité de sources culturelles et linguistiques, y compris les langues régionales et les expressions artistiques moins représentées”¹³⁹

- Limites contextuelles

« How to give context to the machines? To give common sense? It’s a problem of artificial intelligence from the beginning. »¹⁴⁰

- limites de l’automatisation :

”l’intégration de la vision artificielle aux méthodes des historiens n’existe que conjointement à des interventions humaines, qui assurent la pertinence des traitements effectués et apportent une analyse nécessaire.”¹⁴¹

¹³⁸ *Ibid.*

¹³⁹ *La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture...*

¹⁴⁰ *AI in Audiovisual Archives / Sound & Vision...*

¹⁴¹ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

- sur l'indexation automatique audio : « Audio archives present a complex terrain for contemporary speech processing technologies, owing to the varied domains these recordings encapsulate. »¹⁴² : deux problèmes sur un corpus d'archives anciennes : variabilité linguistiques (multilingues, accents différents), variabilité temporelle (vieillesse des voix). les archives audiovisuelles sont un matériau hétérogène : opacité du médium.
- sur l'indexation automatique des archives audiovisuelles

IL est important pour les archivistes de savoir comment ont été entraînés les modèles qu'ils utilisent, sur quelles données.

la vidéo : souvent de moins bonne qualité que l'image fixe, donc les résultats d'indexation automatique peuvent être moins bons

contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ».¹⁴³

Lacunes

l'article de attard souligne que « The study underscores the lack of specialised annotation tools and the high resource demands of sophisticated models, which could present significant obstacles for future research with limited computational resources. »¹⁴⁴ c'est une limite surtout pour les institutions. Rejoint l'argument et les limites exposées par¹⁴⁵

Les modèles multimodaux qui combinent audio et vidéo (vivit-ast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d'usage et qui séparent les pipelines.¹⁴⁶

Absence d'outils d'annotation spécialisés dans la segmentation vidéo. Attard adapte label studio, un outil généraliste.¹⁴⁷

Limites des transformers : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset

¹⁴²P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

¹⁴³B. Bachimont, *Indexation et archivage de contenus multimédias...*

¹⁴⁴J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁴⁵P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

¹⁴⁶J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁴⁷*Ibid.*

to train. »¹⁴⁸. : les transformers n'ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu'il soit dans l'image. Ils ont donc besoin d'être entraînés sur beaucoup plus de données : c'est une grande limite. Une approche par classifieurs d'images plus légers comme ResNet peut donc être préférable. ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d'archives historique sauf pré entraînement massif.

- éthique de l'IA

Sur l'éthique de l'expérience utilisateur : Principles for Accountable Algorithms : responsibility, explainability, accuracy, auditability, fairness¹⁴⁹

Limites du machine learning : "Une répartition arbitraire des systèmes est toutefois limitée dans la mesure où, d'une part, les systèmes entraînés ont souvent un domaine d'application spécifique et, d'autre part, leurs capacités sont fortement liées aux jeux de données utilisés. Les algorithmes entraînés avec différents jeux de données produisent des résultats différents."¹⁵⁰

- Biais de la computer vision appliquée aux images :

"For instance, racial bias has been an ongoing challenge with computer vision tools, particularly with facial recognition software. A study published by MIT Media Lab in 2018 found that facial recognition software had an average error rate of 0.8 percent for light-skinned men, versus a 34.7 percent error rate for darker-skinned women"¹⁵¹ "societal biases are often engrained in AI model training datasets, which lead to the models reproducing those biases in their outputs"¹⁵² "In addition to this, the training data of computer vision models has relied mostly on visual content available to be harvested from the Internet, which in its majority corresponds to content developed during the last three decades. These models would underperform on images that are of a more historical character, commonly found in visual archives, since they are underrepresented in the training data"¹⁵³

Limite liée à la qualité des images : la qualité des images est absolument primordiale et déterminante dans la mise en place d'un pipeline d'indexation automatique : "La

¹⁴⁸A. Arnab, M. Dehghani, G. Heigold, *et al.*, ViViT...

¹⁴⁹*Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).

¹⁵⁰J. Arnold, M. Lüpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁵¹K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

¹⁵²*Ibid.*

¹⁵³*Ibid.*

question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle".¹⁵⁴ Important dans le cadre d'une indexation d'archives audiovisuelles, qui sont souvent de moins bonne qualité que les images car les fichiers sont plus lourds.

limites des réseaux de neurones profonds tels que les CNN pour l'analyse de l'esthétisme des images : « While hand-crafted features allow to quantify which feature contributes the most to an aesthetic rating, this interpretability is lost with generic features. [...] Deep neural networks and generic features basically represent a black-box approach that lacks this kind of interpretability. »¹⁵⁵ "with deep learning models, their success comes at a cost. At present, the understanding of deep features and how they work in object or aesthetic recognition lacks behind. »¹⁵⁶ Le problème est le suivant avec les CNN, les décisions qui sont prises sont obscures. Pour l'indexation des archives, c'est problématique si les archivistes ne sont pas capables d'expliquer pourquoi telle classification a été choisie par le modèle. Il faut maintenir une supervision humaine dans le pipeline d'indexation. La question de l'interopérabilité et de la transparence est aussi importante que la question de performance en sciences humaines et dans le milieu du patrimoine, car il s'agit de donner accès aux connaissances. (à relier avec l'éthique de l'IA : principes MA/ML : explainability)

La machine analyse différemment de l'humain, de manière objective et précise et exhaustive, qu'apporte l'humain ? : "the computational analysis of paintings has several advantages compared to an analysis carried out by human experts. For example, a computational analysis can pick up very subtle relationships that may escape the attention by human observers ; moreover, computational methods are objective in nature and are potentially non-exhaustive in the amount of detail analyzed. »¹⁵⁷

- Dépendance à la qualité de l'image

Limite exprimée dans le cadre de l'utilisation de line segment detection : "The first general challenge for line segment detection and description is that the endpoints of detected line segments are generally unstable due to many factors, such as image noise, occlusion, and illumination variance. This makes the line segment description and matching difficult since the corresponding line ROS (Region of Support) or neighborhood rela-

¹⁵⁴ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

¹⁵⁵ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

¹⁵⁶ *Ibid.*

¹⁵⁷ *Ibid.*

tionship among line segments is generated according to the line segment endpoints. »¹⁵⁸
 La compréhension et l'analyse de l'image dépend de la qualité de l'image, souvent réduite pour des raisons de stockage de données, pendant l'entraînement.

14. Archives audiovisuelles

- Définition "Les images animées comprennent une gamme de matériaux différents sur lesquels des séquences d'images ont été enregistrées et qui créent l'illusion du mouvement lorsqu'ils sont projetés, diffusés ou lus (à l'aide d'un projecteur, d'un téléviseur, d'un ordinateur, d'un logiciel ou de dispositifs équivalents). Ces images peuvent être accompagnées ou non de son. »¹⁵⁹

- Spécificités

"When you start looking at moving images and doing ML on them, your object of study is no longer an entire film but shots or scenes or still images. And that suddenly brings in important questions for archives and libraries. When the record itself changes...that raises huge questions that folks are not grappling with. Not just enriching a particular object but changing the object".¹⁶⁰

Difficultés de ce type de contenu : "moving image data, which is a particularly difficult data type to atomize."¹⁶¹

- Indexer les archives audiovisuelles

La spécificité du langage cinématographique comme obstacle à l'indexation
 archives muettes et anciennes

Contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ». ¹⁶² (aussi placé dans IAcinema)

Premier outil d'indexation des images : Perceptron de Franz Rozenblatt en 1957 : machine de reconnaissance d'images.

¹⁵⁸Xinyu Lin, Y. Zhou, Y. Liu, *et al.*, *A Comprehensive Review of Image Line Segment Detection and Description...*

¹⁵⁹FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).

¹⁶⁰R. Cordell, « Machine Learning + Libraries »...

¹⁶¹*Ibid.*

¹⁶²B. Bachimont, *Indexation et archivage de contenus multimédias...*

Pour l'indexation des archives audiovisuelles : apprentissage supervisé, non supervisé ou en profondeur : sont appliqués ou combinés.

”Dans le cas des archives audiovisuelles, on voit en outre très clairement comment les besoins des utilisateur · rice · s sont pris en compte lors de la conception de l'indexation automatique en profondeur et comment les données et les traces des utilisateur · rice · s sont utilisées pour optimiser l'accès aux archives audiovisuelles (mot-clé : système de recommandation).”¹⁶³

”L'indexation, la recherche et le filtrage basés sur le texte de contenus audiovisuels pertinents se heurtent par nature à des limites : Les contenus audiovisuels doivent également pouvoir être recherchés à l'aide de méthodes audiovisuelles (par exemple la navigation par images, Query by Example).”¹⁶⁴

”L'identification de contenus simples d'images ou de sons basée sur des descripteurs techniques ou des attributs dérivés a tendance à être de plus en plus laissée à la machine apprenante (par exemple « photo de groupe », « personne avec un casque sur la tête », termes parlés), tandis que l'identification plus poussée de personnes, de corps, de lieux, d'événements ou de sujets concrets est encore très sujette à erreurs.”¹⁶⁵

- modification de la perception de l'archive

Indexer automatiquement une archive audiovisuelles permet de repenser ses modalités d'analyse et d'interprétation. voir article cairn.

- Big Data

Les archives audiovisuelles, de part la complexité des données qu'elles renferment, des sons et des images, feraient partie d'un ”big data”.¹⁶⁶

- segmentation

Si la structuration d'éléments vidéos tels que les journaux télévisés, le sport, sont ”relativement stable et explicite de leur structure”,¹⁶⁷ et peuvent alors facilement être segmentés, les archives audiovisuelles regroupent des corpus divers et variés, allant de films expérimentaux à des bandes annonces, en passant par des films de famille. Ces archives sont parfois en noir et blanc et muettes.

¹⁶³J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁶⁴*Ibid.*

¹⁶⁵*Ibid.*

¹⁶⁶J. Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels »...

¹⁶⁷*Ibid.*

- adaptation aux algorithmes informatiques

des questions préalables se posent : "comment regarde-t-on un film ? Quels sont les mécanismes qui permettent d'interpréter cette longue séquence d'images (prenons le cas d'un film muet pour simplifier) en une séquence d'actions dramatiques, reliées entre elles par des liens de causalité, et qui nous permettent d'en comprendre le sens (l'histoire) ? Et comment reproduire cette capacité dans un programme informatique de vision par ordinateur ?"¹⁶⁸

"Aborder ces questions, c'est poser le problème de la représentation et de la reconnaissance des actions humaines dans les images."¹⁶⁹

- Problèmes de classification liés à l'analyse automatique des films

la reconnaissance des plans : "Il paraît donc utile de déterminer très tôt la taille de plan qui joue très certainement un rôle important pour la reconnaissance de tous les autres éléments de la scène (acteurs, lieux, objets et actions)."¹⁷⁰

reconnaissance des mouvements de caméra reconnaissance des actions : il faut utiliser des séquences annotées.

répertoire de plans ? de séquences ? d'actions ? de genres ?

Rémi Ronfard propose le terme de canevas pour parler des séquences d'un film dans le cadre d'une analyse automatique par IA¹⁷¹

l'identification de ces "canevas" permettrait ensuite d'identifier le reste des composants vidéo : plans, action, acteurs...¹⁷²

Définition du NLP

Le NLP et la recherche sémantique (Tannier, Wang, ressources ISO/Oracle)

« NLP is the area of AI and linguistics concerned with training machines to decipher meaning in human language. » « NLP tools such as Entity Extraction are especially valuable in archival settings because they can help link descriptive data to controlled vocabularies. »¹⁷³

¹⁶⁸Ronfard, Rémi, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions...*

¹⁶⁹*Ibid.*

¹⁷⁰*Ibid.*

¹⁷¹*Ibid.*

¹⁷²*Ibid.*

¹⁷³*AI in Audiovisual Archives / Sound & Vision...*

limites

« Technologies were primarily trained on white men with regional speaking styles dominant on TV, and didn't work well on speech and accents of people of other cultures or regions. »¹⁷⁴

15. Experience utilisateur

- Côté expérience utilisateur

Skinsoft souhaite améliorer au quotidien son expérience utilisateur. Divers projets en cours le montrent : refonte du tableau de bord de suivi activité, mise en place d'une recherche NLP, mise en place d'un chatbot. Par rapport à d'autres logiciels de gestion de collection qui se limitent à des aspects pratiques d'indexations et de pratiques documentaires, skinsoft souhaite être innovante à tous les niveaux pour rester concurrentielle. Cette concurrence s'exprime notamment à travers l'amélioration continue de l'expérience utilisateur. L'indexation automatique part de cette volonté précise d'améliorer l'expérience utilisateur. Le client n'est pas seulement un professionnel en contexte culturel, il est plus généralement un client d'application dont l'expérience et la fluidité des actions est primordiale pour choisir et garder l'application imaginée par skinsoft. Une sorte de dualité s'installe, celle d'améliorer les pratiques documentaires et celle de faire de l'expérience utilisateur une expérience fluide, personnalisable et efficace. Les deux vont de pair.

Il faut partir de l'expérience utilisateur : quelles sont les attentes, quelles sont les difficultés métier ? est-ce qu'une automatisation des tâches est attendue ? cf. démo avec Yves Klein qui ont demandé de ne pas avoir les nouvelles fonctionnalités IA dans leur espace de travail. Crainte de fuite de données aussi. "the real problems are professional problems – the idea is that the IT people have to be aware of the real problems, the real things to do ; if they don't introduce themselves in the archives they won't be aware of what to do."¹⁷⁵

Indexation automatique et expérience utilisateur : une question de transparence : "Alors que l'utilisation du ML va déjà de soi dans certains domaines, il y a des domaines dans lesquels nous devons rendre son utilisation transparente pour les utilisateurs et leur donner la possibilité d'option de retrait, par exemple lorsqu'il s'agit de données personnelles. La transparence est également requise lorsqu'il s'agit d'adapter l'offre concrète aux besoins des utilisateurs sur la base de profils d'utilisateur."

¹⁷⁴ *Ibid.*

¹⁷⁵ *Bringing AI into the Audiovisual Archive / Sound & Vision...*

(obtenus par le biais de demandes, d'autodéclaration ou de « traces d'utilisation », comme le classement d'une liste de résultats ou des propositions par des systèmes de recommandation).¹⁷⁶

- besoin utilisateur comment répondre à un réel besoin utilisateur et pas seulement à une logique produit ?
- Comment donner accès à ces automatisations ? L'exemple d'Amalia.js

Amalia.js est un lecteur HTML5 extensible qui synchronise des métadonnées avec la lecture de flux vidéo ou audio. Conçu pour visualiser les résultats d'algorithmes d'analyse audiovisuelle.

Le besoin à l'origine d'Amalia.js est de permettre de visualiser les résultats de pipelines d'automatisation, avec leur lot de métadonnées produites : « Whatever the field of analysis, we always need to be able to quickly and easily view the results of the methods we are developing. This problem is particularly true as we often manipulate large amount of videos. Developing visualization and annotation tools is often a tedious task that deserves to be pooled. »¹⁷⁷ « The analysis being at different levels (keyframes, video segments, audio channels, associated synopses, one video alone or relative to a corpus...) results are obtained in very different natures, often needing quite specific approaches to be presented to the end user. »¹⁷⁸ L'indexation automatique regroupe tout un tas de métadonnées issues d'algorithmes et d'outils différents qu'il faut réunir dans une interface de présentation.

C'est une interface pour visualiser et pour corriger.

Comment regrouper dans la même interface des métadonnées de nature très différentes attachées à la même vidéo ?

Les métadonnées horodatées : issues de la segmentation vidéo.

« The main principle of amalia.js is to have a unified metadata model. Ensuring that all the metadata types are consistent and use the same standards will facilitate their use and enable us to design generic visualization plugins. »¹⁷⁹. Importance d'avoir une interface de standardisation des métadonnées : important pour skinsoft qui doit s'adapter aux normes employées par les clients.

¹⁷⁶J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁷⁷N. Hervé, P. Letessier, M. Derval, *et al.*, « Amalia.Js... ».

¹⁷⁸*Ibid.*

¹⁷⁹*Ibid.*

Le logiciel permet à l'utilisateur d'annoter la vidéo pour corriger les métadonnées ou les compléter : « This will allow us to enter or correct metadata directly through the player. We plan to use this version in groundtruth management applications so as to enable the creation of huge research datasets used to train supervised algorithms or to assess analysis methods performances. »¹⁸⁰. La correction humaine permet d'avoir des métadonnées plus justes, mais permet aussi d'avoir des données d'entraînement pour améliorer les algorithmes d'indexation automatique. (aussi vu chez Vanderbilt). Utilistauer comme rôle de correction et d'enrichissement sur une base générée automatiquement.

16. Limites et critiques

- Limites générales de l'IA

les modèles d'IA sont entraînés en anglais, pose des questions d'adaptabilité : "Les IA conversationnelles reposent sur des grands modèles de langue (LLM) entraînés principalement sur des données en anglais, ce qui crée des biais linguistiques et culturels dans les résultats qu'ils produisent. [...] Il est donc indispensable que ces modèles soient entraînés avec une diversité de sources culturelles et linguistiques, y compris les langues régionales et les expressions artistiques moins représentées"¹⁸¹

- Limites contextuelles

« How to give context to the machines? To give common sense? It's a problem of artificial intelligence from the beginning. »¹⁸²

- limites de l'automatisation :

"l'intégration de la vision artificielle aux méthodes des historiens n'existe que conjointement à des interventions humaines, qui assurent la pertinence des traitements effectués et apportent une analyse nécessaire."¹⁸³

- sur l'indexation automatique audio : « Audio archives present a complex terrain for contemporary speech processing technologies, owing to the varied domains these recordings encapsulate. »¹⁸⁴ : deux problèmes sur un corpus d'archives anciennes : variabilité

¹⁸⁰ *Ibid.*

¹⁸¹ *La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture...*

¹⁸² *AI in Audiovisual Archives / Sound & Vision...*

¹⁸³ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

¹⁸⁴ P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

linguistiques (multilingues, accents différents), variabilité temporelle (vieillesse des voix). les archives audiovisuelles sont un matériau hétérogène : opacité du médium.

- sur l'indexation automatique des archives audiovisuelles

IL est important pour les archivistes de savoir comment ont été entraînés les modèles qu'ils utilisent, sur quelles données.

la vidéo : souvent de moins bonne qualité que l'image fixe, donc les résultats d'indexation automatique peuvent être moins bons

contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ».¹⁸⁵

Lacunes

l'article de attard souligne que « The study underscores the lack of specialised annotation tools and the high resource demands of sophisticated models, which could present significant obstacles for future research with limited computational resources. »¹⁸⁶ c'est une limite surtout pour les institutions. Rejoint l'argument et les limites exposées par¹⁸⁷

Les modèles multimodaux qui combinent audio et vidéo (vivit-ast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d'usage et qui séparent les pipelines.¹⁸⁸

Absence d'outils d'annotation spécialisés dans la segmentation vidéo. Attard adapte label studio, un outil généraliste.¹⁸⁹

Limites des transformers : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset to train. »¹⁹⁰. : les transformers n'ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu'il soit dans l'image. Ils ont donc besoin d'être entraînés sur beaucoup plus de données : c'est une grande limite. Une approche par classifieurs d'images plus légers comme ResNet peut donc être préférable.

¹⁸⁵B. Bachimont, *Indexation et archivage de contenus multimédias...*

¹⁸⁶J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁸⁷P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

¹⁸⁸J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁸⁹*Ibid.*

¹⁹⁰A. Arnab, M. Dehghani, G. Heigold, *et al.*, *ViViT...*

ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d'archives historique sauf pré entraînement massif.

- éthique de l'IA

Sur l'éthique de l'expérience utilisateur : Principles for Accountable Algorithms : responsibility, explainability, accuracy, auditability, fairness¹⁹¹

Limites du machine learning : "Une répartition arbitraire des systèmes est toutefois limitée dans la mesure où, d'une part, les systèmes entraînés ont souvent un domaine d'application spécifique et, d'autre part, leurs capacités sont fortement liées aux jeux de données utilisés. Les algorithmes entraînés avec différents jeux de données produisent des résultats différents."¹⁹²

- Biais de la computer vision appliquée aux images :

"For instance, racial bias has been an ongoing challenge with computer vision tools, particularly with facial recognition software. A study published by MIT Media Lab in 2018 found that facial recognition software had an average error rate of 0.8 percent for light-skinned men, versus a 34.7 percent error rate for darker-skinned women"¹⁹³ "societal biases are often engrained in AI model training datasets, which lead to the models reproducing those biases in their outputs"¹⁹⁴ "In addition to this, the training data of computer vision models has relied mostly on visual content available to be harvested from the Internet, which in its majority corresponds to content developed during the last three decades. These models would underperform on images that are of a more historical character, commonly found in visual archives, since they are underrepresented in the training data"¹⁹⁵

Limite liée à la qualité des images : la qualité des images est absolument primordiale et déterminante dans la mise en place d'un pipeline d'indexation automatique : "La question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle".¹⁹⁶ Important

¹⁹¹ *Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML...*

¹⁹² J. Arnold, M. Lüpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁹³ K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

¹⁹⁴ *Ibid.*

¹⁹⁵ *Ibid.*

¹⁹⁶ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

dans le cadre d'une indexation d'archives audiovisuelles, qui sont souvent de moins bonne qualité que les images car les fichiers sont plus lourds.

limites des réseaux de neurones profonds tels que les CNN pour l'analyse de l'esthétisme des images : « While hand-crafted features allow to quantify which feature contributes the most to an aesthetic rating, this interpretability is lost with generic features. [...] Deep neural networks and generic features basically represent a black-box approach that lacks this kind of interpretability. »¹⁹⁷ "with deep learning models, their success comes at a cost. At present, the understanding of deep features and how they work in object or aesthetic recognition lacks behind. »¹⁹⁸ Le problème est le suivant avec les CNN, les décisions qui sont prises sont obscures. Pour l'indexation des archives, c'est problématique si les archivistes ne sont pas capables d'expliquer pourquoi telle classification a été choisie par le modèle. Il faut maintenir une supervision humaine dans le pipeline d'indexation. La question de l'interopérabilité et de la transparence est aussi importante que la question de performance en sciences humaines et dans le milieu du patrimoine, car il s'agit de donner accès aux connaissances. (à relier avec l'éthique de l'IA : principes MA/ML : explainability)

La machine analyse différemment de l'humain, de manière objective et précise et exhaustive, qu'apporte l'humain ? : "the computational analysis of paintings has several advantages compared to an analysis carried out by human experts. For example, a computational analysis can pick up very subtle relationships that may escape the attention by human observers ; moreover, computational methods are objective in nature and are potentially non-exhaustive in the amount of detail analyzed. »¹⁹⁹

- Dépendance à la qualité de l'image

Limite exprimée dans le cadre de l'utilisation de line segment detection : "The first general challenge for line segment detection and description is that the endpoints of detected line segments are generally unstable due to many factors, such as image noise, occlusion, and illumination variance. This makes the line segment description and matching difficult since the corresponding line ROS (Region of Support) or neighborhood relationship among line segments is generated according to the line segment endpoints. »²⁰⁰ La compréhension et l'analyse de l'image dépend de la qualité de l'image, souvent réduite pour des raisons de stockage de données, pendant l'entraînement.

¹⁹⁷ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

¹⁹⁸ *Ibid.*

¹⁹⁹ *Ibid.*

²⁰⁰ Xinyu Lin, Y. Zhou, Y. Liu, *et al.*, *A Comprehensive Review of Image Line Segment Detection and Description...*

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visité le 12/05/2026).
- ARNAB (Anurag), DEGHANI (Mostafa), HEIGOLD (Georg), SUN (Chen), LUČIĆ (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4–2 (juill. 2019), DOI : 10.22148/16.043.
- ASPERTI (Andrea), DESSÌ (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BASSAÏSTEGUY (Sidonie), *Le Médium, c'est La Mémoire : Archivages Du Document à l'Institut National de l'audiovisuel*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visité le 13/05/2026).

- BERGMANN (Cole Stryker Dave), *Qu'est-ce qu'un modèle transformer ? / IBM*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BERMÈS (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l'IA 2025 », dans *Conférence Nationale Sur Les Applications de l'Intelligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARON (Mathilde), BOJANOWSKI (Piotr), JOULIN (Armand) et DOUZE (Matthijs), « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.
- CARRIVE (Jean), « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What's the Difference ? / IBM*, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).
- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- FIAT/IFTA *Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).

- France 2030 : un plan d'investissement pour la France* / *economie.gouv.fr*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].
- HERVÉ (Nicolas), LETESSIER (Pierre), Derval (Mathieu) et NABI (Hakim), « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- INDEXATION : Définition de INDEXATION*, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).
- L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et*, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).
- La stratégie du ministère pour des intelligences artificielles culturelles et responsables* / *Ministère de la Culture*, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).
- LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).
- Les secrets du traitement du langage naturel décryptés*, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).
- LETESSIER (Pierre), HERVÉ (Nicolas), JOLY (Alexis), NABI (Hakim), Derval (Mathieu) et BUISSON (Olivier), « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.
- LIU (Haotian), LI (Chunyu), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].
- LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Ma-

- nan), HAMDY (Mohammed), *et al.*, *Bridging the Data Provenance Gap Across Text, Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].
- MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].
- MOIRAGHI (Eleonora), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs.CV].
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, p. 152, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 08/06/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).
- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).
- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).

- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).
- Qu'est-ce qu'un réseau de neurones convolutifs ?* / IBM, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).
- Qu'est-ce que la conception de chatbot ?* / IBM, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).
- ROBERT (Jérémy), *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).
- RONFARD, RÉMI, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).
- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- SULLIVAN (Peter) et ABDUL-MAGEED (Muhammad), *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*-94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605.
- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).

- Traitement du langage naturel : découvrez comment les machines lisent et écrivent*, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).
- VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*–hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].
- XINYU LIN, ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].
- YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- YOON (Sangwoong), KANG (Woo Young), JEON (Sungwook), LEE (SeongEun), HAN (Changjin), PARK (Jonghun) et KIM (Eun-Sol), *Image-to-Image Retrieval by Learning Similarity between Scene Graphs*, déc. 2020, DOI : 10.48550/arXiv.2012.14700, arXiv : 2012.14700 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.
- ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wenguan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

Mon introduction

Première partie

Une partie

Chapitre 1

Mon premier chapitre

Deuxième partie

Une autre partie

Conclusion

Annexe A

Le titre très long de la première
annexe

Table des matières

Résumé	i
Brouillon	iii
1. Contexte skinsoft	iii
2. Problématique	vi
3. analyse automatique de l'image	ix
4. Indexation automatique	ix
5. indexation iconographique	xi
6. indexation audio	xiii
7. notions IA	xiv
8. machine learning	xiv
9. computer vision	xviii
10. IA appliquée à la vidéo	xxi
11. segmentation	xxiv
12. Limites et critiques	xxxiv
13. Archives audiovisuelles	xxxviii
14. Experience utilisateur	xli
15. Limites et critiques	xliii
Remerciements	xlvi
Introduction	lvii
I Une partie	1
1 Mon premier chapitre	3

II	Une autre partie	5
	Conclusion	7
A	Titre court	9