

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Brouillon

1. Problématique

- Sur la compréhension du cinéma par l'IA :

Ce qui est encore en cours de développement pour les outils actuellement = compréhension du langage cinématographique (montage, narration), analyse des ambiances et émotions, détection d'œuvres musicales.

Incapacité des machines à comprendre le langage ciné pour l'instant et à l'analyser correctement : pourquoi ?

Il n'existe pas de solution tout en un

L'image animée regroupe bcp de choses.

- Interface et l'expérience utilisateur :

Comment combiner performance technique et expérience utilisateur au sein de l'application avec l'implémentation de l'IA ?

Implémentation de deux outils de recherche assistée dans l'application : comment guider l'utilisateur vers l'outil qu'il cherche ?

Faire une interface utilisateur qui augmente la productivité et l'interactivité mais en même temps qui reste adaptée aux institutions culturelles qui n'ont pas forcément d'objectifs de rendement et de productivité comme des entreprises privées. Trouver la limite. Ne pas en faire une appli de marketing.

Tensions entre besoins utilisateurs musée / et une logique de productivité d'entreprise privée vers laquelle se tourne de plus en plus l'application : tableau de bord, intelligence artificielle.

Améliorer l'interface et l'expérience utilisateur est ce qui fait prospérer skinsoft et ce qui la démarque de ses concurrents.

- Migration de données :

Décalage entre ce que le client veut pour ses données, et ce que skin soft est capable de faire. Un changement de logiciel induit forcément une modification de la saisie des données, même si l'application est entièrement paramétrable. Décalage entre ce que l'institution attend et ce que skinsoft peut faire conformément aux standards documentaires, au temps qu'ils peuvent y consacrer et aux limites de l'application et de l'interface.

Difficulté de paramétrer l'application en fonction de la manière de saisir les données propres à chaque institution, des thésaurus utilisés...

L'application et les paramétrages évoluent presque à chaque nouveau client et devient plus malléable.

- Sur l'indexation :

La génération de résumé sur une archive audiovisuelle prévue par skin soft se fait de quelle façon, à partir de quelles données ?

Résumé à partir de notices déjà constituées sur l'archives en question

Extraction des éléments dans l'image : autorités

Extraction d'éléments dans le son

Comment le NLP transforme les pratiques d'indexation ? Lien entre les deux ?

Pour l'instant, il existe des modèles qui permettent de détecter la séparation entre les plans grâce au changement de position des personnages, changement de lumières... Mais la détection du changement de séquences se situe à un niveau supplémentaire de compréhension du langage cinématographique. Cela suppose de comprendre ce qu'est une séquence (combinaison d'un changement temporel et spatial). Comment améliorer les modèles qui détecte les changements de plans pour leur faire comprendre les changements de séquences ? Surtout sur des archives audiovisuelles où il se passe peu de choses dans l'image. La plupart des cas d'usages vus et lus sont entraînés sur des séquences de télévision par exemple, un langage "classique et normé qui est toujours le même. Pour les archives très anciennes comme celles d'Albert Kahn, il n'y a pas de coupures ou très peu, les plans sont fixes, les sujets sont généralement loin de la caméra. Est-ce que c'est plus facile à entraîner ? Comment entraîner un modèle qui puisse analyser des vidéos à la fois très similaires et très différentes en termes de langage cinématographique ?

les archives audiovisuelles nécessitent une indexation de contenu : extraction d'information à partir de ce qui se trouve dans l'image

pour les archives papier, l'indexation automatique des archives nées numériques et les archives numérisées est différentes. Pour les archives nées numériques, il existe déjà un produit numérique : pdf par exemple ou document texte. Pour une archive numérisée, il faut produire ce dérivé pour y appliquer de la reconnaissance d'entités, de caractères... Est-ce la même chose pour les archives audiovisuelles ? Ou ça ne change rien ?

Définition de l'indexation documentaire

- **Indexation documentaire (Sumominen, Husson, Reignier)**

définition de l'indexation : "Le fait de dresser un répertoire ou une liste, généralement alphabétique, des sujets traités, des noms cités dans un ouvrage, suivis des références aux pages, aux paragraphes" (Rolland-Coul. 1969).¹

autre définition : Selon l'AFNOR, l'indexation est la "représentation par les éléments d'un langage documentaire ou naturel, des notions résultant de l'analyse du contenu d'un document en vue d'en faciliter la recherche"²

« Les bibliothèques gèrent un grand nombre de métadonnées, pour différents types de documents. Le plus souvent, ces documents sont indexés à l'aide de mots sujets sélectionnés au sein d'un vocabulaire contrôlé, afin d'être recherchés plus tard. L'indexation manuelle de documents est un travail intellectuel très consommateur de temps. »³

définition de l'indexation : "L'indexation est cette technique consistant à caractériser le contenu d'un document et l'information qu'il détient de manière à le retrouver quand on effectue des recherches sur l'un des sujets dont il traite. La difficulté est donc de savoir caractériser et représenter l'information documentaire pour qu'il soit aisé de la mettre en rapport avec des sujets d'investigation. Mise en rapport d'une requête et d'un contenu représenté et synthétisé, l'indexation permet de s'orienter dans la masse des documents et d'organiser ses connaissances. L'indexation appartient donc à ce qu'on appelle depuis quelques années les techniques intellectuelles Indexation et archivage de contenus multimédias"⁴

¹INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).

²Pierre Husson, « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RETIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).

³Osma Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605, p. 21.

⁴Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « l'indexation par le contenu ». ⁵

- **Indexation automatique**

« Les systèmes d'indexation automatique suivent généralement un processus dans lequel les documents textuels sont, dans un premier temps, "préparés" [...] les documents sont convertis dans une représentation vectorielle de leur fréquence d'apparition, ce qui, à l'aide d'un algorithme, permet d'établir des comparaisons entre les mots-sujets utilisés. » ⁶

« Les algorithmes d'indexation automatique se répartissent selon deux types d'approche : lexicale et associative. » ⁷

Pour les archives audiovisuelles, des processus techniques s'ajoutent : extraction d'entités depuis l'images, extraction d'entités depuis le son. La forme du médium cinématographique crée une opacité et une complexité pour l'instauration de pipeline algorithmiques.

- **Indexation iconographique**

« L'indexation iconographique consiste à décrire le contenu des images à l'aide de descripteurs afin de faciliter l'accès aux œuvres, sans cependant dispenser sa consultation. » ⁸

- **Archives audiovisuelles (Bassaïsteguy (INA), Rattinger, Le Ber, Attard)**
- **IA et vision par ordinateur (Arnab (ViViT), Gong (AST), Trojahn, Yuan)**
- **Pipeline**

Mise en place d'une pipeline IA : Ce sont plusieurs outils combinés qui créent l'indexation : analyse audio avec l'ASR et la segmentation, analyse de l'image avec la computer vision et shot detection, le NLP avec le NER et term extraction. Cette pipeline permet d'extraire des métadonnées en lien avec des vocabulaires contrôlés et ainsi d'indexer les images. « Each tool specializes in a single task, and is brought together

⁵ *Ibid.*

⁶ O. Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande »..., p. 21.

⁷ *Ibid.*

⁸ P. Husson, « Indexation iconographique et intelligence artificielle... », p. 3.

with other tools in pipelines. Technologies can be layered upon one another in order to more meaningfully annotate content. »⁹

Implémentation d'une combinaison d'outils différents pour l'indexation : "La combinaison de différents outils et leur intégration dans des environnements logiciels existants est un sujet important, pour lequel il existe désormais un large éventail de solutions, souvent open source"¹⁰

- Outils

Trint : automatic speech recognition
FasterR CNN et Farec CNN : face detection models
YOLO : outil opensource de détection d'objets et d'identification

- Cas d'indexation

The vanderbilt university television news archive : ils utilisent Trint pour transcrire les discours et engagent des étudiants pour corriger les transcriptions sur l'interface de l'outil Trint :

"students also note the start and stop time of segments, and write relevant on-screen information such as names into the transcript. Each 30-minute program takes one hour of student worker time to correct. When the transcript is complete, it is exported to Amazon's Named Entity Recognition service on the cloud, where information such as person, location, or topic is pulled out. That information is then brought back into the workflow with scripts written in Python that turn the information into individual titles for each news segment. Additional information such as reporter or location are added to database fields, and duplicate records are kept in PBCore for future use when more of the information from the Named Entity Recognition system might be stored in the database."¹¹

2. limites

« How to give context to the machines? To give common sense? It's a problem of artificial intelligence from the beginning. »¹²

⁹*AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).

¹⁰Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

¹¹*Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).

¹²*AI in Audiovisual Archives / Sound & Vision...*

Définition du NLP

Le NLP et la recherche sémantique (Tannier, Wang, ressources ISO/Oracle)

« NLP is the area of AI and linguistics concerned with training machines to decipher meaning in human language. » « NLP tools such as Entity Extraction are especially valuable in archival settings because they can help link descriptive data to controlled vocabularies. »¹³

limites

« Technologies were primarily trained on white men with regional speaking styles dominant on TV, and didn't work well on speech and accents of people of other cultures or regions. »¹⁴

3. IA générale

- Éthique de l'IA

Sur l'éthique de l'expérience utilisateur : Principles for Accountable Algorithms : responsibility, explainability, accuracy, auditability, fairness¹⁵

4. Expérience utilisateur

- Côté expérience utilisateur

Il faut partir de l'expérience utilisateur : quelles sont les attentes, quelles sont les difficultés métier ? est ce qu'une automatisation des tâches est attendue ? cf démo avec Yves Klein qui ont demandé de ne pas avoir les nouvelles fonctionnalités IA dans leur espace de travail. Crainte de fuite de données aussi. "the real problems are professional problems – the idea is that the IT people have to be aware of the real problems, the real things to do ; if they don't introduce themselves in the archives they won't be aware of what to do."¹⁶

Indexation automatique et expérience utilisateur : une question de transparence : "Alors que l'utilisation du ML va déjà de soi dans certains domaines, il y a des domaines dans lesquels nous devons rendre son utilisation transparente pour les utilisateur · rice · s et leur donner la possibilité d'option de retrait, par exemple lorsqu'il s'agit de données

¹³ *Ibid.*

¹⁴ *Ibid.*

¹⁵ *Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).

¹⁶ *Bringing AI into the Audiovisual Archive | Sound & Vision...*

personnelles. La transparence est également requise lorsqu'il s'agit d'adapter l'offre concrète aux besoins des utilisateurs sur la base de profils d'utilisateur (obtenus par le biais de demandes, d'autodéclaration ou de « traces d'utilisation », comme le classement d'une liste de résultats ou des propositions par des systèmes de recommandation).¹⁷

5. IA et cinéma

- Archives audiovisuelles

”When you start looking at moving images and doing ML on them, your object of study is no longer an entire film but shots or scenes or still images. And that suddenly brings in important questions for archives and libraries. When the record itself changes...that raises huge questions that folks are not grappling with. Not just enriching a particular object but changing the object”.¹⁸

Difficultés de ce type de contenu : ”moving image data, which is a particularly difficult data type to atomize.”¹⁹

- Cas d'usage

Exemple de projet d'extraction d'entités depuis des images en mouvement :²⁰ méthode du distant viewing : reconnaissance des visages, classification des plans. Le montage et le cadrage servent à construire la place des personnages dans le récit. ”« One of the first tasks in understanding a video file is to break up the sequence of frames into distinct units known as shots ». « We first split an input video file into individual shots, then locate faces within every frame, identify the faces in a frame, and finally put all of the information together to cluster shots based on camera angles and distances ». ²¹ Shot boundary detection : détection automatique des coupures entre les plans dans une vidéo Shot semantics : description de ce qui est présent dans l'image et à quel endroit de l'image et ainsi relier l'image à des catégories de plan (shot type).

problématique principale pour indexer : il faut déjà séparer la vidéo en tous les plans qui la composent pour en extraire les éléments : ”One of the first tasks in understanding

¹⁷Id., « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁸Ryan Cordell, « Machine Learning + Libraries » ().

¹⁹*Ibid.*

²⁰Taylor Arnold, Lauren Tilton et Annie Berke, « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4-2 (juill. 2019), DOI : 10.22148/16.043.

²¹*Ibid.*

a video file is to break up the sequence of frames into distinct units known as shots—or uninterrupted footage between cuts—in a process known as shot boundary detection.”²²

exemple de pipeline pour détecter les coupures entre les plans : ”the vast majority of cuts in most film and television episodes consist of abrupt transitions between alternative camera shots. These are both easy to define and relatively easy to detect. The algorithm we use in our analysis uses a combination of histogram differences and down sampled pixel intensities. Our method functions by measuring the extent to which two successive shots are different from one another in terms of the general color palette and the distribution of brightness over the frame. If these differences fall above a specified threshold, we indicate the presence of a cut.²² We also added special logic to avoid erroneous cuts during fade-in and fade-out events.”²³

face detection models : Faster R-CNN and FAREC-CNN²⁴

shot classification : il est possible de classifier le type de plan à l’image en utilisant le placement des visages : ”In this final step we no longer work directly with the visual materials and build a meta-algorithm that takes detected shot breaks and faces as input and outputs categorical predictions for each shot”.²⁵ Il s’agit de définir tous les types de plans et à partir de ces définitions, construire un jeu de données qui sera testé : close-up, over the shoulder...

Audiovisuel Processing (AVP) : ensemble de technologies appliquées à l’analyse de contenus vidéos et audio (comprend computer vision et ASR automatic speech recognition)²⁶

constat : malgré de grandes avancées dans le processing audiovisuel, ces outils restent largement inaccessibles et ne sont pas donc pas adoptés dans le milieu des archives : « Despite the massive progress made in the performance levels and overall availability of Audiovisual Processing (AVP) technologies, such as Computer Vision (CV) and Automatic Speech Recognition (ASR), the availability of these tools for heritage institutions is still lagging behind. »²⁷

ImageJ : open source visual analysis software suite²⁸ Detectron2 : détection de points

²² *Ibid.*

²³ *Ibid.*

²⁴ *Ibid.*

²⁵ *Ibid.*

²⁶ Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

²⁷ *Ibid.*

²⁸ *Ibid.*

corporels dans l'image²⁹

les AVP ne sont pas accessible en libre accès aux chercheurs en humanité numériques. Les algorithmes ont besoin d'un accès direct aux données, or, pour des raisons de sécurité des données et des droits de propriétés intellectuelles auxquels sont soumis les archives, les données des archives ne peuvent pas quitter leur environnement numérique. donc : "A side effect of this is that for the analysis of AV material commercially available tools cannot be used, as these are primarily cloud based. To tackle this challenge it is necessary that any AVP infrastructure can be integrated with a local archival infrastructure, i.e., we need to bring the algorithms to the data, rather than the data to the algorithms"³⁰

au lieu de transférer les fichiers vers un service externe, l'algorithme doit être déployé localement au sein même de l'infrastructure de l'archive.

exemple de l'architecture DANE au sein du projet CLARIAH : l'architecture est divisée en plusieurs "workers" et une file d'attente. si l'un des workers s'arrêtent de fonctionner, les autres continuent leur tâche. Cette architecture produit deux types de données : des métadonnées structurées directement exploitables, et des vecteurs de caractéristiques (= représentations abstraites des données utilisables pour des requêtes de similarité : ouvre des possibilités de recherche par ressemblance son et vidéo.)³¹

"there is a near-linear relationship between quality of transcriptions and search performance. » : importance de la qualité de la transcription audiovisuelle pour améliorer la recherche.³²

"the application of AVP tools to large image datasets significantly scales up the level of analysis from 'close' to 'distant' viewing, allowing scholars to observe patterns in the data that are invisible in the traditional, interpretative analyses of small sample sets. » le distant viewing permet de passer d'une lecture individuelle d'items à une analyse d'éléments à l'échelle d'un corpus.³³

"« Digital tools for paper resources have tended not to consider the strong presence of visual elements in them. Due to the lack of practically available AVP tools to digital humanities, scholarly research has 'grossly neglected visual content, causing a lopsided representation of all sorts of digitized archives'. » Sous représentation des éléments visuels dans l'indexation, même pour une collection audiovisuelle. Les métadonnées

²⁹ *Ibid.*

³⁰ *Ibid.*

³¹ *Ibid.*

³² *Ibid.*

³³ *Ibid.*

textuelles liées aux films sont insuffisantes pour enrichir leurs métadonnées : titre, synopsis...³⁴

- Indexation des archives audiovisuelles

Premier outil d'indexation des images : Perceptron de Franz Rozenblatt en 1957 : machine de reconnaissance d'images.

Pour l'indexation des archives audiovisuelles : apprentissage supervisé, non supervisé ou en profondeur : sont appliqués ou combinés.

”Dans le cas des archives audiovisuelles, on voit en outre très clairement comment les besoins des utilisateur · rice · s sont pris en compte lors de la conception de l'indexation automatique en profondeur et comment les données et les traces des utilisateur · rice · s sont utilisées pour optimiser l'accès aux archives audiovisuelles (mot-clé : système de recommandation).”³⁵

”L'indexation, la recherche et le filtrage basés sur le texte de contenus audiovisuels pertinents se heurtent par nature à des limites : Les contenus audiovisuels doivent également pouvoir être recherchés à l'aide de méthodes audiovisuelles (par exemple la navigation par images, Query by Example).”³⁶

”L'identification de contenus simples d'images ou de sons basée sur des descripteurs techniques ou des attributs dérivés a tendance à être de plus en plus laissée à la machine apprenante (par exemple « photo de groupe », « personne avec un casque sur la tête », termes parlés), tandis que l'identification plus poussée de personnes, de corps, de lieux, d'événements ou de sujets concrets est encore très sujette à erreurs.”³⁷

”When it comes to processing image-based records in archives archives, supervised learning models can be helpful for identification and classification, while unsupervised learning models are best suited for processing large amounts of data for creating generic descriptions, and highlighting possible connections between records.”³⁸

- Outils

YOLO (you only look once) Algorithme qui utilise CNNs pour entourer des objets dans des images et les classer dans des catégories il s'agit d'un single shot object detector :

³⁴ *Ibid.*

³⁵ J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

³⁶ *Ibid.*

³⁷ *Ibid.*

³⁸ Kaila Fewster et Richard Arias, « Teachable AI for the Archival Professions – Module 4 : » ().

il se base sur une seule analyse de l'image dans sa globalité facial recognition, scene analysis, object tracking³⁹

two shot objects detector : multiple image reviews Exemple : Mask Region-based CNN (R-CNN) algorithm. "uses deep neural networks to identify regions of interest in the photograph and build boxes around objects found throughout the image"⁴⁰ Cette manière de faire est appelée "semantic segmentation" : "identifies semantic objects without specifying how many instances of that object are present in the image"⁴¹ Par exemple, s'il y a 5 personnes dans une image, la segmentation sémantique les identifie comme un même objet sémantique dans l'image.

Instance segmentation : "identifies all the semantic objects in an image and segments them into specific instances to accurately distinguish between each object of a similar semantic category" (c'est ce que fait Mask RCNN)⁴²

Computer-Aided Metadata generation for Photo Archives Initiative (CAMPI)⁴³ production de tags sur des images et recommandation d'images similaires

- Biais et limites

"For instance, racial bias has been an ongoing challenge with computer vision tools, particularly with facial recognition software. A study published by MIT Media Lab in 2018 found that facial recognition software had an average error rate of 0.8 percent for light-skinned men, versus a 34.7 percent error rate for darker-skinned women"⁴⁴ "societal biases are often engrained in AI model training datasets, which lead to the models reproducing those biases in their outputs"⁴⁵ "In addition to this, the training data of computer vision models has relied mostly on visual content available to be harvested from the Internet, which in its majority corresponds to content developed during the last three decades. These models would underperform on images that are of a more historical character, commonly found in visual archives, since they are underrepresented in the training data"⁴⁶

IL est important pour les archivistes de savoir comment ont été entraînés les modèles qu'ils utilisent, sur quelles données.

³⁹ *Ibid.*

⁴⁰ *Ibid.*

⁴¹ *Ibid.*

⁴² *Ibid.*

⁴³ *Ibid.*

⁴⁴ *Ibid.*

⁴⁵ *Ibid.*

⁴⁶ *Ibid.*

6. IA

- Définition

”Par IA, on entend, dans une acception large et ouverte, la tentative de construire des machines et des systèmes capables de penser et d’agir rationnellement”⁴⁷

- Machine learning ”Le ML est un domaine de l’IA qui regroupe les méthodes, les processus et les techniques nécessaires pour rendre une machine ou un système informatique plus « intelligent ».”⁴⁸

”L’idée à la base du ML est qu’une machine peut résoudre des problèmes de la même manière que l’homme, en apprenant à partir d’« expériences » et d’exemples, sans être explicitement programmée pour la résolution spécifique du problème. Ainsi, au lieu d’implémenter un algorithme concret de résolution de problèmes dans une machine, les données sont transmises à un algorithme générique qui, par un « processus d’apprentissage », devient lui-même capable de résoudre les problèmes.”⁴⁹

il existe différentes méthodes de machine learning : Apprentissage supervisé Apprentissage non supervisé Apprentissage profond et réseaux neuronaux artificiels (deep learning)

Limites du machine learning : ”Une répartition arbitraire des systèmes est toutefois limitée dans la mesure où, d’une part, les systèmes entraînés ont souvent un domaine d’application spécifique et, d’autre part, leurs capacités sont fortement liées aux jeux de données utilisés. Les algorithmes entraînés avec différents jeux de données produisent des résultats différents.”⁵⁰

”La raison pour laquelle telle ou telle fonction s’impose pendant le processus d’apprentissage ne peut être reconstituée que rétrospectivement et favorise souvent des décisions curieuses de l’algorithme. L’un des principaux problèmes réside dans le fait que les systèmes ne font pas la distinction entre les corrélations et les causalités dans les ensembles de données. L’exemple d’une « recherche de vaches sur des images » illustre bien cette situation : les vaches se trouvent souvent dans des prairies ; le modèle commence alors à ajouter « prairie » (couleur, formes, modèles d’images) au concept « vache ». L’algorithme n’a donc appris qu’une corrélation sur la base d’une probabilité statistique (vache et pré), mais n’a pas compris les relations.”⁵¹

⁴⁷J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives »...

⁴⁸*Ibid.*

⁴⁹*Ibid.*

⁵⁰*Ibid.*

⁵¹*Ibid.*

Exemple de transcription basée sur le machine learning : Transkribus : peut aussi s'appliquer aux archives audiovisuelles.

Content-Based Image Retrieval : une des applications de la computer vision. Exemple de cas d'usage : Galt archives avec Archippanion⁵²

visual language models (VLMs) : combinaison d'algorithmes de computer vision et de LLMs pour : "create visual outputs based on input text, or textual outputs based on images or video" / "VLMs are able to do a variety of vision language tasks like captioning and summarization, image generation, search and retrieval, and object detection and segmentation" "However, there are still challenges with these emerging models like biases, hallucinations, and overgeneralizations as well as concerns of cost and environmental impact considering that VLMs combine two already complex AI architectures into one even more complicated tool "⁵³

⁵²K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

⁵³*Ibid.*

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visit  le 07/05/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visit  le 12/05/2026).
- ARNAB (Anurag), DEGHANI (Mostafa), HEIGOLD (Georg), SUN (Chen), LUĆ  (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), L POLD (Martin), THEILK S (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'acc s Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4–2 (juill. 2019), DOI : 10.22148/16.043.
- ASPERTI (Andrea), DESS  (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Indexation et archivage de contenus multim dias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visit  le 05/06/2026).
- BASSA STEGUY (Sidonie), *Le M dium, c'est La M moire : Archivages Du Document   l'Institut National de l'audiovisuel*, m m. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visit  le 13/05/2026).
- BERM S (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l'IA 2025 », dans *Conf rence Nationale Sur Les Applications de l'In-*

- telligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAT/IFTA *Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- INDEXATION : Définition de INDEXATION*, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).
- LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).
- Les secrets du traitement du langage naturel décryptés*, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).
- LIU (Haotian), LI (Chunyuan), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].
- LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Manan), HAMDY (Mohammed), *et al.*, *Bridging the Data Provenance Gap Across Text, Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].
- MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].

- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).
- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).
- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).
- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).
- Qu'est-ce que la conception de chatbot ? | IBM*, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).
- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605.

- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).
- Traitement du langage naturel : découvrez comment les machines lisent et écrivent*, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).
- VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*-hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-
640, DOI : 10.5220/0010387706330640.

Introduction

Mon introduction

Première partie

Une partie

Chapitre 1

Mon premier chapitre

Deuxième partie

Une autre partie

Conclusion

Annexe A

Le titre très long de la première
annexe

Table des matières

Résumé	i
Brouillon	iii
1. Problématique	iii
2. limites	vii
3. IA générale	viii
4. Experience utilisateur	viii
5. IA et cinéma	ix
6. IA	xiv
Remerciements	xvii
Introduction	xxv
I Une partie	1
1 Mon premier chapitre	3
II Une autre partie	5
Conclusion	7
A Titre court	9