

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Introduction

[L’indexation] est le fait de dresser un répertoire ou une liste, généralement alphabétique, des sujets traités, des noms cités dans un ouvrage, suivis des références aux pages, aux paragraphes (Rolland-Coul. 1969).¹

Cette citation décrit l’indexation comme un travail répétitif d’extraction d’informations directement à partir de la forme et du contenu d’un document. Ce document, ici textuel, contiendrait en lui-même ces informations dès le premier coup d’oeil d’après sa couverture, ses numéros de page, sa table des matières... Ce travail tel qu’il est décrit ici, est aujourd’hui facilement automatisable grâce à des modèles d’apprentissage automatique, capables de lire les documents et en d’extraire les métadonnées pertinentes à indexer pour ensuite les relier à des référentiels.

Or, d’autres types de documents et en particulier les archives audiovisuelles, qui constituent l’objet d’étude de ce mémoire de recherche, résistent à cette automatisation en raison de l’opacité de leur forme, conçue comme une boîte noire. En effet, contrairement à la plupart des supports textuels, les archives audiovisuelles ne révèlent, le plus souvent, rien à la lecture de leur contenant. Le contenu apparaît au moment de la projection. Ainsi, cette particularité formelle les rend en quelque sorte hermétiques aux pratique d’indexation telles que définies par Rolland-Coul et d’autant plus pour l’automatisation de ces pratiques.²

En effet, la mise en place d’une indexation automatisée pour ce type d’archives suppose que les modèles d’intelligence artificielle sachent lire l’enchaînement des images animées et la bande sonore, et en comprennent le langage du montage composé de séquences, de plans, de transitions... Ce langage spécifique n’est pas encore analysé ni compris de manière satisfaisante par les modèles d’intelligence artificielle, surtout dans le cadre de corpus patrimoniaux anciens aux sujets historiques, dont la qualité de l’image et du son est compromise.

¹*INDEXATION : Définition de INDEXATION*, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).

²Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

À cette difficulté d'extraire automatiquement des métadonnées depuis un contenu audiovisuel, une autre difficulté s'ajoute, celle de leur modélisation. En effet, dans un contexte de gestion patrimoniale des collections audiovisuelles, c'est le modèle FRBR qui est utilisé, issu du milieu des bibliothèques et élaboré par l'IFLA en 1998. IL propose une indexation à quatre niveaux : oeuvre, expression, manifestation, item. Cette indexation par niveaux permet de distinguer les métadonnées relevant de l'oeuvre intellectuelle, des métadonnées physique issues de son contenant. En 2016, la Fédération internationale des archives du film (FIAF) adapte le modèle aux archives audiovisuelles, en fusionnant le niveau Oeuvre/Expression et en ajoutant celui de Variante. Le FRBR n'est plus fondé sur un WEMI mais désormais sur un WVMI. En effet, une oeuvre cinématographique est nécessairement exprimée, mais comporte souvent des variantes : montage différent, changement de personnage, des dialogues. Or, si la FIAF propose un modèle nourri d'exemples et de cas d'application, le FRBR reste un modèle conceptuel flexible, repensé dépendamment du type de corpus indexé et qui diffère ainsi d'une institution à l'autre.

Ainsi, l'automatisation de l'indexation des archives audiovisuelles se heurte à une double difficulté, celle de la compréhension du langage cinématographique et d'un modèle d'indexation de données hautement dépendant du contexte dans lequel il est utilisés. Réalisé dans le cadre d'un stage de six mois au sein de l'entreprise Skinsoft, qui propose des solutions logicielles de gestion des collections, ce mémoire analyse les possibilités d'implémentation d'une indexation automatique au sein d'un espace de travail dédié à la gestion de collections audiovisuelles, fondé sur un modèle de données flexible.

Dans quelle mesure la variabilité institutionnelle et sémantique du modèle de données FRBR adapté aux archives audiovisuelles limite-t-elle la mise en place d'une indexation automatique pour ce type d'archives ?

Dans un premier temps, nous analyserons le modèle conceptuel du FRBR, un modèle de données issu des bibliothèques, et les modalités de son adaptation aux archive audiovisuelles. Nous verrons quelles questions pose l'implémentation de ce modèle dans le cadre d'une mise en place de l'indexation automatique. Dans un second temps nous proposerons une implémentation concrète d'indexation automatique des archives audiovisuelles au sein de ce modèle de données, dans le cadre du projet IA chez skinsoft. Nous analyserons plus spécifiquement la mise en place de la segmentation vidéo en séquences, une fonctionnalité priorisée dans la mise en place de l'indexation automatique, et sa compatibilité avec le FRBR. Enfin, nous analyserons les biais et limites techniques posés par les lacunes des données d'entraînement des modèles d'intelligence artificielles, difficilement adaptables au contexte patrimonial. Ces limites permettront d'orienter notre réflexion vers une indexation augmentée plutôt qu'automatisée, qui permettrait également d'améliorer la compréhension du FRBR.

Partie 1 - Indexer les archives audiovisuelles

I. Le FRBR, modèle d'indexation conçu pour les bibliothèques

- Un modèle entité-relation qui permet la description de concepts reliés entre eux. Avant ce modèle, une notice bibliographique correspondait à un objet physique. Il permet par ailleurs de mieux décrire les objets complexes comme les archives audiovisuelles.
- La structure WEMI, qui permet de décrire chaque niveau : Oeuvre, expression, manifestation, item. C'est une structure pensée pour des oeuvres textuelles, avec une verticalité limitée
- Les objectifs du FRBR sont les besoins utilisateurs. Il doit pouvoir répondre à quatre tâches utilisateurs : trouver, identifier, sélectionner, obtenir. Afin de remplir ces objectifs, une interface intuitive doit pouvoir accueillir le modèle FRBR.

II. Adapter le FRBR aux archives audiovisuelles

- Remodéliser le FRBR sur les caractéristiques complexes du médium cinématographique. L'exemple de S-Movies : un espace de travail pour la gestion des archives audiovisuelles, fondé sur une remodelisation du FRBR, adaptable selon les corpus de données
- L'inscription de différents types de corpus audiovisuels dans ce modèle repensé du FRBR : la cause d'une expérience utilisateur complexe et non-intuitive
- Le projet d'ajouter sur cette remodelisation du FRBR, une indexation augmentée et automatisée des collections audiovisuelles content...

III. Automatiser l'indexation des collections audiovisuelles basée sur le FRBR

- L'automatisation de l'indexation des archives audiovisuelles, motivée par les caractéristiques physiques de ce type de collection. En effet, les collections audiovisuelles sont indexées par leur contenu puisque leur support physique est qualifié de “boîte noire”. Leur indexation est donc un travail long et fastidieux.
- Les possibilités d'automatisation de l'indexation sur les collections audiovisuelles :
 - Analyse d'objets, (segmentation sémantique)
 - Analyse et transcription de texte
 - Analyse et transcription audio
 - Reconnaissance vocale et reconnaissance des locuteurs
 - Extraction d'entités nommées (lier ces analyses automatiques à des référentiels)
- Séquençage (segmentation temporelle) : une fonctionnalité spécifique aux archives audiovisuelles puisqu'il s'agit de comprendre les relations entre les plans pour pouvoir adéquatement les séquencer.
 - Faire de l'adaptation de cette automatisation au modèle FRBR dédiée aux archives audiovisuelles, un objectif

Partie 2 - Implémenter l'indexation automatique des archives audiovisuelles au sein d'une remodelisation du FRBR

IV. Le projet d'implémentation de l'IA chez Skinsoft (projet Skai), dont l'analyse vidéo est une composante majeure

- L'objectif du projet est de proposer différents moteurs IA spécialisés dans différentes tâches automatisées, entraînés sur des données ouvertes patrimoniales (POP, Joconde, Europeana). Cela permettrait aux modèles d'être adaptés au contexte patrimonial et de produire des métadonnées conformes aux normes bibliographiques. En revanche, ces bases de données contiennent majoritairement des archives textuelles et iconographiques.
- L'orientation donnée est de proposer des modèles force de proposition, et facilitateurs pour l'utilisateur : l'utilisateur doit pouvoir garder le contrôle sur ses données
- Parmi les moteurs IA en cours de développement : un moteur spécialisé pour l'analyse vidéo multimodale, adapté aux collections audiovisuelles. Une des composantes principales de ce moteur, issue d'une demande client, est la segmentation temporelle, c'est-à-dire le séquençage vidéo. L'objectif est, à partir des séquences produites, d'apporter des mots clés sur le contenu de l'image.

V. Séquençage et analyse d'un corpus audiovisuel (exemple du corpus de musée Albert Kahn)

- Séquençage des archives audiovisuelles en unités analysables, la première étape complexe d'un pipeline multimodal, dépendante du type de corpus analysé : la détection des coupures permet une classification des segments puis une vérification humaine.
- Combinaison des approches syntaxique et sémantique pour la segmentation de scènes : réseaux de neurones récurrents (RNN), réseaux de neurones convolutifs (CNN) ou Transformers ?
- L'adaptation de ces outils au corpus Albert Kahn, archives audiovisuelles des années 1920, documentaires et muettes : un séquençage facilement identifiable mais difficilement classifiable d'un point de vue sémantique.

VI. Reversement des métadonnées dans le modèle FRBR : dans quelle mesure les résultats produits peuvent-ils s'inscrire au sein de ce modèle d'indexation ?

- Cartographie du reversement des métadonnées : quels résultats pour quels niveaux du FRBR ? Cette cartographie dépend de l'utilisation du FRBR par l'institution concernée.
- Le reversement adéquat des métadonnées produites sur différents niveaux du FRBR ne peut se produire sans une interface navigable et intuitive entre ces différents niveaux. Une refonte est ainsi nécessaire pour la mise en place d'un reversement automatique. Actuellement, il existe une confusion des liens entre les niveaux, qui fait l'objet d'un projet de refonte dans l'espace de travail S-Movies.
- La mise en place d'une interface dans laquelle l'utilisateur pourrait valider les données produites, et décider de leur reversement de tel ou tel niveau du FRBR. Le moteur d'IA aurait alors bien ce rôle de "facilitateur" en proposant des solutions, tout en laissant le choix final à l'utilisateur. Cette solution pourrait rendre la compréhension du FRBR plus claire.

Partie 3 - Biais, limites et enjeux

VII. Les archives audiovisuelles comme données d'entraînement

- La sous-représentation des archives audiovisuelles anciennes dans les corpus d'entraînement. Il faudrait entraîner le modèle sur les corpus individuels de chaque institution pour pouvoir produire des résultats pertinents. L'inadaptation des corpus d'entraînement entraîne des biais d'indexation.
- le manque de temps et d'argent dédié à l'entraînement d'un modèle sur de multiples corpus. Quelles solutions ? Fine tuning, transfert learning, données synthétiques.
- Trouver le juste milieu entre un pipeline complexe multimodal qui demande beaucoup de puissance de calcul, et un pipeline léger mais moins performant. Ce choix dépend effectivement du type d'archives à indexer.

VIII. La difficulté d'adaptation au modèle de données, même avec un entraînement adéquat

- L'utilisation des niveaux du FRBR varie pour chaque institution, puisqu'elle dépend de la nature du corpus audiovisuel. Le modèle est donc interprété par des règles métiers internes et propres à chaque institution. Il faudrait ainsi entraîner un modèle IA sur ces règles métier liées à l'utilisation du FRBR. Par exemple, la collection du musée Albert Kahn s'adapte mal au FRBR puisqu'il s'agit d'archives documentaires, sans réelle diffusion. Un reversement automatique suppose que le modèle d'IA soit entraîné sur le contexte spécifique de chaque institution.
- S'impose alors la mise en place d'une indexation semi automatisée où l'utilisateur choisit, décide pour respecter la cohérence de l'usage du modèle de données.

IX. Vers une indexation augmentée plutôt qu'automatisée

- L'interactivité et le dialogue entre le modèle et l'utilisateur comme réponse aux biais et aux manques des données d'entraînement. Il faudrait rendre le processus transparent comme le préconise Skinsoft dans son projet Skai, en rendant accessible les données sur lesquelles le modèle a été entraîné, la réflexion effectuée...
- La transparence comme éthique de la transmission du savoir au public : la diffusion des connaissances est facilitée et augmentée par le modèle d'IA. La mise en place d'une interface de dialogue entre le modèle et l'utilisateur en est la condition essentielle

Conclusion

Le modèle de données et la manière dont il est modélisé dans un système de gestion des collections dirige l'implémentation de nouvelles fonctionnalités applicatives. Dans le cadre de ce mémoire de recherche, nous avons mesuré la complexité de la mise en place de l'indexation automatisée par IA, alors même que le modèle de données adapté aux collections audiovisuelles (FRBR) pose des difficultés de navigation et de compréhension documentaires pour les utilisateurs. L'analyse de l'adaptation du modèle FRBR aux archives audiovisuelles a notamment permis de pointer sa verticalité, conçue pour les notices bibliographiques, qui écarte les spécificités et les différences de corpus vidéo. En effet, nombreuses sont les institutions qui conservent des archives documentaires, non diffusées, issues de films amateurs ou expérimentaux, auxquelles les niveaux du FRBR restent mal adaptés. Ainsi, l'utilisation du FRBR et la navigation entre ses différents niveaux dépend de la nature du corpus audiovisuel et est, de fait, hétérogène. Dans ce contexte, le projet de la mise en place d'une indexation automatique des archives audiovisuelles multimodale pose question.

Dans le cadre du projet IA chez Skinsoft, nous avons tenté de proposer la mise en place d'un pipeline d'indexation automatique au sein de l'espace de travail S-Movies. Nous nous sommes toutefois confrontés à la complexité du reversement des métadonnées produites au sein du modèle FRBR, au delà des difficultés posées par un corpus audiovisuel historique et vieillissant.

Dès lors, nous en avons conclu que la modélisation du FRBR selon le contexte institutionnel constitue un frein à la mise en place de l'indexation automatique, puisqu'elle repose sur des règles métier d'usage selon le corpus indexé. La refonte de la navigation entre les niveaux du FRBR constitue alors un tournant essentiel et nécessaire à la mise en place d'une telle automatisation, permettant aux modèles d'apprentissage et à l'utilisateur de mieux comprendre les liens entre les différents niveaux d'indexation.

Finalement, il s'agit de centrer notre approche sur l'expérience utilisateur en raison des difficultés d'entraîner un modèle d'intelligence artificielle adapté aux corpus audiovisuels et au modèle de données associé. Nous proposons alors la mise en place d'une aide à l'indexation, d'une indexation augmentée, qui suggérerait à l'utilisateur des choix en les explicitant, sans

pour autant automatiser l'ensemble du processus. Par ses choix de validation, l'utilisateur entraînerait lui-même le modèle à la fois sur les corpus utilisés et à la fois sur l'utilisation du modèle FRBR. Une telle interface d'échange pourrait permettre de rendre l'indexation plus efficace et d'améliorer la compréhension des liens entre les niveaux d'indexation du FRBR.

1. IE FRBR, modèle d'indexation conçu pour les bibliothèques

Commençons par définir le modèle de données qu'est le FRBR. Le FRBR, Functional Requirements for Bibliographic Records, est un modèle conceptuel de données bibliographiques élaboré par l'IFLA de 1992 à 1996.³ Ce modèle établit quatre niveaux d'informations de production catalographique portant sur le document : ses caractéristiques individuelles en tant qu'exemplaire (item), les caractéristiques de sa publication (manifestation), les caractéristiques de son contenu intellectuel (expression), et les caractéristiques de la création abstraite à laquelle il se rattache (oeuvre).⁴ Ce modèle prétend répondre à quatre besoins utilisateur : trouver, identifier, sélectionner, obtenir.⁵ Ainsi, l'utilisateur localise la ressource, identifie si elle correspond à ce qu'il cherche, sélectionne la ressource selon ses besoins, et accède finalement à la ressource. Barbara Tillett ajoute un besoin éventuel, celui de pouvoir relier les ressources trouvées par l'utilisateur à d'autres ressources pertinentes ou qui lui sont reliées par le FRBR.⁶

À ces entités du premier groupe du FRBR (oeuvre, expression, manifestation, item), s'ajoutent des entités de deuxième groupe : personnes et collectivités, qui expriment le rôle joué par ces entités avec une ou plusieurs entités du premier groupe.⁷ Ce modèle entité-relation permet donc de mieux identifier le rôle des entités créatrices de chaque niveau bibliographique. Les entités du troisième groupe sont les sujets des oeuvres, pouvant correspondre à des concepts, objets, événements ou lieux. Les sujets peuvent également prendre la forme d'entités des premier et deuxième groupes.⁸

Aujourd'hui, plus utilisé par les bibliothèques

justification de la clarté du modèle FRBR pour la mise en place d'un modèle automatique :

impact de l'indexation automatique sur les données : "Comme le repérage d'entités visuelles demande énormément d'informations locales, les bases de données d'indexation constituées à partir de la reconnaissance des entités sont conséquentes (elles peuvent avoir une taille supérieure à celle des vidéos elles-mêmes) et font l'objet de recherches au sein de l'établissement pour en optimiser les temps de calcul.

Dans ce contexte, la qualité et la modélisation des données jouent un rôle fondamental

³zotero-item-651.

⁴zotero-item-651.

⁵Tillett, Barbara B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.

⁶*Ibid.*

⁷IFLA Study Group on the Functional Requirements for Bibliographic Records, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).

⁸*Ibid.*

car c'est sur les bases de données que les algorithmes sont entraînés.”⁹

Si nous définissons ici le FRBR comme un modèle de données, il est remis en question comme tel, en raison de ses entités trop ”génériques”.¹⁰ Ainsi, il ne peut pas être implémenté tel quel et suppose d'être redéfini en tant que modèle à chaque implémentation. En revanche, il devrait toujours servir les tâches utilisateurs que nous avons défini ci-dessus, en plaçant la navigation comme véritable besoin et non plus comme une tâche annexe.

les FRBR ne disent pas comment structurer les éléments de données ni comment les afficher de manière à ce que la structure en soit comprise rien qu'à la lecture de la description ; les FRBR fournissent un cadre intellectuel pour une typologisation des éléments de données et pour en montrer les interrelations de notice à notice (par exemple, 4 instances de Manifestation peuvent matérialiser seulement 2 instances d'Expression qui réalisent une seule instance d'œuvre : analyse dont ne rendent nullement compte les ISBD mais qui est fondamentale dans l'organisation du savoir et dans la définition de moyens rationnels d'afficher les résultats d'une recherche dans nos catalogues).¹¹

Cependant, que signifie au juste l'expression « implémenter les FRBR » ? Je viens de dire à l'instant que les FRBR n'étaient pas un modèle de données, comment pourraient-ils donc être « implémentés » ? Au mieux, en concevant un modèle de données intermédiaire, fondé sur les FRBR ; au pire, en prenant les FRBR pour un modèle de données ; dans tous les cas de figure, en « mappant » soit un format existant vers les FRBR, soit les FRBR vers un nouveau format.¹²

Tout « contenu » est-il une « Œuvre » ?¹³

⁹Eleonora Moiraghi, *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.

¹⁰Patrick Boeuf, « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/unauthorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).

¹¹*Ibid.*

¹²*Ibid.*

¹³*Ibid.*

2. Contexte skinsoft

- L'entreprise

Skinsoft propose des solutions logicielles full web principalement à destination d'institutions patrimoniales.

L'application générale est divisée en différents espaces de travail, chacun spécifique à un type de collection patriculier. Par exemple, un musée aura un module S-museum, un musée d'histoire naturelle aura un module Skin Specimen, une cinémathèque aura un module S-movies. Ces espaces de travail sont eux-mêmes configurables et adaptables en fonction des pratiques métiers de l'institution. Skinsoft peut ainsi paramétrer l'utilisation de certains champs, de certains types de notices sur demande de l'utilisateur. En amont de la livraison de l'application chez un client, un mapping est effectué entre les champs d'indexation et de catalogage utilisés par le client dans l'ancienne base de données, et les champs que propose skinsoft dans son application. Même si les champs sont configurables, une adaptation et une mise à niveau doit s'effectuer. C'est d'ailleurs le point le plus complexe à gérer en termes de relations clients. Le client doit en effet accepter d'abandonner certaines pratiques pour pouvoir adopter un nouveau logiciel. Ce processus est fastidieux et demande de nombreuses formations pour accompagner les équipes métiers.

En un mot, l'idée de l'application proposée par skinsoft est celle de la configurabilité et de l'adaptabilité. C'est ce mot d'ordre qui pousse l'entreprise à repenser son logiciel à chaque nouveau contrat, pour être le plus proche possible des pratiques métiers de chaque institution et des différentes attentes.

Ce qui caractérise l'application de skinsoft, davantage qu'une simple édition de données, c'est surtout la recherche de données et la flexibilité de la recherche de données.

- mise en place de l'IA

La gestion de collections culturelles est un métier très normé, régit par des normes professionnelles pour favoriser le partage des connaissances. L'IA émergente devra être enstraîné sur ces normes professionnelles.

Avec l'arrivée de l'IA dans le monde du travail et sa remise en question de la place humaine dans certaines pratiques professionnelles qui seraient automatisables, une entreprise dédiée à l'amélioration des pratiques métier en contexte patrimonial et culturel comme skinsoft souhaite l'implémenter.

Cette volonté d'implémenter l'IA s'inscrit dans l'appel à projets "France 2030" qui couvre notamment la maitrise des technologies numériques et le "déploiement de l'inno-

vation”¹⁴. Ce projets finance des initiatives à l’intersection de la culture, du numérique et de l’IA.

L’une des caractéristiques majeures de l’application, nous l’avons dit, est sa flexibilité et son adaptabilité. La mise en place de l’IA permettrait de mettre cette adaptabilité en place plus efficacement et à plus large échelle. Automatiser la migration de données, le paramétrage de l’application, la navigation dans l’application permettrait à l’entreprise de satisfaire ses clients plus rapidement et de gérer ainsi plusieurs contrats à la fois. Mais l’IA est-elle attendue côté client ?

À quels besoins concrets chez les clients skinsoft l’IA répond-elle ? aussi, on parle d’IA mais qu’est ce que ça implique comme notions et outils concrètement ? (voir IAgenerale.tex)

- améliorer l’expérience client dans l’application - améliorer l’efficacité de l’application
- augmenter l’efficacité des pratiques métier - donner accès plus rapidement et à un plus grand nombre d’archives - promouvoir une meilleur organisation interne

En effet, la question du besoin est centrale, pour une utilisation de l’IA éthique, comme le mentionne le ministère de la culture : ” il ne s’agit pas d’utiliser l’IA par défaut, mais d’abord d’examiner le besoin à couvrir et de vérifier la capacité des systèmes d’IA à satisfaire ce besoin dans des conditions optimales ; le cas échéant, de favoriser des alternatives moins consommatrices que l’IA si elles sont suffisantes à répondre au besoin”¹⁵.

L’objectif est double pour une entreprise comme skinsoft : La mise ne place de l’IA dans l’application permettrait d’autonomiser les institutions sur leur usage du logiciel et d’être plus productifs dans l’indexation de leurs collections. Ainsi, les équipes skinsoft seraient moins sollicitées pour des problèmes liés à l’usage de l’application qui pourraient être réglés par un modèle de langage. La mise en place d’une barre de recherche fondée sur le langage naturel découle de ces objectifs, ainsi que la mise en place d’un chatbot, deux idées déjà amorcées et au coeur des discussions chez Skinsoft.

Les fonctionnalités que skinsoft souhaite mettre en place, liées la vidéo : composants de l’image avec proposition d’indexation, transcription du son et proposition d’indexation sujets, reconnaissance vocale et proposition d’indexation musique, personnage,

¹⁴France 2030 : un plan d’investissement pour la France / *economie.gouv.fr*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).

¹⁵La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).

ambiance. Important : la mise en place de l'IA se fait par l'identification de données ouvertes qui peuvent nourrir le moteur. Le projet est de paramétrer et d'entraîner plusieurs moteurs : socle de savoir. le moteur doit il être entraîné sur des données publiques, ou entraîné complémentirement par des données de l'institution sur laquelle il travaille. il faut que les clients acceptent : contrat spécifique. (limites) ce que veut skinsoft : création de contenus structurés, recommandation de contenus structurés, assistance à l'usage, force de proposition créative, détection... choix d'appui sur des données produites directement par des institutions culturelles. utiliser exclusivement des sources ouvertes. pour les images : entraînement sur des images disponibles sous licence ouverte : european, POP + textes de lois, méthodologie des gestion des collections, thesaurus, normes de catalogage... Restaurant Caspian, Rue des Entrepreneurs, Paris Il faut l'accord client et les données d'un seul client ne sont pas suffisantes. l'indexation est un composant parmi d'autres du projet IA chez skinsoft, avec tout ce qui va être mis en place également. Le moteur IA doit jouer le rôle de prescripteur, force de proposition, et de facilitateur. (attention : mots exacts employés par skinsoft). Il revient à l'utilisateur de retenir tout ou une partie de la proposition faite par l'IA.

Mais d'autres besoins métier sont susceptibles d'être assistés par IA, au delà de la recherche et de questionnements d'usage. En effet, skinsoft souhaiterait mettre en place une automatisation de l'indexation, permettant ainsi d'une part d'alléger la charge de travail des équipes au sein d'une institution patrimoniale, et d'autre part, de donner accès à davantage de documents pour le grand public.

Faire le lien avec l'indexation des archives audiovisuelles : pas les mêmes défis d'indexation pour une collection audiovisuelles : lié à la spécificité de ces documents "boîtes noires"

- la tension privé public Si skinsoft est une entreprise privée, elle adopte en revanche une posture publique culturelle, celle de ses clients, afin de répondre à leurs besoins. La mise en place de l'IA est pensée pour améliorer les logiques patrimoniales quotidiennes telles que l'indexation, le catalogage, le classement, la gestion de projet... Ces pratiques ne sont pas liées à des objectifs de rentabilité et de productivité concurrentiels comme c'est le cas d'entreprises privées. Ainsi, skinsoft fait face à une tension : l'entreprise s'affiche comme une entreprise innovante en matière de technologies numériques, alors même que ses clients sont cantonnés à des pratiques presque ancestrales, celle de la gestion de collections.

Au sein de la mise en place et de l'arrivée de l'IA dans un logiciel de gestion des collections, il faut ainsi se questionner sur sa pertinence. Ces nouvelles fonctionnalités

sont-elles attendues ? Les institutions sont-elles prêtes à utiliser l'IA au quotidien pour gérer leur collection ? pour les décrire ? pour les rendre accessible au public ?

En 2025, le ministère de la culture identifie "l'enrichissement de la connaissance et des savoirs" comme un usage potentiel de l'IA en secteur culturel avec par exemple "de l'aide au catalogage, à l'indexation automatique des collections, au tri et au classement des documents et données destinés à être archivés, à la transcription des textes manuscrits, à la reconnaissance de formes, à la diffusion et à la valorisation des contenus culturels et patrimoniaux quel que soit leur format (image, son...)".¹⁶

Les limites de l'IA identifiées, à savoir l'hallucination, la marge d'erreur, les biais culturels, sont ici restreintes puisque les outils d'IA seraient mis à disposition auprès de professionnels, et non au grand public directement. Certes, ces outils IA permettraient à terme, comme l'indexation automatique, de rendre les collections accessibles au public, mais seulement après vérification d'un professionnel attitré.

Les professionnels pourraient mettre à profit l'IA pour un double objectif : la préservation et l'accessibilité des collections.¹⁷ C'est exactement le cas pour l'indexation automatique.

- S-movies

les collections de film posent des défis spécifiques pour l'implémentation de l'IA, et en même temps, ce serait pour ces collections que l'IA serait pertinente à mettre en place : un défi documentaire WEMI opacité de la hiérarchisation des niveaux refonte de la manière d'indexer dans l'application pour les collections de films : un des enjeux actuels : améliorer l'expérience utilisateur.

notes depuis la doc interne : l'IA devra permettre de proposer une indexation pertinente des images par rapport au contenu des métadonnées de chaque fichier et à l'analyse de la représentation de cette image. (reversement des métadonnées). Reconnaissance des types d'objets, extraction des détails visuels, Indexer les vidéos ou enregistrements sonores par l'analyse du texte transcrit, indexer les vidéos par l'analyse de l'image, indexer les vidéos ou enregistrements sonores par la reconnaissance vocale, reconnaissance de textes, lien vers les référentiels. transcription automatique : convertir les archives orales en texte searchable et les indexer (termes référentiels, autorités, lieux), pointage vers des éléments de référentiels existants (thésaurus). par exemple : citation d'un au-

¹⁶ *Ibid.*

¹⁷ L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).

teur dans un texte OCR et lien vers la fiche d'auteur. Indexation temporelle, ce qui nous intéresse ici : créer des marqueurs automatiques dans les vidéos : changement de scènes, apparition d'objets. séquençage média Reconnaissance de voix : identifier les intervenants dans les itv extraction de métadonnées : analyser le contenu sonore (musique, ambiance, silences) détectin d'incohérence des données : doublons...

3. S-Movies

Skinsoft propose la gestion de collections cinématographiques, avec un espace de travail dédié, S-Movies. C'est au sein de cet espace que l'entreprise souhaite mettre en place l'indexation automatique des items films.

Cet espace de travail repose sur la description des collections en différents niveaux du FRBR comme recommandé par la Fédération Internationale des Archives du Film. En effet, la FIAF recommande quatre niveaux de description hiérarchique pour le catalogage des films : l'oeuvre/expression, qui correspond à l'idée de l'oeuvre originale, la variante, qui est, comme son nom l'indique, une version différente de l'oeuvre originale, la manifestation, qui correspond à la diffusion de l'oeuvre, sa sortie, l'item, qui correspond à l'exemplaire physique ou numérique de l'oeuvre. Une oeuvre peut avoir plusieurs diffusion, et ainsi être liée à plusieurs manifestations. De plus, la collection peut compter plusieurs exemplaires physiques ou numériques d'une seule oeuvre.¹⁸

Ainsi pour une même oeuvre, il peut exister diverses diffusions/manifestations, et des collections aux formes multiples, au format pellicule, DVD, numérique... Une oeuvre originale peut elle-même subir des variantes : versions restaurées, montages différents, doublages et dialogues différents. Les niveaux du FRBR recommandés par la FIAF permettent alors de distinguer ces niveaux et les différences qui existent pour chacun de ces niveaux afin de mieux les décrire. Ce mode de description permet de séparer la description intellectuelle de la description matérielle.

Toutefois, ce découpage en différents niveaux n'est pas toujours intuitif ni facilement déployable dans une application de gestion de collections. Les termes films et copies employés entre professionnels sont remplacés par des termes hiérarchiques opaques tels que manifestation, non spécifique à l'audiovisuel. (Ouvre non plus n'est pas spécifique à l'audiovisuel) Il n'est pas toujours évident de distinguer la variante d'une oeuvre. Où se trouve la limite entre l'oeuvre et sa variante ? La FIAF donne des pistes et des cas d'application mais ça ne couvre pas la complexité des collections réelle.

Une manifestation peut être par exemple une pré diffusion, une distribution en salles, une télédiffusion, une diffusion en ligne.¹⁹ Toutefois, les institutions qui conservent des archives audiovisuelles non diffusées, qui ne sont pas vraiment des oeuvres mais seulement des rushes documentaires par exemple, s'adaptent très mal au FRBR. La description se fait généralement au niveau de l'item.

De plus, le modèle FRBR a été conçu pour les bibliothèques au départ. Ainsi, le terme

¹⁸FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).

¹⁹*Ibid.*

de "manifestation" par exemple paraît opaque appliqué à des collections audiovisuelles. La FIAF tente d'adapter ce modèle aux collections audiovisuelles dans son manuel, mais les frontières entre les niveaux peuvent parfois être fines. Chaque institution choisit les niveaux qu'elle souhaite mettre en place au sein de ses pratiques de catalogage. Chez les clients de skinsoft, le niveau variante, par exemple reste peu utilisé puisque la frontière entre une oeuvre et sa variante sont complexes à définir.

Au sein de l'application, dans l'espace S-Movies, la hiérarchisation n'est pas intuitive.

Lien avec l'indexation : crée des éléments qui se rattacheront à l'oeuvre et à l'item. Les métadonnées seront rattachées à l'item numérique (cf spécification sur item/media).

Certains clients chez Skinsoft ont déjà une pratique manuelle de segmentation de leurs séquences audiovisuelles. Une institution en particulier qui préserve des archives films muettes documentaires, possède déjà des marqueurs de séparation de séquences avec les timecodes correspondant dans sa base de données. Dans ce cas, la segmentation automatique viendrait être entraînée sur ces corpus et pourrait remplacer cette pratique manuelle pour les archives non annotées.

Problématique : les métadonnées issues de la segmentation automatique seraient liées à l'item numérique, segmenté en plusieurs médias qui correspondraient chacun à des séquences. Mais ces métadonnées décrivent le contenu sémantique de l'oeuvre. Les métadonnées doivent ainsi pouvoir être reversées sur la notice de l'oeuvre.

Avant de pouvoir mettre en place la segmentation automatique, beaucoup de problèmes résident dans les entremêlements de liens entre les niveaux hiérarchiques du FRBR. Il faudrait pouvoir régler les confusions sur les liens entre les notices dans l'application avant de mettre en place une autre fonctionnalité. Sans avoir l'ambition de régler ces problèmes, nous proposerons ici toutefois une mise en place d'un processus de segmentation adapté et conforme au modèle FRBR.

4. Problématique

- Sur la compréhension du cinéma par l'IA :

Ce qui est encore en cours de développement pour les outils actuellement = compréhension du langage cinématographique (montage, narration), analyse des ambiances et émotions, détection d'œuvres musicales.

Incapacité des machines à comprendre le langage ciné pour l'instant et à l'analyser correctement : pourquoi ?

Il n'existe pas de solution tout en un

L'image animée regroupe bcp de choses.

- Interface et l'expérience utilisateur :

Comment combiner performance technique et expérience utilisateur au sein de l'application avec l'implémentation de l'IA ?

Implémentation de deux outils de recherche assistée dans l'application : comment guider l'utilisateur vers l'outil qu'il cherche ?

Faire une interface utilisateur qui augmente la productivité et l'interactivité mais en même temps qui reste adaptée aux institutions culturelles qui n'ont pas forcément d'objectifs de rendement et de productivité comme des entreprises privées. Trouver la limite. Ne pas en faire une appli de marketing.

Tensions entre besoins utilisateurs musée / et une logique de productivité d'entreprise privée vers laquelle se tourne de plus en plus l'application : tableau de bord, intelligence artificielle.

Améliorer l'interface et l'expérience utilisateur est ce qui fait prospérer skinsoft et ce qui la démarque de ses concurrents.

- Migration de données :

Décalage entre ce que le client veut pour ses données, et ce que skin soft est capable de faire. Un changement de logiciel induit forcément une modification de la saisie des données, même si l'application est entièrement paramétrable. Décalage entre ce que l'institution attend et ce que skinsoft peut faire conformément aux standards documentaires, au temps qu'ils peuvent y consacrer et aux limites de l'application et de l'interface.

Difficulté de paramétrer l'application en fonction de la manière de saisir les données propres à chaque institution, des thésaurus utilisés...

L'application et les paramétrages évoluent presque à chaque nouveau client et devient plus malléable.

- Sur l'indexation :

La génération de résumé sur une archive audiovisuelle prévue par skin soft se fait de quelle façon, à partir de quelles données ?

Résumé à partir de notices déjà constituées sur l'archives en question

Extraction des éléments dans l'image : autorités

Extraction d'éléments dans le son

Comment le NLP transforme les pratiques d'indexation ? Lien entre les deux ?

Pour l'instant, il existe des modèles qui permettent de détecter la séparation entre les plans grâce au changement de position des personnages, changement de lumières... Mais la détection du changement de séquences se situe à un niveau supplémentaire de compréhension du langage cinématographique. Cela suppose de comprendre ce qu'est une séquence (combinaison d'un changement temporel et spatial). Comment améliorer les modèles qui détectent les changements de plans pour leur faire comprendre les changements de séquences ? Surtout sur des archives audiovisuelles où il se passe peu de choses dans l'image. La plupart des cas d'usages vus et lus sont entraînés sur des séquences de télévision par exemple, un langage "classique et normé" qui est toujours le même. Pour les archives très anciennes comme celles d'Albert Kahn, il n'y a pas de coupures ou très peu, les plans sont fixes, les sujets sont généralement loin de la caméra. Est-ce que c'est plus facile à entraîner ? Comment entraîner un modèle qui puisse analyser des vidéos à la fois très similaires et très différentes en termes de langage cinématographique ?

Les archives audiovisuelles nécessitent une indexation de contenu : extraction d'information à partir de ce qui se trouve dans l'image

Pour les archives papier, l'indexation automatique des archives nées numériques et les archives numérisées est différente. Pour les archives nées numériques, il existe déjà un produit numérique : pdf par exemple ou document texte. Pour une archive numérisée, il faut produire ce dérivé pour y appliquer de la reconnaissance d'entités, de caractères... Est-ce la même chose pour les archives audiovisuelles ? Ou ça ne change rien ?

Permettre l'annotation vidéo : pour qui ? quand ? comment ?

L'un des problèmes sur la mise en place de l'IA dans les institutions patrimoniales est un manque de moyens financiers et de savoir-faire technique. Les institutions sont

souvent limitées à choisir des outils déjà entraînés et constitués à partir de données souvent différentes et éloignées des archives historiques complexes et hétérogènes (whisper, MMS...). Cela donne une indexation imprécise, risquée et pas forcément performante. Skinsoft est une entreprise innovante au service de ces institutions, cela peut être son rôle de proposer aux musées des outils entraînés à partir de données historiques et donc plus performants pour des collections patrimoniales. ou alors récupérer des modèles et les réentraîner.

Définition de l'indexation documentaire

- **Indexation documentaire (Sumominen, Husson, Reignier)**

définition de l'indexation : "Le fait de dresser un répertoire ou une liste, généralement alphabétique, des sujets traités, des noms cités dans un ouvrage, suivis des références aux pages, aux paragraphes" (Rolland-Coul. 1969).²⁰

autre définition : Selon l'AFNOR, l'indexation est la "représentation par les éléments d'un langage documentaire ou naturel, des notions résultant de l'analyse du contenu d'un document en vue d'en faciliter la recherche"²¹

définition de l'indexation : "L'indexation est cette technique consistant à caractériser le contenu d'un document et l'information qu'il détient de manière à le retrouver quand on effectue des recherches sur l'un des sujets dont il traite. La difficulté est donc de savoir caractériser et représenter l'information documentaire pour qu'il soit aisé de la mettre en rapport avec des sujets d'investigation. Mise en rapport d'une requête et d'un contenu représenté et synthétisé, l'indexation permet de s'orienter dans la masse des documents et d'organiser ses connaissances. L'indexation appartient donc à ce qu'on appelle depuis quelques années les techniques intellectuelles Indexation et archivage de contenus multimédias"²²

Contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ». ²³ (aussi placé dans IAcinema)

- **Archives audiovisuelles (Bassaïsteguy (INA), Rattinger, Le Ber, Attard)**
- **IA et vision par ordinateur (Arnab (ViViT), Gong (AST), Trojahn, Yuan)**

²⁰INDEXATION : Définition de INDEXATION...

²¹Pierre Husson, « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RETIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).

²²B. Bachimont, *Indexation et archivage de contenus multimédias...*

²³*Ibid.*

5. analyse automatique de l'image

Objet de cette sous partie : Avant de pouvoir indexer, il faut pouvoir produire une analyse automatique de l'image animée.

6. Indexation automatique

- Pourquoi automatiser l'indexation ?

Pour justifier l'indexation automatique : « Les bibliothèques gèrent un grand nombre de métadonnées, pour différents types de documents. Le plus souvent, ces documents sont indexés à l'aide de mots sujets sélectionnés au sein d'un vocabulaire contrôlé, afin d'être recherchés plus tard. L'indexation manuelle de documents est un travail intellectuel très consommateur de temps. »²⁴

« Incomplete descriptive metadata often hinder their access by the public.²⁵ Légitime la mise en place d'une indexation automatique car elle servirait à compléter des métadonnées manquantes et donc à rendre accès les collections plus facilement au public. Le manque de métadonnées et d'informations, d'indexation est souvent un frein lors de la publication en ligne, de l'accès au public (car pas de contexte : risque de contradictions historiques).

« Les systèmes d'indexation automatique suivent généralement un processus dans lequel les documents textuels sont, dans un premier temps, "préparés" [...] les documents sont convertis dans une représentation vectorielle de leur fréquence d'apparition, ce qui, à l'aide d'un algorithme, permet d'établir des comparaisons entre les mots-sujets utilisés. »²⁶ Pour les images : comparaison des objets. La différence de médium modifie les outils utilisés et la manière de les utiliser pour en tirer des infos.

« Les algorithmes d'indexation automatique se répartissent selon deux types d'approche : lexicale et associative. »²⁷

Pour les archives audiovisuelles, des processus techniques s'ajoutent : extraction d'entités depuis l'image, extraction d'entités depuis le son. La forme du médium cinématographique crée une opacité et une complexité pour l'instauration de pipeline algorithmiques.

- Pipeline

Mise en place d'une pipeline IA : Ce sont plusieurs outils combinés qui créent l'indexation : analyse audio avec l'ASR et la segmentation, analyse de l'image avec la

²⁴Osmo Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605, p. 21.

²⁵Peter Sullivan et Muhammad Abdul-Mageed, *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].

²⁶O. Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande »..., p. 21.

²⁷*Ibid.*

computer vision et shot detection, le NLP avec le NER et term extraction. Cette pipeline permet d'extraire des métadonnées en lien avec des vocabulaires contrôlés et ainsi d'indexer les images. « Each tool specializes in a single task, and is brought together with other tools in pipelines. Technologies can be layered upon one another in order to more meaningfully annotate content. »²⁸

Implémentation d'une combinaison d'outils différents pour l'indexation : "La combinaison de différents outils et leur intégration dans des environnements logiciels existants est un sujet important, pour lequel il existe désormais un large éventail de solutions, souvent open source"²⁹

- Outils

Trint : automatic speech recognition
FasterR CNN et Farec CNN : face detection models
YOLO : outil opensource de détection d'objets et d'identification

- Cas d'indexation

The vanderbilt university television news archive : ils utilisent Trint pour transcrire les discours et engagent des étudiants pour corriger les transcriptions sur l'interface de l'outil Trint :

"students also note the start and stop time of segments, and write relevant on-screen information such as names into the transcript. Each 30-minute program takes one hour of student worker time to correct. When the transcript is complete, it is exported to Amazon's Named Entity Recognition service on the cloud, where information such as person, location, or topic is pulled out. That information is then brought back into the workflow with scripts written in Python that turn the information into individual titles for each news segment. Additional information such as reporter or location are added to database fields, and duplicate records are kept in PBCore for future use when more of the information from the Named Entity Recognition system might be stored in the database."³⁰

- Points d'attention la qualité des images est absolument primordiale et déterminante dans la mise en place d'un pipeline d'indexation automatique : "La question de la qualité

²⁸ *AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).

²⁹ Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

³⁰ *Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).

des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle".³¹

³¹Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

7. indexation iconographique

- Définition « L'indexation iconographique consiste à décrire le contenu des images à l'aide de descripteurs afin de faciliter l'accès aux œuvres, sans cependant dispenser sa consultation. »³²

- Outils

"When it comes to processing image-based records in archives, supervised learning models can be helpful for identification and classification, while unsupervised learning models are best suited for processing large amounts of data for creating generic descriptions, and highlighting possible connections between records."³³

- cas d'usage

Computer-Aided Metadata generation for Photo Archives Initiative (CAMPI)³⁴ production de tags sur des images et recommandation d'images similaires

détection d'objets

YOLO (you only look once) Algorithme qui utilise CNNs pour entourer des objets dans des images et les classer dans des catégories il s'agit d'un single shot object detector : il se base sur une seule analyse de l'image dans sa globalité facial recognition, scene analysis, object tracking³⁵

two shot objects detector : multiple image reviews Exemple : Mask Region-based CNN (R-CNN) algorithm. "uses deep neural networks to identify regions of interest in the photograph and build boxes around objects found throughout the image"³⁶ Cette manière de faire est appelée "semantic segmentation" : "identifies semantic objects without specifying how many instances of that object are present in the image"³⁷ Par exemple, s'il y a 5 personnes dans une image, la segmentation sémantique les identifie comme un même objet sémantique dans l'image.

Instance segmentation : "identifies all the semantic objects in an image and segments them into specific instances to accurately distinguish between each object of a similar semantic category" (c'est ce que fait Mask RCNN)³⁸

Line segment detection and description

³²P. Husson, « Indexation iconographique et intelligence artificielle... », p. 3.

³³Kaila Fewster et Richard Arias, « Teachable AI for the Archival Professions – Module 4 : » ().

³⁴*Ibid.*

³⁵*Ibid.*

³⁶*Ibid.*

³⁷*Ibid.*

³⁸*Ibid.*

”« As a typical two-dimensional (2D) low-level image feature, line segments contain more structural and geometric features about the scene than points, as shown in Fig. 1. In addition, they have the advantage of compact data expression and strong orientation constraints, and can completely support multiview geometry theory in both 2D and three-dimensional (3D) spaces, compared with edges. »³⁹ L’analyse par lignes surpasse l’analyse par pixel/points, car elle permet une analyse géométrique de l’image et une meilleur classification de lieux par exemple : décor, perspective, architectures. L’analyse par segment permet aussi de réduire la taille de calcul par rapport à une analyse de contours de l’image par exemple : un segment est relié par deux points donc prend moins de place.

« Gradient grouping-based methods [...] lack adequate semantic and global feature constraints, the region candidates are easily interrupted by noise and small occlusion. [...] Learning-based approaches tend to detect semantically meaningful line segments, such as those in indoor scenarios. In addition, similar to point features, they struggle to detect highly accurate line segments. One reason lies in that images are often downsized during training. »⁴⁰

Gallica.pix

41

- Indexation par le contenu sémantique ”L’indexation par le contenu sémantique, ne vise pas à rechercher des notions visuelles (aussi définies comme « bas niveau ») mais à détecter automatiquement des concepts (aussi définis comme « haut niveau ») pour la création d’un index sémantique. Cela permet l’étiquetage soit d’une image entière, soit d’une portion de l’image et ces étiquettes peuvent être ensuite incluses dans une ontologie qui permet de faire des inférences ou de désambiguïser.”⁴² exemple le plus parlant aujourd’hui : ImageNet

Autres outils d’indexation sémantique des images : IBM Watson, réseau ResNet SSD pour la reconnaissance des visages. classification des genres d’images : CNN, modèle inception v3 (tensorflow) extraction de thèmes : Topic modeling (latent dirichlet allocation)

³⁹Xinyu Lin, Yingjie Zhou, Yipeng Liu et Ce Zhu, *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].

⁴⁰*Ibid.*

⁴¹E. Moiraghi, *Explorer des corpus d’images. L’IA au service du patrimoine...*

⁴²*Ibid.*

8. indexation audio

- Indexation audio

automatic speech recognition and speech translation

Selon une expérimentation de Sullivan et Abdul-Mageed en 2025 sur des archives de l'unesco, Whisper V3 est le modèle le plus convaincant pour identifier la langue dans une piste audio (LID), avec 91,13 pourcent de précision. En revanche, MMS (massively multilingual speech) de Meta obtient une précision de seulement 11 pourcent. Cela s'explique car MMS a été entraîné sur des données trop homogènes (enregistrements de la bible).⁴³

les embedding de locuteurs (représentations vectorielles de voix) se dégradent dans deux cas : si un locuteur parle plusieurs langues différentes, ce sont plusieurs locuteurs qui sont reconnus. Si un long moment sépare deux enregistrements d'un même locuteur, il est également interprété comme deux personnes différentes. « Speaker embeddings remain a fragile component of speech processing pipelines that is prone to biases related to the channel, age, and language. »⁴⁴

⁴³P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

⁴⁴*Ibid.*

9. notions IA

- Définition

”Par IA, on entend, dans une acception large et ouverte, la tentative de construire des machines et des systèmes capables de penser et d’agir rationnellement”⁴⁵ donc à terme, de pouvoir effectuer exactement les mêmes actions spécialisées que l’homme, telles que l’indexation, qui est une tâche certes répétitive, mais complexe, qui varie selon le type de corpus.

⁴⁵J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives »...

10. machine learning

- Machine learning "Le ML est un domaine de l'IA qui regroupe les méthodes, les processus et les techniques nécessaires pour rendre une machine ou un système informatique plus « intelligent »."⁴⁶ c'est à cette étape que la machine apprend et est entraînée sur les techniques d'indexation à partir d'exemples humains : annotation de données.

"L'idée à la base du ML est qu'une machine peut résoudre des problèmes de la même manière que l'homme, en apprenant à partir d'« expériences » et d'exemples, sans être explicitement programmée pour la résolution spécifique du problème. Ainsi, au lieu d'implémenter un algorithme concret de résolution de problèmes dans une machine, les données sont transmises à un algorithme générique qui, par un « processus d'apprentissage », devient lui-même capable de résoudre les problèmes."⁴⁷

Il existe différentes méthodes de machine learning : Apprentissage supervisé Apprentissage non supervisé Apprentissage profond et réseaux neuronaux artificiels (deep learning)

"La raison pour laquelle telle ou telle fonction s'impose pendant le processus d'apprentissage ne peut être reconstituée que rétrospectivement et favorise souvent des décisions curieuses de l'algorithme. L'un des principaux problèmes réside dans le fait que les systèmes ne font pas la distinction entre les corrélations et les causalités dans les ensembles de données. L'exemple d'une « recherche de vaches sur des images » illustre bien cette situation : les vaches se trouvent souvent dans des prairies ; le modèle commence alors à ajouter « prairie » (couleur, formes, modèles d'images) au concept « vache ». L'algorithme n'a donc appris qu'une corrélation sur la base d'une probabilité statistique (vache et pré), mais n'a pas compris les relations."⁴⁸

Exemple de transcription basée sur le machine learning : Transkribus : peut aussi s'appliquer aux archives audiovisuelles.

- Deep learning

méthode dérivée du machine learning basée sur les réseaux de neurones.

"L'apprentissage profond permet d'envisager une redéfinition des méthodes des historiens et historiennes de l'art, en intégrant une part d'automatisation dans le traitement des sources iconographiques, permettant ainsi d'envisager l'exploration de corpus bien plus vastes "⁴⁹

⁴⁶ *Ibid.*

⁴⁷ *Ibid.*

⁴⁸ *Ibid.*

⁴⁹ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

”La recherche de similarité compte parmi les applications les plus directes du deep learning”, ” elle permet de classifier les images en vue de leur étude en constituant des séries iconographiques aux caractéristiques visuelles similaires, selon un score de similarité calculé par l’algorithme”⁵⁰

Transformers

Récemment, une transition architecturale des modèles a produit un basculement vers des modèles basés sur les transformers en vision par ordinateur, remplaçant progressivement les CNN. Cela explique pourquoi les outils actuellement disponibles comme CLIP, ViViT, AT, sont tous basés sur cette architecture.

”les vision transformers (ViT) s’avèrent souvent plus efficaces que les réseaux de neurones convolutifs (CNN) dans des domaines tels que la segmentation d’image, la détection d’objets et les tâches connexes. L’architecture de type transformer alimente également de nombreux modèles de diffusion utilisés pour la génération d’images, le Text to Speech multimodal et les modèles vision-langage (VLM).”⁵¹ ”En raison de leur capacité à comprendre la manière complexe dont chaque partie d’une séquence de données influence les autres et s’y rapporte, les modèles transformers permettent également un usage multimodal.”⁵² ”La fonctionnalité centrale des modèles transformers est leur mécanisme d’auto-attention, dont ils tirent leur incroyable capacité à détecter les relations (ou dépendances) entre les différentes parties d’une entrée. Contrairement aux architectures RNN et CNN qui l’ont précédée, l’architecture de type transformer utilise uniquement des couches d’attention et des couches de propagation standard.”⁵³ Les RNN et CNN analysent les données de façon ”sérielle”⁵⁴, dans un ordre donné, les empêchant ainsi de saisir les ”dépendances à longue portée”.⁵⁵ les transformers : ”Les mécanismes d’attention, quant à eux, examinent simultanément les séquences dans leur intégralité et décident de la manière et du moment où il convient de se concentrer sur certaines étapes de chaque séquence.”, ”En plus d’améliorer considérablement la capacité à comprendre les dépendances à longue portée, cette qualité des transformateurs permet également la parallélisation, qui consiste à réaliser plusieurs étapes de calcul simultanément, au lieu de les sérialiser.”⁵⁶

⁵⁰ *Ibid.*

⁵¹ Cole Stryker Bergmann Dave, *Qu’est-ce qu’un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

⁵² *Ibid.*

⁵³ *Ibid.*

⁵⁴ *Ibid.*

⁵⁵ *Ibid.*

⁵⁶ *Ibid.*

les transformers pour l'analyse d'image : "Les transformeurs offrent également certains avantages par rapport aux réseaux de neurones, en particulier pour les données visuelles. Intrinsèquement locaux, les CNN utilisent des convolutions pour traiter successivement les sous-ensembles de données d'entrée. Par conséquent, les CNN peinent à discerner les dépendances à longue portée, telles que les corrélations entre les mots (dans un texte) ou les pixels (dans une image) qui ne sont pas voisins. Les mécanismes d'attention n'ont pas cette limitation."⁵⁷

CNN : réseau de neurones convolutif Outils de classification : "modèles de programmation puissants permettant notamment la reconnaissance d'images en attribuant automatiquement à chaque image fournie en entrée, une étiquette correspondant à sa classe d'appartenance."⁵⁸ l'un des principaux cas d'usages des CNN est la "reconnaissance d'images". "Dans une moindre mesure, on les utilise aussi pour l'analyse vidéo."⁵⁹

Description du fonctionnement d'un CNN appliqué à un corpus d'images : « CNNs learn a hierarchy of filters, which are applied to an input image in order to extract meaningful information from the input. [...] CNNs tend to learn features that resemble Gabor-like edge detectors and color-opponent filters at lower layers [...]. On higher layers of the CNNs, features capture more abstract image content by integrating the lower-layer features. »⁶⁰. A relier avec ResNet : même fonctionnement.

- Supervised learning

Définition : "Supervised learning is a machine learning approach that's defined by its use of labeled data sets. These data sets are designed to train or "supervise" algorithms into classifying data or predicting outcomes accurately. Using labeled inputs and outputs, the model can measure its accuracy and learn over time."⁶¹ Ils peuvent être séparés entre deux types de problèmes : classification and regression

Nécessite l'intervention humaine : "In supervised learning, the algorithm "learns" from the training data set by iteratively making predictions on the data and adjusting for the correct answer. While supervised learning models tend to be more accurate than unsupervised learning models, they require upfront human intervention to label the

⁵⁷ *Ibid.*

⁵⁸ Jérémie Robert, *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).

⁵⁹ *Ibid.*

⁶⁰ Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

⁶¹ Julianna Delua, *Supervised vs. Unsupervised Learning : What's the Difference ? / IBM*, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

data appropriately.”⁶²

appliqué aux images, l'apprentissage supervisé suppose que chaque image fournie à une machine soit annotée par un humain⁶³

Cela suppose des heures de travail et des milliers d'annotations pour entraîner le modèle, ce que les institutions ne peuvent pas faire

- Unsupervised learning

définition : ”Unsupervised learning uses machine learning algorithms to analyze and cluster unlabeled data sets. These algorithms discover hidden patterns in data without the need for human intervention (hence, they are “unsupervised”). Unsupervised learning models are used for three main tasks : clustering, association and dimensionality reduction”.⁶⁴

”Unsupervised learning models, in contrast, work on their own to discover the inherent structure of unlabeled data. Note that they still require some human intervention for validating output variables.”⁶⁵

Un exemple de tentative de unsupervised learning est Deepcluster, une tentative d'entraîner un CNN sans annotations humaines, en générant des étiquettes automatiquement via un algorithme de clustering (k-means).⁶⁶

Un modèle peut regrouper des images similaires et utiliser ces groupes comme étiquettes⁶⁷

Deepcluster regroupe ainsi les similarités visuelles produites par le CNN en clusters avec k-means, et entraîne le CNN à prédire ces clusters.

Deepcluster est performant même sur des images structurées différemment : « Even when trained on uncured Flickr images, DeepCluster outperforms the current state of the art by a significant margin on most tasks. This experiment validates that DeepCluster is robust to a change of image distribution. »⁶⁸. C'est intéressant dans l'idée d'adapter un de ces outils à des archives patrimoniales spécifiques.

⁶² *Ibid.*

⁶³ Mathilde Caron, Piotr Bojanowski, Armand Joulin et Matthijs Douze, « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.

⁶⁴ J. Delua, *Supervised vs. Unsupervised Learning...*

⁶⁵ *Ibid.*

⁶⁶ M. Caron, P. Bojanowski, A. Joulin, *et al.*, « Deep Clustering for Unsupervised Learning of Visual Features »...

⁶⁷ *Ibid.*

⁶⁸ *Ibid.*

Mais la limite est la suivante : « Replacing labels by raw metadata leads to biases in the visual representations with unpredictable consequences. ».⁶⁹ On donne des métadonnées brutes ou incomplètes à un CNN, donc il est possible que ce qu'il interprète soit biaisé. Un tel biais n'est pas acceptable dans un contexte archivistique.

autre limite, Deepcluster a été validé sur imageNet, qui compte 1.28 millions d'images, et YFCC100M, 1 million d'images. Il est donc probable qu'il ne soit pas adapté à une collection réduite comme celles des institutions patrimoniales.

⁶⁹ *Ibid.*

11. computer vision

- Définition Branche de l'IA qui permet principalement d'extraire de l'information d'images ou de vidéos. Permet aux machines de "voir", comme les humains et ainsi d'extraire des données d'éléments visuels.

Aujourd'hui, la computer vision se fait par machine learning.

"La vision par ordinateur est un domaine d'intelligence artificielle (IA) qui permet aux ordinateurs et aux systèmes d'extraire des informations pertinentes à partir d'images, de vidéos et d'autres entrées visuelles numériques, pour prendre des mesures selon ces entrées. Cette capacité à fournir des recommandations la distingue des tâches de reconnaissance d'images."⁷⁰

les composants de la vision par ordinateur ont été mis en place en partie pour l'analyse d'images et la détection d'objets dans l'image.⁷¹

"La détection de contours (ou edge detection) est une étape fondamentale pour le traitement des images en vision artificielle : combinée à des méthodes de détection des lignes il devient envisageable d'automatiser la transformation d'images au format .tiff ou .jpeg en objets plus aisément manipulables"⁷²

Etapes d'entraînement d'un modèle : "prévoir un jeu de données initial, et d'évaluer les performances du modèle après ce premier entraînement. À partir de ces résultats, il devient possible d'adapter les jeux de données suivants, pour pallier aux faiblesses constatées."⁷³

"Pour des tâches classiques de vision artificielle, telles que la détection d'objet, des modèles pré-entraînés performants existent en libre accès, qui ne nécessitent donc pas autant de travail d'entraînement qu'un modèle créé dans son entièreté pour un projet. Des jeux de données en accès libre sont également disponibles pour l'entraînement de modèles pour la détection automatique, tels que ImageNet 16, qui bien qu'ils ne soient pas adaptés à des sources historiques, permettent d'effectuer un premier entraînement d'un modèle sans mobiliser les moyens nécessaires à la création d'un jeu de données."⁷⁴

limites : est ce qu'il en existe tout autant pour les corpus vidéos ? à chercher

- cas d'application

⁷⁰ *Qu'est-ce qu'un réseau de neurones convolutifs ?* / IBM, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).

⁷¹ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁷² *Ibid.*

⁷³ *Ibid.*

⁷⁴ *Ibid.*

Object detection :⁷⁵ single shot detector : YOLO, using CNN two stages detectors : Deux analyses de l'image. Demande plus de puissance de calcul mais est plus efficace. pour prédire, analyser et comparer la performance des différents modèles de détection d'objet, on a besoin de "standard quantitative metrics". Les plus communs "evaluation metrics" sont : INtersection over union (LOu) et average precision (AP)

YOLO : réseau de neurones qui fait des prédictions sur la détection d'objets et qui les classe "all at once". (à placer aussi dans les cas d'usages sur les archives audiovisuelles)

Content-Based Image Retrieval : une des applications de la computer vision. Exemple de cas d'usage : Galt archives avec Archipanion⁷⁶

Visual language models (VLMs) : combinaison d'algorithmes de computer vision et de LLMs pour : "create visual outputs based on input text, or textual outputs based on images or video" / "VLMs are able to do a variety of vision language tasks like captioning and summarization, image generation, search and retrieval, and object detection and segmentation" "However, there are still challenges with these emerging models like biases, hallucinations, and overgeneralizations as well as concerns of cost and environmental impact considering that VLMs combine two already complex AI architectures into one even more complicated tool"⁷⁷ exemple de VLM : CLIP : génère de la description en langage naturel à partir d'éléments visuels

- Esthétique computationnelle

Sous discipline de la vision par ordinateur : évaluation de l'art par une machine. terme développé par Brachmann dans son article.⁷⁸

"computational aesthetics is concerned with [...] "the creation and evaluation of art using computers." [...] A computational analysis can pick up very subtle relationships that may escape the attention by human observers; moreover, computational methods are objective in nature and are potentially non-exhaustive in the amount of detail analyzed. »⁷⁹

prédiction automatique des scores esthétiques : Rating prediction : algorithmes capables de prédire la qualité esthétique d'une image.

les modèles les plus utilisés pour faire ces prédictions sont les CNN « Deep neural networks learn features that are important for aesthetic evaluations automatically, provi-

⁷⁵ *YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).

⁷⁶ K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

⁷⁷ *Ibid.*

⁷⁸ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

⁷⁹ *Ibid.*

ded that a dataset is big enough. [...] They can even take into account abstract features, such as image content, without the explicit design of such features by humans. »⁸⁰

limite des CNN pour l'analyse de l'esthétisme des images : « While hand-crafted features allow to quantify which feature contributes the most to an aesthetic rating, this interpretability is lost with generic features. [...] Deep neural networks and generic features basically represent a black-box approach that lacks this kind of interpretability. »⁸¹

⁸⁰ *Ibid.*

⁸¹ *Ibid.*

12. IA appliquée à la vidéo

- Intro "Visual object analysis researchers are increasingly experimenting with video, because it is expected that motion cues should help with detection, recognition, and other analysis tasks."⁸²
- audiovisual processing Audiovisuel Processing (AVP) : ensemble de technologies appliquées à l'analyse de contenus vidéos et audio (comprend computer vision et ASR automatic speech recognition)⁸³

constat : malgré de grandes avancées dans le processing audiovisuel, ces outils restent largement inaccessibles et ne sont pas donc pas adoptés dans le milieu des archives : « Despite the massive progress made in the performance levels and overall availability of Audiovisual Processing (AVP) technologies, such as Computer Vision (CV) and Automatic Speech Recognition (ASR), the availability of these tools for heritage institutions is still lagging behind. »

autre constat : "« Digital tools for paper resources have tended not to consider the strong presence of visual elements in them. Due to the lack of practically available AVP tools to digital humanities, scholarly research has 'grossly neglected visual content, causing a lopsided representation of all sorts of digitized archives'. » Sous représentation des éléments visuels dans l'indexation, même pour une collection audiovisuelle. Les métadonnées textuelles liées aux films sont nsuffisantes pour enrichir leurs métadonnées : titre, synopsis...⁸⁴

- Cas d'usage

Reconnaissance et extraction d'objets

Exemple de projet d'extraction d'entités depuis des images en mouvement :⁸⁵ Méthode du distant viewing : reconnaissance des visages, classification des plans. Le montage et le cadrage servent à construire la place des personnages dans le récit. « One of the first tasks in understanding a video file is to break up the sequence of frames into distinct units known as shots ». « We first split an input video file into individual shots, then

⁸²Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30–2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

⁸³Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

⁸⁴*Ibid.*

⁸⁵Taylor Arnold, Lauren Tilton et Annie Berke, « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4–2 (juill. 2019), DOI : 10.22148/16.043.

locate faces within every frame, identify the faces in a frame, and finally put all of the information together to cluster shots based on camera angles and distances ».⁸⁶

Shot boundary detection

Shot boundary detection : détection automatique des coupures entre les plans dans une vidéo
 Shot semantics : description de ce qui est présent dans l'image et à quel endroit de l'image et ainsi relier l'image à des catégories de plan (shot type).

exemple de pipeline pour détecter les coupures entre les plans : "the vast majority of cuts in most film and television episodes consist of abrupt transitions between alternative camera shots. These are both easy to define and relatively easy to detect. The algorithm we use in our analysis uses a combination of histogram differences and down sampled pixel intensities. Our method functions by measuring the extent to which two successive shots are different from one another in terms of the general color palette and the distribution of brightness over the frame. If these differences fall above a specified threshold, we indicate the presence of a cut.²² We also added special logic to avoid erroneous cuts during fade-in and fade-out events."⁸⁷

face detection models : Faster R-CNN and FAREC-CNN⁸⁸

Shot classification : il est possible de classifier le type de plan à l'image en utilisant le placement des visages : "In this final step we no longer work directly with the visual materials and build a meta-algorithm that takes detected shot breaks and faces as input and outputs categorical predictions for each shot".⁸⁹ Il s'agit de définir tous les types de plans et à partir de ces définitions, construire un jeu de données qui sera testé : close-up, over the shoulder...

Outils AVP

ImageJ : open source visual analysis software suite⁹⁰ Detectron2 : détection de points corporels dans l'image⁹¹

- Limites et discussion

les AVP ne sont pas accessibles en libre accès aux chercheurs en humanité numériques.

Les algorithmes ont besoin d'un accès direct aux données, or, pour des raisons de

⁸⁶ *Ibid.*

⁸⁷ *Ibid.*

⁸⁸ *Ibid.*

⁸⁹ *Ibid.*

⁹⁰ N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

⁹¹ *Ibid.*

sécurité des données et des droits de propriétés intellectuelles auxquels sont soumis les archives, les données des archives ne peuvent pas quitter leur environnement numérique. donc : "A side effect of this is that for the analysis of AV material commercially available tools cannot be used, as these are primarily cloud based. To tackle this challenge it is necessary that any AVP infrastructure can be integrated with a local archival infrastructure, i.e., we need to bring the algorithms to the data, rather than the data to the algorithms"⁹²

au lieu de transférer les fichiers vers un service externe, l'algorithme doit être déployé localement au sein même de l'infrastructure de l'archive.

exemple de l'architecture DANE au sein du projet CLARIAH : l'architecture est divisée en plusieurs "workers" et une file d'attente. si l'un des workers s'arrête de fonctionner, les autres continuent leur tâche. Cette architecture produit deux types de données : des métadonnées structurées directement exploitables, et des vecteurs de caractéristiques (= représentations abstraites des données utilisables pour des requêtes de similarité : ouvre des possibilité de recherche par ressemblance son et vidéo.)⁹³

"there is a near-linear relationship between quality of transcriptions and search performance. » : importance de la qualité de la transcription audiovisuelle pour améliorer la recherche.⁹⁴

"the application of AVP tools to large image datasets significantly scales up the level of analysis from 'close' to 'distant' viewing, allowing scholars to observe patterns in the data that are invisible in the traditional, interpretative analyses of small sample sets. » le distant viewing permet de passer d'une lecture individuelle d'items à une analyse d'éléments à l'échelle d'un corpus.⁹⁵

- Diginpix : système d'identification d'entités visuelles dans les images fixes et animées
Développé par l'INA et open source pour les images animées : "L'image animée implique une problématique ultérieure par rapport à l'image fixe en raison de sa dimension temporelle. Un visualiseur spécifique a été aussi développé, dans une logique open source, pour permettre le repérage rapide des entités visuelles dans la temporalité de la vidéo."⁹⁶

impact de l'indexation automatique sur les données : "Comme le repérage d'entités visuelles demande énormément d'informations locales, les bases de données d'indexation

⁹² *Ibid.*

⁹³ *Ibid.*

⁹⁴ *Ibid.*

⁹⁵ *Ibid.*

⁹⁶ E. Moiraghi, *Explorer des corpus d'images. L'IA au service du patrimoine...*

constituées à partir de la reconnaissance des entités sont conséquentes (elles peuvent avoir une taille supérieure à celle des vidéos elles-mêmes) et font l'objet de recherches au sein de l'établissement pour en optimiser les temps de calcul.

Dans ce contexte, la qualité et la modélisation des données jouent un rôle fondamental car c'est sur les bases de données que les algorithmes sont entraînés.”⁹⁷

Diginpix repose sur : ”The identification process mainly relies on an efficient CBIR system, searching in an indexed image database composed of 600,000 weak-labelled images crawled from Google Images. DigInPix proposes a responsive-design html5 interface1 for testing purposes.”⁹⁸

fonctionnement détaillé : ”The core engine makes use of local descriptors hashing techniques and a scalable indexing and search structure based on hash tables. This allows matching all local descriptors one by one in the full index and favors a more precise matching of small objects in highly cluttered pictures. Using geometry in addition to this raw scheme further improves the search performances”⁹⁹

Diginpix produit une sorte de segmentation : ”When dealing with videos, keyframes are first extracted whenever the content changes significantly, i.e. new shot, moving camera, new objects appearing, etc., thanks to a keyframe detector using grid-based histograms of LBP features. The time between two keyframes typically varies from 100ms to 30s. All the detected keyframes are then processed one by one in the same way than single images.”¹⁰⁰

- Amalia.js¹⁰¹

⁹⁷ *Ibid.*

⁹⁸ Pierre Letessier, Nicolas Hervé, Alexis Joly, Hakim Nabi, Mathieu Derval et Olivier Buisson, « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.

⁹⁹ *Ibid.*

¹⁰⁰ *Ibid.*

¹⁰¹ N. Hervé, P. Letessier, M. Derval et H. Nabi, « Amalia.Js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.

13. segmentation

- Segmentation d'images

La segmentation appliquée à l'image en général, y compris l'image fixe, consiste à diviser l'image en groupes de pixels selon certains critères.

- Segmentation vidéo

Appliquée à l'image animée, la segmentation peut signifier plusieurs choses différentes. En effet, l'image audiovisuelle comporte une valeur ajoutée à l'image fixe : celle de la dimension temporelle d'une succession d'images, créant une animation. Elle peut également comporter une piste audio, dans la plupart des cas, le son ayant été intégré au cinéma dès 1932. Il faut tout de même noter que toutes les images animées ne comportent pas de son (films de famille, films expérimentaux, films muets). Dans notre analyse, le son sera tout de même pris en compte dans la mise en place d'un pipeline de segmentation pour prévoir le cas fréquent d'une bande sonore.

Appliquée à la vidéo, la segmentation peut alors être de deux formes : une division en plusieurs segments ou objets.¹⁰² La division d'une image animée en séquences ou en différents plans correspond à une segmentation temporelle. La segmentation d'objets dominants dans l'image¹⁰³ selon des critères visuels¹⁰⁴, désigne plutôt une segmentation spatiale, analysant la place des objets dans l'image, pas encore leur signification.¹⁰⁵ C'est au moment d'apposer une signification sur ces objets qu'on parle de segmentation sémantique. En effet, la segmentation sémantique consiste à extraire des objets de l'image selon des catégories sémantiques prédéfinies.¹⁰⁶ Ce type de segmentation prépare l'indexation en assignant des étiquettes à chaque pixel extrait de l'image. Parmi ces trois types de segmentation, seule la segmentation temporelle est spécifique à l'image animée, puisqu'elle analyse la différence temporelle et sémantique entre les plans et leur relations pour pouvoir en extraire des séquences distinctes. Les segmentation d'objets et sémantiques sont en revanche également applicables à l'image fixe.

Enfin, peut être appliquée à une vidéo une segmentation de la bande sonore, qu'on désignera sous le nom de segmentation audio, utilisée par exemple, pour segmenter les

¹⁰²Tianfei Zhou, Fatih Porikli, David Crandall, Luc Van Gool et Wenguan Wang, *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

¹⁰³*Ibid.*

¹⁰⁴Jean Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.

¹⁰⁵T. Zhou, F. Porikli, D. Crandall, et al., *A Survey on Deep Learning Technique for Video Segmentation...*

¹⁰⁶*Ibid.*

paroles de la musique dans une même séquence vidéo.¹⁰⁷

- la segmentation sémantique Concentrons nous ici sur la segmentation sémantique. Deux modèles de segmentation sémantique se distinguent. Les méthodes orientées précision, qui agrègent l'information temporelle entre les images pour améliorer la prédiction. (Elles utilisent le flux optique ou des modèles basés sur l'attention. Ex de méthodes : TDNET)¹⁰⁸ Les méthodes orientées vitesse, qui réutilisent les caractéristiques des images adjacentes pour ne pas les recalculer à chaque image. (ex : approche des keyframes : calculer les features clés sur certaines images et les appliquer aux autres. Manque de précision.¹⁰⁹) La segmentation sémantique reste toutefois lacunaire sur des vidéos longue durée, ou sur des vidéos dont les catégories sémantiques sont inconnues, ce qu'on appelle la segmentation "open world".¹¹⁰ (les modèles actuels connaissent les catégories sémantiques à l'avance et ne peuvent pas gérer ou reconnaître des catégories inconnues). Zhou et al. conseillent également d'adapter le calcul en fonction du contenu de l'image, pour adapter des parties du réseau au contexte de l'image pour éviter un gaspillage de calcul.¹¹¹

Adapté au contexte skinsoft, il faudrait donc produire un mapping des champs utilisés pour décrire un film, une archive audiovisuelle, ou annoter des archives avec les champs dédiés. Les corpus sur lesquels sont entraînés les modèles sont bien loin de la complexité des archives audiovisuelles.

Ex de résultats : Sur Cityscapes (VSS), la méthode EFC obtient les meilleures performances avec 83,5 pourcents d'IoUclass.¹¹²

Segmentation guidée par le langage (LVOS)

Problématiques liées à la nature de la vidéo : "C'est donc un problème de segmentation, qui est posé parce que les divisions "calculables" d'une vidéo (les plans et les segments de parole ou de musique), n'ont pas de valeur documentaire. En revanche, les divisions documentaires "naturelles" (sujets d'un journal, numéros d'un spectacle de variétés, scènes d'un film) ne sont pas directement calculables"¹¹³

¹⁰⁷J. Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels »...

¹⁰⁸T. Zhou, F. Porikli, D. Crandall, et al., *A Survey on Deep Learning Technique for Video Segmentation...*

¹⁰⁹*Ibid.*

¹¹⁰*Ibid.*

¹¹¹*Ibid.*

¹¹²*Ibid.*

¹¹³Ronfard, Rémi, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).

La segmentation d'objets vidéo se décline en trois mode : automatique, semi automatique, interactif.¹¹⁴

(en quoi est ce différent d'une image fixe ? ça ne peut pas être appliqué aux images fixes ?). C'est plutôt utilisé pour le montage : retirer des objets dans l'image par ex. Ça ne concerne pas la signification des images dans l'image, seulement leur place.

- pourquoi segmenter ?

La segmentation découle d'une volonté d'indexer le contenu de l'image. En effet, selon Carrive, "La première étape du processus d'analyse des documents audiovisuels est bien souvent une étape de segmentation temporelle qui consiste à identifier dans le document des séquences possédant des caractéristiques communes ou des ruptures entre ces séquences."¹¹⁵. Segmenter ainsi l'image permet d'indexer non plus la vidéo au complet mais des fragments, rendant son analyse plus précise. C'est également la manière dont sont analysés les films, plans par plans, ou séquences par séquence, pour en déceler le sens, à la fois une segmentation des éléments qui se trouve dans l'image, leur relations entre eux, et l'enchaînement des plans, les mouvements de caméra. L'entraînement de modèles pour l'indexation est donc calquée sur le regard humain qui permet d'analyser et d'indexer des films. Une fois la segmentation effectuée, l'objet d'analyse n'est plus le film entier mais des plans ou des séquences.¹¹⁶ La segmentation crée ainsi de nouveaux objets indexables. La segmentation est ainsi la première étape de la compréhension d'un fichier vidéo : "One of the first tasks in understanding a video file is to break up the sequence of frames into distinct units"¹¹⁷ Une fois le fichier vidéo segmenté, il est alors possible d'organiser le contenu, d'améliorer l'accès, et de produire des analyses sur des larges données vidéo.¹¹⁸ La segmentation permettrait d'analyser de larges quantités de données, tout en homogénéisant les pratiques documentaires, en augmentant la précision et la cohérence.¹¹⁹

Qu'est-ce que ça signifie pour l'institution de passer d'un objet-film à une collection de plans ? Quelles sont les implications pour le droit, pour l'accès public, pour la description archivistique ?

¹¹⁴T. Zhou, F. Porikli, D. Crandall, *et al.*, *A Survey on Deep Learning Technique for Video Segmentation...*

¹¹⁵J. Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels »...

¹¹⁶Ryan Cordell, « Machine Learning + Libraries » ().

¹¹⁷T. Arnold, L. Tilton et A. Berke, « Visual Style in Two Network Era Sitcoms »...

¹¹⁸Jonathan Attard et Dylan Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].

¹¹⁹*Ibid.*

la mise en place d'une automatisation de la segmentation permettrait d'homogénéiser l'indexation documentaire : un algorithme segmente les vidéos de la même façon, pas les humains. Mais les vidéos sont toutes différentes : est ce qu'on peut garder la même pratique de segmentation sur des corpus vidéo différents ?

- Segmentation sémantique ou segmentation d'images

La segmentation sémantique est une tâche de la vision par ordinateur.

"Semantic segmentation is a fundamental task in computer vision. It aims to divide the image into multiple regions according to the class of the pixel, which is important for practical applications such as autonomous driving, automatic delivery sorting, and intelligent surveillance systems"¹²⁰

Importance de la segmentation sémantique pour les vidéos : "videos contain not only spatial features but also temporal features. This naturally results in lower accuracy of image-based segmentation models compared with video-based segmentation models for Video Semantic Segmentation (VSS)."¹²¹

- Pipelines de segmentation

Pyscenedetect Une idée de pipeline de segmentation : est la détection de scènes avec pyscenedetect (découpage d'une vidéo en segments en détectant les coupes visuelle), puis classification des segments. D'un côté la segmentation syntaxique et de l'autre la classification sémantique.¹²²

ResNet (pas de la segmentation : créer un fichier sur la classification ?) Le meilleur classifieur d'images avec le plus haut résultat de précision selon attard 2025 est ResNet¹²³

Recommandations : Les modèles multimodaux qui combinent audio et vidéo (vivitast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d'usage et qui séparent les pipelines.¹²⁴

ViViT Expérimentation avec ViViT : le modèle ViViT, modèle basé sur des transformers, capture les caractéristiques spatio temporelles de la vidéo, contrairement à

¹²⁰Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

¹²¹*Ibid.*

¹²²J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹²³*Ibid.*

¹²⁴*Ibid.*

Resnet qui analyse chaque image d'un vidéo indépendamment. ViViT extrait "extracts spatio-temporal tokens from the input video, which are then encoded by a series of transformer layers." ¹²⁵. C'est un modèle qui tente d'analyser l'espace et le temps dans une vidéo donnée. Vivit adopte donc une approche "video-native". Le modèle à choisir dépend de la nature du corpus audiovisuel que l'on souhaite indexer. Si les archives sont des plans fixes qui ne changent que très peu, resnet suffit.

Conclusion sur ViViT : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset to train. » ¹²⁶. : les transformers n'ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu'il soit dans l'image. Ils ont donc besoin d'être entraînés sur beaucoup plus de données : c'est une grande limite. Une approche par classifieurs d'images plus légers comme ResNet peut donc être préférable. ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d'archives historique sauf pré entraînement massif.

2SDS

l'étude de xin2023 ¹²⁷ présente 2SDS, un algorithme de segmentation temporelle vidéo. Plutôt que d'utiliser un réseau de neurones pour détecter les changements de scènes, 2SDS compare des empreintes (hash) d'images successives. Si deux frames sont suffisamment différentes (distance de Hamming supérieure à un seuil), elles appartiennent à des scènes distinctes. « 2D CNNs only recognise a video as discrete images, rather than a continuous stream of images. This poses some issues. For example, a CNN model could not resolve the motion of a person because the person is stationary in every frame, and this will cause the loss of significant information in video analysis. » ¹²⁸ : un CNN 2D comme resnet analyse chaque plan de manière indépendante et ignore la logique temporelle de la vidéo. 2SDS résout ce problème en regroupant les plans similaires avant de les classifier. (à relier avec la notion de shot boundary detection). « We need to devise an implementation that complements the CNN model to solve the continuity issue. This implementation should group the discrete frames (adjacent

¹²⁵Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić et Cordelia Schmid, *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].

¹²⁶*Ibid.*

¹²⁷Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

¹²⁸*Ibid.*

on the temporal axis) that look similar to each other into scenes, this procedure is what we call temporal segmentation. »¹²⁹ : la segmentation temporelle : regrouper les plans qui se suivent et visuellement similaires : c'est ce que fait pyscene detect avec le content detector. l'article explique aussi la mise en place d'un pipeline de détection de changement de plan : 4 étapes :

down sampling : miniaturisation du plan pour détecter les changements globaux, pas locaux

conversion de l'image RGB en niveaux de gris

calcul d'une valeur de "hachage" de l'image : Chaque ligne de 9 pixels est convertie en 8 bits binaires comparant les pixels adjacents. Produit une « empreinte » numérique de la frame.

distance de hamming : comparaison des empreinte de deux frames consécutives. Si la distance est supérieure à 5, les deux plans appartiennent à des scènes différentes. le seuil est paramétrable. pyscenedetect est l'implémentation concrète de ce processus.

les auteurs conseillent de ne pas utiliser des réseaux de neurones pour la segmentation vidéo : « The usage of RNN or even neural networks is not practical in time sensitive tasks like real-time object recognition and live video stream analysis, which requires fast responding algorithms, and RNNs usually cannot meet those requirements. »¹³⁰

détecter les coupures entre es scènes est une analyse syntaxique et non sémantique : il suffit de détecter la différence visuelle. les meilleurs résultats de détection de coupures se font sur des plans fixes, avec des suets distants, des mouvements lents, donc plutôt bien adaptées aux archives audiovisuelles.

l'article de XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV] ne cherche pas à comprendre les scènes mais seulement à analyser leur syntaxe pour en détecter les coupures. 2SDS règle le problème de délimitation en séquence, mais ne décrit pas la vidéo comme d'autres outils peuvent le faire : CLIP, YOLO, BLIP. De plus, le corpus de tests est réduit (6 vidéos issues de youtube), et en couleur.

video semantic segmentation (VSS) : TDNSNet

"fundamental machine vision task with various practical applications, such as autonomous driving and automated surveillance. Current studies mainly utilize temporal

¹²⁹ *Ibid.*

¹³⁰ *Ibid.*

features based on optical flow and the self-attention mechanism to improve VSS accuracy.”¹³¹ Limites : ”reduced accuracy and computational overhead due to inaccurate optical flow and the computational cost of the self-attention mechanism.”¹³² L’outil temporal difference segmentation net se propose comme une solution à ces limites selon l’article de Yuan¹³³

Limites identifiées par Yuan²⁰²⁵ des modèles de VSS existants : les modèles basés sur le flux optique (optical flow) sont dépendants de la prédiction du flux et génèrent des erreurs, dégradant ainsi la qualité de la segmentation (erreur d’accumulation). Les modèles fondés sur les mécanismes d’auto attention capturent mieux les relations entre images mais leur complexité les rend difficilement applicables à des vidéos complexes elles mêmes.¹³⁴

TDSNet : ”TDSNet employs temporal-difference-based temporal feature through the Temporal Feature Refine Module (TFRM). To further improve the accuracy of VSS, TDSNet adaptively fuses temporal features of varied motion magnitude with the Motion Magnitude Refine Module (MMRM). This module weighs and fuses temporal features of different magnitudes between frames.”¹³⁵

TDSNet est donc un modèle qui se base sur la différence temporelle : ”the temporal-difference-based features are obtained by the subtraction of the features from two consecutive frames. As a result, the model activates the dynamic regions of the feature while deactivating the static regions, allowing it to capture temporal features effectively.”¹³⁶ Le modèle soustrait les features de deux images consécutives pour en faire ressortir les régions dynamiques (en mouvement) et désactive les régions statiques. Ainsi il capture uniquement l’information temporelle, pour un faible coût computationnel.

TDSNet repose sur deux modules : TFRM : temporal feature refine model : il extrait les features temporelles par différence entre l’image cible (target frame) et l’image de référence (reference frame). Il utilise ensuite l’information de mouvement retenue pour aligner et fusionner les features de la référence dans l’image cible.¹³⁷

MMRM : Motion magnitude refine module les features extraites par le TFRM contiennent des magnitudes de mouvements variés : ”we observe that motion magnitudes in the far frames are not necessarily larger than that of near frames. For example, with re-

¹³¹H. Yuan, J. Peng et Z. Cai, « TDSNet... ».

¹³²*Ibid.*

¹³³*Ibid.*

¹³⁴*Ibid.*

¹³⁵*Ibid.*

¹³⁶*Ibid.*

¹³⁷*Ibid.*

titive motion of the video, farther frames may exhibit smaller motion magnitudes.”. Le MMRM calcule donc le poids adaptatif de chaque feature temporelle selon la magnitude de mouvement réellement observée dans la vidéo en entrée, puis les fusionne.¹³⁸

Le modèle est entraîné sur deux jeux de données : VSPW (13 images par secondes et un écart de mean Intersection over Union de 0.7 pourcent)

CamVid

Cambridge driving : base de données vidéo étiquetée par des classes sémantiques d'objets.¹³⁹ : 2009 donc trop vieux ce qui est intéressant, c'est que en 2009, il y a moins d'algorithmes puissants et précis qui existent, donc c'est la vé

- Automatic temporal video scene segmentation (ou video story segmentation)

”The automatic temporal video scene segmentation (also known as video story segmentation) is still an open problem without definite solutions in most cases.”¹⁴⁰ les meilleurs solutions et qui donnent les meilleurs résultats qui existent sont les techniques multimodales utilisant les caractéristiques de plusieurs outils : ”Among the available techniques, the ones which shows better results are multimodal using features extracted from multiple modalities.”¹⁴¹ La fusion multimodale peut se faire de deux façon, fusion en une seule représentation, fusion par segmentation de chaque modalité : ”Multimodal fusion may be performed to fuse each modality as a single representation (early fusion) or by each modality segmentation (late fusion), the latter been widely due to multimodal fusion simplicity.”¹⁴². C'est la seconde approche qui est privilégiée.

limites des CNN : ”CNNs cannot adequately learn cues which are temporally distributed along the video due to difficulties to model temporal features data dependencies.”¹⁴³

RNNs : ”Successfully employed on text processing, RNNs are fitted to analyze sequences of data of variable length and may better grasp the temporal relationship among low-level features of video segments, hopefully obtaining more accurate scene boundary detection.”¹⁴⁴. Les RNN permettent de mieux capturer les relations temporelles.

Une des solutions serait de combiner CNN et RNN : complémentaires.

¹³⁸ *Ibid.*

¹³⁹ G. J. Brostow, J. Fauqueur et R. Cipolla, « Semantic Object Classes in Video... ».

¹⁴⁰ Tiago Henrique Trojahn et Rudinei Goularte, « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.

¹⁴¹ *Ibid.*

¹⁴² *Ibid.*

¹⁴³ *Ibid.*

¹⁴⁴ *Ibid.*

DIVAN - INA mise en place d'un système expérimental d'indexation semi automatique des archives audiovisuelles, conçu en trois étapes : segmenter, classifier, composer.¹⁴⁵ les événements détectés dans l'image sont annotés et validés par les archivistes.

- segmentation audio la segmentation audio peut être divisée en différentes sous tâches : la transcription de la parole ("Les performances de ces systèmes peuvent être très bonnes lorsque de bonnes conditions sont réunies : bonnes conditions d'enregistrement, élocution claire, syntaxe correcte, noms propres connus du système en particulier."¹⁴⁶), l'alignement audio/texte, indexation ("identification des termes les plus importants (mots clés), identification des sujets traités ou segmentation thématique"¹⁴⁷)

Une autre tâche de la segmentation audio et de l'analyse audio est l'identification des locuteurs. "Pour cela, il est nécessaire de posséder une référence pour chacun des locuteurs à reconnaître. Une référence peut consister en un ensemble d'échantillons de la voix de la personne à reconnaître"¹⁴⁸

- analyse des visages l'analyse des visages dans une vidéo se divise en plusieurs sous tâches : détection, suivi, caractérisation, reconnaissance.¹⁴⁹
- autres tâches de la segmentation Recherche d'instance (instance search) : "À partir d'un plan vidéo cible et d'un ensemble de thèmes qui délimitent la requête, il s'agit de retrouver dans une collection les plans les plus pertinents correspondant à la requête."¹⁵⁰

Indexation sémantique : "Il s'agit de caractériser des plans vidéo en leur assignant des étiquettes (tags) représentant des caractéristiques abstraites (appelées « concepts »)."¹⁵¹

- Découverte d'objets visuels "La découverte d'objets visuels consiste à rechercher automatiquement les objets apparaissant le plus fréquemment dans une collection d'images ou de vidéos"¹⁵²
- data mining

"La fouille de données, ou data mining, recouvre un « ensemble de techniques ayant pour objet l'extraction d'un savoir à partir de grandes quantités de données, par des

¹⁴⁵Ronfard, Rémi, (*PDF*) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions...*

¹⁴⁶J. Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels »...

¹⁴⁷*Ibid.*

¹⁴⁸*Ibid.*

¹⁴⁹*Ibid.*

¹⁵⁰*Ibid.*

¹⁵¹*Ibid.*

¹⁵²*Ibid.*

méthodes automatiques ou semi-automatiques » [14]. Les outils informatiques cherchent à découvrir, à faire émerger, à dégager, dévoiler des informations qu'il n'aurait pas été possible d'obtenir manuellement, parce que la quantité de documents à analyser est trop importante ou parce que les informations cherchées ne sont pas explicites et n'apparaissent en quelque sorte que statistiquement.”¹⁵³

Les archives audiovisuelles s'appliquent mal à ce concept puisque ce sont des archives : on veut pouvoir les décrire à la pièce, comme le ferait l'archiviste. On n'a pas extrait de statistiques mais des descriptions précises.

- fossé sémantique désigne le fossé entre ce que les algorithmes savent détecter et ce que les utilisateurs recherchent.

¹⁵³ *Ibid.*

14. Limites et critiques

- Limites générales de l'IA

les modèles d'IA sont entraînés en anglais, pose des questions d'adaptabilité : "Les IA conversationnelles reposent sur des grands modèles de langue (LLM) entraînés principalement sur des données en anglais, ce qui crée des biais linguistiques et culturels dans les résultats qu'ils produisent. [...] Il est donc indispensable que ces modèles soient entraînés avec une diversité de sources culturelles et linguistiques, y compris les langues régionales et les expressions artistiques moins représentées"¹⁵⁴

- Limites contextuelles

« How to give context to the machines? To give common sense? It's a problem of artificial intelligence from the beginning. »¹⁵⁵

- limites de l'automatisation :

"l'intégration de la vision artificielle aux méthodes des historiens n'existe que conjointement à des interventions humaines, qui assurent la pertinence des traitements effectués et apportent une analyse nécessaire."¹⁵⁶

- sur l'indexation automatique audio : « Audio archives present a complex terrain for contemporary speech processing technologies, owing to the varied domains these recordings encapsulate. »¹⁵⁷ : deux problèmes sur un corpus d'archives anciennes : variabilité linguistiques (multilingues, accents différents), variabilité temporelle (vieillesse des voix). les archives audiovisuelles sont un matériau hétérogène : opacité du médium.
- sur l'indexation automatique des archives audiovisuelles

IL est important pour les archivistes de savoir comment ont été entraînés les modèles qu'ils utilisent, sur quelles données.

la vidéo : souvent de moins bonne qualité que l'image fixe, donc les résultats d'indexation automatique peuvent être moins bons

contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent

¹⁵⁴La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture...

¹⁵⁵AI in Audiovisual Archives / Sound & Vision...

¹⁵⁶J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

¹⁵⁷P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ».¹⁵⁸

Lacunes

l'article de Attard souligne que « The study underscores the lack of specialised annotation tools and the high resource demands of sophisticated models, which could present significant obstacles for future research with limited computational resources. »¹⁵⁹ c'est une limite surtout pour les institutions. Rejoint l'argument et les limites exposées par¹⁶⁰

Les modèles multimodaux qui combinent audio et vidéo (vivit-ast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d'usage et qui séparent les pipelines.¹⁶¹

Absence d'outils d'annotation spécialisés dans la segmentation vidéo. Attard adapte label studio, un outil généraliste.¹⁶²

Limites des transformers : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset to train. »¹⁶³ : les transformers n'ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu'il soit dans l'image. Ils ont donc besoin d'être entraînés sur beaucoup plus de données : c'est une grande limite. Une approche par classifieurs d'images plus légers comme ResNet peut donc être préférable. ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d'archives historique sauf pré entraînement massif.

- éthique de l'IA

Sur l'éthique de l'expérience utilisateur : Principles for Accountable Algorithms : responsibility, explainability, accuracy, auditability, fairness¹⁶⁴

Limites du machine learning : "Une répartition arbitraire des systèmes est toutefois limitée dans la mesure où, d'une part, les systèmes entraînés ont souvent un domaine

¹⁵⁸B. Bachimont, *Indexation et archivage de contenus multimédias...*

¹⁵⁹J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁶⁰P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

¹⁶¹J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

¹⁶²*Ibid.*

¹⁶³A. Arnab, M. Dehghani, G. Heigold, *et al.*, *ViViT...*

¹⁶⁴*Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).

d'application spécifique et, d'autre part, leurs capacités sont fortement liées aux jeux de données utilisés. Les algorithmes entraînés avec différents jeux de données produisent des résultats différents.”¹⁶⁵

- Biais de la computer vision appliquée aux images :

”For instance, racial bias has been an ongoing challenge with computer vision tools, particularly with facial recognition software. A study published by MIT Media Lab in 2018 found that facial recognition software had an average error rate of 0.8 percent for light-skinned men, versus a 34.7 percent error rate for darker-skinned women”¹⁶⁶ ”societal biases are often engrained in AI model training datasets, which lead to the models reproducing those biases in their outputs”¹⁶⁷ ”In addition to this, the training data of computer vision models has relied mostly on visual content available to be harvested from the Internet, which in its majority corresponds to content developed during the last three decades. These models would underperform on images that are of a more historical character, commonly found in visual archives, since they are underrepresented in the training data”¹⁶⁸

Limite liée à la qualité des images : la qualité des images est absolument primordiale et déterminante dans la mise en place d'un pipeline d'indexation automatique : ”La question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle”.¹⁶⁹ Important dans le cadre d'une indexation d'archives audiovisuelles, qui sont souvent de moins bonne qualité que les images car les fichiers sont plus lourds.

limites des réseaux de neurones profonds tels que les CNN pour l'analyse de l'esthétisme des images : « While hand-crafted features allow to quantify which feature contributes the most to an aesthetic rating, this interpretability is lost with generic features. [...] Deep neural networks and generic features basically represent a black-box approach that lacks this kind of interpretability. »¹⁷⁰ ”with deep learning models, their success comes at a cost. At present, the understanding of deep features and how they work in object or aesthetic recognition lags behind. »¹⁷¹ Le problème est le suivant avec

¹⁶⁵J. Arnold, M. Lüpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁶⁶K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

¹⁶⁷*Ibid.*

¹⁶⁸*Ibid.*

¹⁶⁹J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

¹⁷⁰A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

¹⁷¹*Ibid.*

les CNN, les décisions qui sont prises sont obscures. Pour l'indexation des archives, c'est problématique si les archivistes ne sont pas capables d'expliquer pourquoi telle classification a été choisie par le modèle. Il faut maintenir une supervision humaine dans le pipeline d'indexation. La question de l'interopérabilité et de la transparence est aussi importante que la question de performance en sciences humaines et dans le milieu du patrimoine, car il s'agit de donner accès aux connaissances. (à relier avec l'éthique de l'IA : principes MA/ML : explainability)

La machine analyse différemment de l'humain, de manière objective et précise et exhaustive, qu'apporte l'humain ? : "the computational analysis of paintings has several advantages compared to an analysis carried out by human experts. For example, a computational analysis can pick up very subtle relationships that may escape the attention by human observers ; moreover, computational methods are objective in nature and are potentially non-exhaustive in the amount of detail analyzed. »¹⁷²

- Dépendance à la qualité de l'image

Limite exprimée dans le cadre de l'utilisation de line segment detection : "The first general challenge for line segment detection and description is that the endpoints of detected line segments are generally unstable due to many factors, such as image noise, occlusion, and illumination variance. This makes the line segment description and matching difficult since the corresponding line ROS (Region of Support) or neighborhood relationship among line segments is generated according to the line segment endpoints. »¹⁷³

La compréhension et l'analyse de l'image dépend de la qualité de l'image, souvent réduite pour des raisons de stockage de données, pendant l'entraînement.

¹⁷² *Ibid.*

¹⁷³ Xinyu Lin, Y. Zhou, Y. Liu, *et al.*, *A Comprehensive Review of Image Line Segment Detection and Description...*

15. Archives audiovisuelles

- Définition "Les images animées comprennent une gamme de matériaux différents sur lesquels des séquences d'images ont été enregistrées et qui créent l'illusion du mouvement lorsqu'ils sont projetés, diffusés ou plus (à l'aide d'un projecteur, d'un téléviseur, d'un ordinateur, d'un logiciel ou de dispositifs équivalents). Ces images peuvent être accompagnées ou non de son." ¹⁷⁴

- Spécificités

"When you start looking at moving images and doing ML on them, your object of study is no longer an entire film but shots or scenes or still images. And that suddenly brings in important questions for archives and libraries. When the record itself changes...that raises huge questions that folks are not grappling with. Not just enriching a particular object but changing the object". ¹⁷⁵

Difficultés de ce type de contenu : "moving image data, which is a particularly difficult data type to atomize." ¹⁷⁶

- Indexer les archives audiovisuelles

La spécificité du langage cinématographique comme obstacle à l'indexation
archives muettes et anciennes

Contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ». ¹⁷⁷ (aussi placé dans IAcinema)

Premier outil d'indexation des images : Perceptron de Franz Rozenblatt en 1957 : machine de reconnaissance d'images.

Pour l'indexation des archives audiovisuelles : apprentissage supervisé, non supervisé ou en profondeur : sont appliqués ou combinés.

"Dans le cas des archives audiovisuelles, on voit en outre très clairement comment les besoins des utilisateur · rice · s sont pris en compte lors de la conception de l'indexation automatique en profondeur et comment les données et les traces des utilisateur · rice · s

¹⁷⁴FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF...*

¹⁷⁵R. Cordell, « Machine Learning + Libraries »...

¹⁷⁶*Ibid.*

¹⁷⁷B. Bachimont, *Indexation et archivage de contenus multimédias...*

sont utilisées pour optimiser l'accès aux archives audiovisuelles (mot-clé : système de recommandation).¹⁷⁸

”L’indexation, la recherche et le filtrage basés sur le texte de contenus audiovisuels pertinents se heurtent par nature à des limites : Les contenus audiovisuels doivent également pouvoir être recherchés à l’aide de méthodes audiovisuelles (par exemple la navigation par images, Query by Example).¹⁷⁹

”L’identification de contenus simples d’images ou de sons basée sur des descripteurs techniques ou des attributs dérivés a tendance à être de plus en plus laissée à la machine apprenante (par exemple « photo de groupe », « personne avec un casque sur la tête », termes parlés), tandis que l’identification plus poussée de personnes, de corps, de lieux, d’événements ou de sujets concrets est encore très sujette à erreurs.¹⁸⁰

- modification de la perception de l’archive

Indexer automatiquement une archive audiovisuelles permet de repenser ses modalités d’analyse et d’interprétation. voir article cairn.

- Big Data

Les archives audiovisuelles, de part la complexité des données qu’elles renferment, des sons et des images, feraient partie d’un ”big data”.¹⁸¹

- segmentation

Si la structuration d’éléments vidéos tels que les journaux télévisés, le sport, sont ”relativement stable et explicite de leur structure”,¹⁸² et peuvent alors facilement être segmentés, les archives audiovisuelles regroupent des corpus divers et variés, allant de films expérimentaux à des bandes annonces, en passant par des films de famille. Ces archives sont parfois en noir et blanc et muettes.

- adaptation aux algorithmes informatiques

des questions préalables se posent : ”comment regarde-t-on un film ? Quels sont les mécanismes qui permettent d’interpréter cette longue séquence d’images (prenons le cas d’un film muet pour simplifier) en une séquence d’actions dramatiques, reliées entre elles

¹⁷⁸J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives »...

¹⁷⁹*Ibid.*

¹⁸⁰*Ibid.*

¹⁸¹J. Carrive, « Chapitre 4. Analyse automatique de l’image et du son pour l’enrichissement de contenus audiovisuels »...

¹⁸²*Ibid.*

par des liens de causalité, et qui nous permettent d'en comprendre le sens (l'histoire) ? Et comment reproduire cette capacité dans un programme informatique de vision par ordinateur ?"¹⁸³

"Aborder ces questions, c'est poser le problème de la représentation et de la reconnaissance des actions humaines dans les images."¹⁸⁴

- Problèmes de classification liés à l'analyse automatique des films

la reconnaissance des plans : "Il paraît donc utile de déterminer très tôt la taille de plan qui joue très certainement un rôle important pour la reconnaissance de tous les autres éléments de la scène (acteurs, lieux, objets et actions)."¹⁸⁵

reconnaissance des mouvements de caméra reconnaissance des actions : il faut utiliser des séquences annotées.

répertoire de plans ? de séquences ? d'actions ? de genres ?

Rémi Ronfard propose le terme de canevas pour parler des séquences d'un film dans le cadre d'une analyse automatique par IA¹⁸⁶

l'identification de ces "canevas" permettrait ensuite d'identifier le reste des composants vidéo : plans, action, acteurs...¹⁸⁷

¹⁸³Ronfard, Rémi, (*PDF*) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions...*

¹⁸⁴*Ibid.*

¹⁸⁵*Ibid.*

¹⁸⁶*Ibid.*

¹⁸⁷*Ibid.*

Définition du NLP

Le NLP et la recherche sémantique (Tannier, Wang, ressources ISO/Oracle)

« NLP is the area of AI and linguistics concerned with training machines to decipher meaning in human language. » « NLP tools such as Entity Extraction are especially valuable in archival settings because they can help link descriptive data to controlled vocabularies. »¹⁸⁸

limites

« Technologies were primarily trained on white men with regional speaking styles dominant on TV, and didn't work well on speech and accents of people of other cultures or regions. »¹⁸⁹

¹⁸⁸ *AI in Audiovisual Archives / Sound & Vision...*

¹⁸⁹ *Ibid.*

16. Expérience utilisateur

- Côté expérience utilisateur

Skinsoft souhaite améliorer au quotidien son expérience utilisateur. Divers projets en cours le montrent : refonte du tableau de bord de suivi activité, mise en place d'une recherche NLP, mise en place d'un chatbot. Par rapport à d'autres logiciels de gestion de collection qui se limitent à des aspects pratiques d'indexations et de pratiques documentaires, skinsoft souhaite être innovante à tous les niveaux pour rester concurrentielle. Cette concurrence s'exprime notamment à travers l'amélioration continue de l'expérience utilisateur. L'indexation automatique part de cette volonté précise d'améliorer l'expérience utilisateur. Le client n'est pas seulement un professionnel en contexte culturel, il est plus généralement un client d'application dont l'expérience et la fluidité des actions est primordiale pour choisir et garder l'application imaginée par skinsoft. Une sorte de dualité s'installe, celle d'améliorer les pratiques documentaires et celle de faire de l'expérience utilisateur une expérience fluide, personnalisable et efficace. Les deux vont de pair.

Il faut partir de l'expérience utilisateur : quelles sont les attentes, quelles sont les difficultés métier ? est-ce qu'une automatisation des tâches est attendue ? cf. démo avec Yves Klein qui ont demandé de ne pas avoir les nouvelles fonctionnalités IA dans leur espace de travail. Crainte de fuite de données aussi. "the real problems are professional problems – the idea is that the IT people have to be aware of the real problems, the real things to do ; if they don't introduce themselves in the archives they won't be aware of what to do."¹⁹⁰

Indexation automatique et expérience utilisateur : une question de transparence : "Alors que l'utilisation du ML va déjà de soi dans certains domaines, il y a des domaines dans lesquels nous devons rendre son utilisation transparente pour les utilisateurs et leur donner la possibilité d'option de retrait, par exemple lorsqu'il s'agit de données personnelles. La transparence est également requise lorsqu'il s'agit d'adapter l'offre concrète aux besoins des utilisateurs sur la base de profils d'utilisateur (obtenus par le biais de demandes, d'autodéclaration ou de « traces d'utilisation », comme le classement d'une liste de résultats ou des propositions par des systèmes de recommandation)."¹⁹¹

- besoin utilisateur comment répondre à un réel besoin utilisateur et pas seulement à une

¹⁹⁰ *Bringing AI into the Audiovisual Archive / Sound & Vision...*

¹⁹¹ J. Arnold, M. Lüpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

logique produit ?

- Comment donner accès à ces automatisations ? L'exemple d'Amalia.js

Amalia.js est un lecteur HTML5 extensible qui synchronise des métadonnées avec la lecture de flux vidéo ou audio. Conçu pour visualiser les résultats d'algorithmes d'analyse audiovisuelle.

Le besoin à l'origine d'Amalia.js est de permettre de visualiser les résultats de pipelines d'automatisation, avec leur lot de métadonnées produites : « Whatever the field of analysis, we always need to be able to quickly and easily view the results of the methods we are developing. This problem is particularly true as we often manipulate large amount of videos. Developing visualization and annotation tools is often a tedious task that deserves to be pooled. »¹⁹² « The analysis being at different levels (keyframes, video segments, audio channels, associated synopses, one video alone or relative to a corpus...) results are obtained in very different natures, often needing quite specific approaches to be presented to the end user. »¹⁹³ L'indexation automatique regroupe tout un tas de métadonnées issues d'algorithmes et d'outils différents qu'il faut réunir dans une interface de présentation.

C'est une interface pour visualiser et pour corriger.

Comment regrouper dans la même interface des métadonnées de nature très différentes attachées à la même vidéo ?

Les métadonnées horodatées : issues de la segmentation vidéo.

« The main principle of amalia.js is to have a unified metadata model. Ensuring that all the metadata types are consistent and use the same standards will facilitate their use and enable us to design generic visualization plugins. »¹⁹⁴. Importance d'avoir une interface de standardisation des métadonnées : important pour skinsoft qui doit s'adapter aux normes employées par les clients.

Le logiciel permet à l'utilisateur d'annoter la vidéo pour corriger les métadonnées ou les compléter : « This will allow us to enter or correct metadata directly through the player. We plan to use this version in groundtruth management applications so as to enable the creation of huge research datasets used to train supervised algorithms or to assess analysis methods performances. »¹⁹⁵. La correction humaine permet d'avoir des métadonnées plus justes, mais permet aussi d'avoir des données d'entraînement

¹⁹²N. Hervé, P. Letessier, M. Derval, *et al.*, « Amalia.Js... ».

¹⁹³*Ibid.*

¹⁹⁴*Ibid.*

¹⁹⁵*Ibid.*

pour améliorer les algorithmes d'indexation automatique. (aussi vu chez Vanderbilt).
Utiliser comme rôle de correction et d'enrichissement sur une base générée automatiquement.

17. Limites et critiques

- Limites générales de l'IA

les modèles d'IA sont entraînés en anglais, pose des questions d'adaptabilité : "Les IA conversationnelles reposent sur des grands modèles de langue (LLM) entraînés principalement sur des données en anglais, ce qui crée des biais linguistiques et culturels dans les résultats qu'ils produisent. [...] Il est donc indispensable que ces modèles soient entraînés avec une diversité de sources culturelles et linguistiques, y compris les langues régionales et les expressions artistiques moins représentées"¹⁹⁶

- Limites contextuelles

« How to give context to the machines? To give common sense? It's a problem of artificial intelligence from the beginning. »¹⁹⁷

- limites de l'automatisation :

"l'intégration de la vision artificielle aux méthodes des historiens n'existe que conjointement à des interventions humaines, qui assurent la pertinence des traitements effectués et apportent une analyse nécessaire."¹⁹⁸

- sur l'indexation automatique audio : « Audio archives present a complex terrain for contemporary speech processing technologies, owing to the varied domains these recordings encapsulate. »¹⁹⁹ : deux problèmes sur un corpus d'archives anciennes : variabilité linguistiques (multilingues, accents différents), variabilité temporelle (vieillesse des voix). les archives audiovisuelles sont un matériau hétérogène : opacité du médium.
- sur l'indexation automatique des archives audiovisuelles

IL est important pour les archivistes de savoir comment ont été entraînés les modèles qu'ils utilisent, sur quelles données.

la vidéo : souvent de moins bonne qualité que l'image fixe, donc les résultats d'indexation automatique peuvent être moins bons

contrairement aux documents textuels qui comportent souvent des éléments d'indexation dans leur forme (couverture de livre,) les archives audiovisuelles n'en contiennent

¹⁹⁶ *La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture...*

¹⁹⁷ *AI in Audiovisual Archives / Sound & Vision...*

¹⁹⁸ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

¹⁹⁹ P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

peu ou pas, ce qui les rend opaques et peu réceptives aux pratiques d'indexation. Il s'agit alors de mettre en place une « indexation par le contenu ».²⁰⁰

Lacunes

l'article de attard souligne que « The study underscores the lack of specialised annotation tools and the high resource demands of sophisticated models, which could present significant obstacles for future research with limited computational resources. »²⁰¹ c'est une limite surtout pour les institutions. Rejoint l'argument et les limites exposées par²⁰²

Les modèles multimodaux qui combinent audio et vidéo (vivit-ast) ne donnent pas les meilleurs résultats. Il faudrait donc adopter des architectures plus simples, qui demandent moins de calcul d'usage et qui séparent les pipelines.²⁰³

Absence d'outils d'annotation spécialisés dans la segmentation vidéo. Attard adapte label studio, un outil généraliste.²⁰⁴

Limites des transformers : « ViT has been shown to only be effective when trained on large-scale datasets, as transformers lack some of the inductive biases of convolutional networks, and thus require datasets larger than the common ImageNet ILSRVC dataset to train. »²⁰⁵. : les transformers n'ont pas les biais des CNN qui leur permettraient de faire des généralisations et de reconnaître un objet où qu'il soit dans l'image. Ils ont donc besoin d'être entraînés sur beaucoup plus de données : c'est une grande limite. Une approche par classifieurs d'images plus légers comme ResNet peut donc être préférable. ViViT obtient de très bons résultats mais entraînés sur des corpus vidéos contemporains : vidéos youtube. Difficilement adaptable à un corpus d'archives historique sauf pré entraînement massif.

- éthique de l'IA

Sur l'éthique de l'expérience utilisateur : Principles for Accountable Algorithms : responsibility, explainability, accuracy, auditability, fairness²⁰⁶

Limites du machine learning : "Une répartition arbitraire des systèmes est toutefois limitée dans la mesure où, d'une part, les systèmes entraînés ont souvent un domaine

²⁰⁰B. Bachimont, *Indexation et archivage de contenus multimédias...*

²⁰¹J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

²⁰²P. Sullivan et M. Abdul-Mageed, *On Barriers to Archival Audio Processing...*

²⁰³J. Attard et D. Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation...*

²⁰⁴*Ibid.*

²⁰⁵A. Arnab, M. Dehghani, G. Heigold, *et al.*, *ViViT...*

²⁰⁶*Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML...*

d'application spécifique et, d'autre part, leurs capacités sont fortement liées aux jeux de données utilisés. Les algorithmes entraînés avec différents jeux de données produisent des résultats différents.”²⁰⁷

- Biais de la computer vision appliquée aux images :

”For instance, racial bias has been an ongoing challenge with computer vision tools, particularly with facial recognition software. A study published by MIT Media Lab in 2018 found that facial recognition software had an average error rate of 0.8 percent for light-skinned men, versus a 34.7 percent error rate for darker-skinned women”²⁰⁸ ”societal biases are often engrained in AI model training datasets, which lead to the models reproducing those biases in their outputs”²⁰⁹ ”In addition to this, the training data of computer vision models has relied mostly on visual content available to be harvested from the Internet, which in its majority corresponds to content developed during the last three decades. These models would underperform on images that are of a more historical character, commonly found in visual archives, since they are underrepresented in the training data”²¹⁰

Limite liée à la qualité des images : la qualité des images est absolument primordiale et déterminante dans la mise en place d'un pipeline d'indexation automatique : ”La question de la qualité des images est cruciale dans le cadre d'un projet de recherche en vision artificielle, puisque celle-ci a la possibilité d'impacter les performances de l'algorithme utilisé, et d'affecter négativement les interprétations du modèle”.²¹¹ Important dans le cadre d'une indexation d'archives audiovisuelles, qui sont souvent de moins bonne qualité que les images car les fichiers sont plus lourds.

limites des réseaux de neurones profonds tels que les CNN pour l'analyse de l'esthétisme des images : « While hand-crafted features allow to quantify which feature contributes the most to an aesthetic rating, this interpretability is lost with generic features. [...] Deep neural networks and generic features basically represent a black-box approach that lacks this kind of interpretability. »²¹² ”with deep learning models, their success comes at a cost. At present, the understanding of deep features and how they work in object or aesthetic recognition lags behind. »²¹³ Le problème est le suivant avec

²⁰⁷J. Arnold, M. Lüpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

²⁰⁸K. Fewster et R. Arias, « Teachable AI for the Archival Professions – Module 4 : »...

²⁰⁹*Ibid.*

²¹⁰*Ibid.*

²¹¹J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

²¹²A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

²¹³*Ibid.*

les CNN, les décisions qui sont prises sont obscures. Pour l'indexation des archives, c'est problématique si les archivistes ne sont pas capables d'expliquer pourquoi telle classification a été choisie par le modèle. Il faut maintenir une supervision humaine dans le pipeline d'indexation. La question de l'interopérabilité et de la transparence est aussi importante que la question de performance en sciences humaines et dans le milieu du patrimoine, car il s'agit de donner accès aux connaissances. (à relier avec l'éthique de l'IA : principes MA/ML : explainability)

La machine analyse différemment de l'humain, de manière objective et précise et exhaustive, qu'apporte l'humain ? : "the computational analysis of paintings has several advantages compared to an analysis carried out by human experts. For example, a computational analysis can pick up very subtle relationships that may escape the attention by human observers ; moreover, computational methods are objective in nature and are potentially non-exhaustive in the amount of detail analyzed. »²¹⁴

- Dépendance à la qualité de l'image

Limite exprimée dans le cadre de l'utilisation de line segment detection : "The first general challenge for line segment detection and description is that the endpoints of detected line segments are generally unstable due to many factors, such as image noise, occlusion, and illumination variance. This makes the line segment description and matching difficult since the corresponding line ROS (Region of Support) or neighborhood relationship among line segments is generated according to the line segment endpoints. »²¹⁵

La compréhension et l'analyse de l'image dépend de la qualité de l'image, souvent réduite pour des raisons de stockage de données, pendant l'entraînement.

²¹⁴*Ibid.*

²¹⁵Xinyu Lin, Y. Zhou, Y. Liu, *et al.*, *A Comprehensive Review of Image Line Segment Detection and Description...*

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visit  le 07/05/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visit  le 12/05/2026).
- ARNAB (Anurag), DEGHANI (Mostafa), HEIGOLD (Georg), SUN (Chen), LUĆIĆ (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), L POLD (Martin), THEILK S (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'acc s Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4–2 (juill. 2019), DOI : 10.22148/16.043.
- ASPERTI (Andrea), DESS  (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Indexation et archivage de contenus multim dias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visit  le 05/06/2026).
- BASSA STEGUY (Sidonie), *Le M dium, c'est La M moire : Archivages Du Document   l'Institut National de l'audiovisuel*, m m. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visit  le 13/05/2026).

- BERGMANN (Cole Stryker Dave), *Qu'est-ce qu'un modèle transformer ? / IBM*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BERMÈS (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l'IA 2025 », dans *Conférence Nationale Sur Les Applications de l'Intelligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- BOEUF (Patrick), « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/unauthorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters, Video-Based Object and Event Analysis 30-2* (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARON (Mathilde), BOJANOWSKI (Piotr), JOULIN (Armand) et DOUZE (Matthijs), « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.
- CARRIVE (Jean), « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What's the Difference ? / IBM*, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- FIAT/IFTA *Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).
- France 2030 : un plan d'investissement pour la France | *economie.gouv.fr*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].
- HERVÉ (Nicolas), LETESSIER (Pierre), Derval (Mathieu) et NABI (Hakim), « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- IFLA STUDY GROUP ON THE FUNCTIONAL REQUIREMENTS FOR BIBLIOGRAPHIC RECORDS, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).
- INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).
- L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).
- La stratégie du ministère pour des intelligences artificielles culturelles et responsables | Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).

- LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).
- Les secrets du traitement du langage naturel décryptés*, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).
- LETESSIER (Pierre), HERVÉ (Nicolas), JOLY (Alexis), NABI (Hakim), DERVAL (Mathieu) et BUISSON (Olivier), « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.
- LIU (Haotian), LI (Chunyuan), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].
- LIU (Ying-Hsang), « Navigating the AI-Driven Metadata Landscape : A Human Centered Approach » ().
- LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Manan), HAMDY (Mohammed), *et al.*, *Bridging the Data Provenance Gap Across Text, Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].
- MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].
- MOIRAGHI (Eleonora), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs.CV].
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

- *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, p. 152, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 08/06/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).
- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).
- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).
- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).
- Qu'est-ce qu'un réseau de neurones convolutifs ? | IBM*, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).
- Qu'est-ce que la conception de chatbot ? | IBM*, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).
- ROBERT (Jérémy), *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).
- RONFARD, RÉMI, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).

- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- SULLIVAN (Peter) et ABDUL-MAGEED (Muhammad), *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605.
- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).
- TILLETT, BARBARA B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.
- Traitement du langage naturel : découvrez comment les machines lisent et écrivent*, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).
- VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*–hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

- XINYU LIN, ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].
- YOLO Algorithm for Object Detection Explained [+Examples], janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- YOON (Sangwoong), KANG (Woo Young), JEON (Sungwook), LEE (SeongEun), HAN (Changjin), PARK (Jonghun) et KIM (Eun-Sol), *Image-to-Image Retrieval by Learning Similarity between Scene Graphs*, déc. 2020, DOI : 10.48550/arXiv.2012.14700, arXiv : 2012.14700 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.
- ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wenguan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

Mon introduction

Première partie

Une partie

Chapitre 1

Mon premier chapitre

Deuxième partie

Une autre partie

Conclusion

Annexe A

Le titre très long de la première
annexe

Table des matières

Résumé	i
Partie 1 - Indexer les archives audiovisuelles	v
I. Le FRBR, modèle d'indexation conçu pour les bibliothèques	v
II. Adapter le FRBR aux archives audiovisuelles	v
III. Automatiser l'indexation des collections audiovisuelles basée sur le FRBR . .	vi
Partie 2 - Implémenter l'indexation automatique des archives audiovisuelles au sein d'une remodelisation du FRBR	vii
IV. Le projet d'implémentation de l'IA chez Skinsoft (projet Skai), dont l'analyse vidéo est une composante majeure	vii
V. Séquençage et analyse d'un corpus audiovisuel (exemple du corpus de musée Albert Kahn)	viii
VI. Reversement des métadonnées dans le modèle FRBR : dans quelle mesure les résultats produits peuvent-ils s'inscrire au sein de ce modèle d'indexation ? .	viii
Partie 3 - Biais, limites et enjeux	ix
VII. Les archives audiovisuelles comme données d'entraînement	ix
VIII. La difficulté d'adaptation au modèle de données, même avec un entraînement adéquat	ix
IX. Vers une indexation augmentée plutôt qu'automatisée	x
1. IE FRBR, modèle d'indexation conçu pour les bibliothèques	xiii
2. Contexte skinsoft	xiv
3. S-Movies	xix
4. Problématique	xxi
5. analyse automatique de l'image	xxv
6. Indexation automatique	xxvi
7. indexation iconographique	xxix

8.	indexation audio	xxxix
9.	notions IA	xxxix
10.	machine learning	xxxix
11.	computer vision	xxxviii
12.	IA appliquée à la vidéo	xli
13.	segmentation	xlvi
17.	Limites et critiques	lxvi
15.	Archives audiovisuelles	lix
16.	Experience utilisateur	lxiii
17.	Limites et critiques	lxvi
Remerciements		lxxi
Introduction		lxxxix
I Une partie		1
1	Mon premier chapitre	3
II Une autre partie		5
Conclusion		7
A Titre court		9